


PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Rafael Gastão Coimbra Ferreira



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Análise exploratória de dados

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir o processo de análise exploratória.
- Descrever as etapas de uma análise exploratória.
- Reconhecer os objetivos e importância de uma análise exploratória de dados.

Introdução


As empresas cada vez mais procuram armazenar um grande volume de dados. Novas tecnologias de armazenamento surgiram e ganharam espaço, permitindo a representação de uma grande variedade de informações ditas não estruturadas, ou seja, não necessariamente com um formato único de representação e de uma única origem. Ambientes heterogêneos, a exemplo da *web*, permitiram sua manipulação e, consequentemente, seu cruzamento, gerando uma nova ciência de dados. Somada aos conceitos da matemática, a análise de dados fornece resultados confiáveis e consistentes.

Entretanto, essa ciência de dados também é baseada no valor gerado pelos métodos estatísticos e algoritmos, que ajudam na descoberta de padrões nos dados. Um único método de acesso e análise de dados não vai gerar os resultados esperados. O segredo em uma análise de dados eficiente é, por meio de uma análise exploratória desses dados, realizar uma atividade de observação mais de uma vez e por diferentes perspectivas.

Neste capítulo, você vai estudar os conceitos relacionados à análise exploratória de dados e ver suas etapas relevantes e sua importância, quando realizada antes de o conjunto de dados ser submetido a uma análise mais profunda, por meio de técnicas e ferramentas de investigação. Essa análise permite realizar a tentativa e erro, uma etapa importante dessa ciência.

1 Análise exploratória de dados

Hoje cada vez mais temos acesso a dados dos mais variados tipos e formatos. Além disso, a quantidade de dados com acesso à informação vem aumentando. Para um projeto de ciência de dados (*data science*), é necessário tratar e analisar os dados brutos até se transformarem em informação. O uso correto dessa informação a transforma em conhecimento, e o ato de utilizarmos esse conhecimento em benefício da tomada de decisão gera o conhecimento como sabedoria. A Figura 1 apresenta uma pirâmide com as diferentes etapas de transformação do dado.



Os dados obtidos para um projeto preditivo não chegam em pacotes prontos e formatados para análise. Os dados brutos variam substancialmente em formato e é necessário transformar todas as fontes de dados de modo que a análise possa ser feita. Uma transformação nos dados pode envolver mudanças nos tipos de dados existentes ou até mesmo na criação de dados (algo como corrigir erros) baseada nos dados existentes.

A finalidade da **análise exploratória de dados (AED)** é verificar os dados para qualquer aplicação estatística. Com isso, obtemos entendimento sobre os dados coletados e, principalmente, sobre as relações existentes entre as variáveis analisadas. O Quadro 1 apresenta as estratégias utilizadas em diferentes abordagens estatísticas, incluindo a AED.

Quadro 1. Abordagens estatísticas e estratégias utilizadas

Abordagem	Estratégia
Estatística clássica	Problema → Dados → Modelo → Análise
Estatística bayesiana	Problema → Dados → Modelo Priori → Análise
AED	Problema → Dados → Análise → Modelo

Fonte: Adaptado de Capítulo... ([2011]).

Você pode observar que as estatísticas clássica e bayesiana geram um modelo e depois fazem a análise dos dados. Já a AED faz a análise dos dados por meio de mineração antes de indicar o modelo a ser utilizado. A AED tenta olhar para os dados de forma mais profunda sem resumir muito a quantidade de informações.

Classificação dos dados

Em uma análise exploratória os dados são considerados como variáveis, a exemplo de peso, altura, sexo e idade de determinado indivíduo. Tais variáveis podem representar diferentes valores, como valores numéricos e valores não numéricos.

Valores numéricos, também conhecidos como **valores quantitativos**, podem ser representados de duas formas: por valores inteiros, chamados de **discretos**, ou por valores no intervalo de números reais, chamados de **contínuos**. Utilizando os exemplos citados, *idade* seria um exemplo de valor quantitativo discreto e *peso* seria um exemplo de valor quantitativo contínuo.

Valores não numéricos, conhecidos como **valores qualitativos**, podem ser tratados como valores **nominais**, quando suas categorias de dados não seguem uma ordem natural — por exemplo, valores relacionados ao *nome*, *cor* e *raça* do indivíduo. Para categorias de valores ordenados, a exemplo da *classe social* (baixa, média e alta) ou *tamanho de uma roupa* (pequeno, médio e grande), se tem o tipo de valor qualitativo **ordinal**.

Técnicas gráficas e resumos numéricos

Gráficos são utilizados para representar informações quantitativas, pois são visualmente mais intuitivos para o leitor. Os gráficos são construídos a partir de dados em formato tabular. O objetivo principal dos gráficos é dar uma visão mais rápida e fácil dos dados a que se referem. Já uma tabela fornece uma ideia mais precisa dos dados e de como eles podem ser tratados.

A Figura 2 apresenta uma tabela com as quantidades vendidas de cada produto e um gráfico com as mesmas informações. Perceba que fica muito mais fácil visualizar que a laranja foi o produto mais vendido, uma vez que 200 do total de 830 vendas (isto é, 24,09%) foram deste produto. A qualidade na representação gráfica deve estar focada na clareza, simplicidade e autoexplicação. As técnicas gráficas desempenham um papel fundamental na AED, pois, como visto na Figura 1, é a partir da análise dos dados que se indica o modelo a ser utilizado.





Figura 2. Tabela de vendas x gráfico de vendas.

Para Gabriel Stankevix ([2020]), a análise exploratória dos dados é considerada a principal etapa da análise dos dados. Ela inclui um processo de organizar, resumir, aplicar alguns cálculos e resumir as informações em um formato adequado à visualização.

2 Etapas de uma análise exploratória de dados

Segundo Navidi (2012), uma amostra é uma longa lista de valores. Para destacar as características dessa amostra, normalmente se calculam algumas medidas estatísticas. As mais comuns dessas medidas são a média amostral e o desvio padrão amostral. A **média amostral** indica onde esses dados estão centralizados, e o **desvio padrão** fornece uma indicação de quão dispersos estão esses dados. A estatística descritiva é composta das medidas estatísticas calculadas.

A **estatística descritiva** consiste em interpretar os dados, visualizá-los e após relacioná-los com as variáveis. Ela está diretamente relacionada com os objetivos da pesquisa e é composta por etapas, conforme apresenta a Figura 3.



O trabalho da AED é geralmente dividido em várias etapas: coleta, organização, tratamento, análise, apresentação e interpretação dos dados. Ressalta-se neste ponto que a estatística descritiva está, portanto, fortemente relacionada com o processo de AED, uma vez que as etapas de organização, tratamento, análise e apresentação de dados utilizam técnicas descritivas. Compreender as etapas dessa análise orienta sua realização de forma correta. A seguir serão detalhadas cada uma dessas etapas.

Coleta e organização de dados

Na etapa de coleta de dados, deve-se definir quais serão os métodos de coleta utilizados. Inicialmente, são definidos os objetivos, ou seja, as questões da pesquisa; depois disso, define-se quais dados serão coletados e como serão coletados.

A organização dos dados consiste em estabelecer como obter informações a partir dos dados coletados a respeito de uma ou mais características de interesse. É muito importante levar em consideração a natureza dos dados. Por exemplo, em uma base de dados, existem dados que devem ser coletados em diferentes colunas de uma tabela — digamos, uma data de nascimento, na qual os valores do dia, mês e ano estão em colunas separadas — e devemos unificar esses dados para unificar a informação.

Tratamento de dados

A etapa de tratamento dos dados visa a melhorar ou adequar o conjunto de dados obtidos. Os resultados de uma pesquisa podem ser fortemente comprometidos devido ao fato de as pessoas se sentirem constrangidas e não quererem responder determinada questão, a exemplo da renda familiar, orientação sexual, religião. Para essas situações, é necessário definir qual solução será adotada. No exemplo da informação faltante, pode-se optar por descartar a pessoa que tenha pelo menos uma variável faltante, ou pode-se preencher o dado faltante com técnicas de **imputação de dados**, nas quais o dado pode ser substituído por um valor, como a média ou a repetição do último valor, ou por uma regressão linear. É muito importante observar que as técnicas de imputação dependem do tipo de dado faltante.

O objetivo da normalização de valores é deixar todos os valores numéricos em uma escala comum sem distorcer as diferenças no intervalo de valores, ou seja, transformar um conjunto de dados que estão em diferentes grandezas e escalas em um conjunto de dados padronizados.

Ainda existe nessa etapa o tratamento de *outliers*, que é considerado um valor extremo, ou seja, são valores que fogem da média dos demais valores. Um *outlier* nada mais é que uma observação que está muito distante do padrão observado naquele conjunto de dados, e pode ser causado por entrada errada de dados ou erros em tempo de tratamento. De qualquer forma, os *outliers* terão impacto em uma análise. Como solução, pode-se realizar sua remoção, seu tratamento individual ou sua transformação.



Fique atento

Para tratar os *outliers* é importante analisar bem o problema em questão e montar um modelo preditivo, entendendo se o *outlier* faz parte da necessidade para atender ao problema, ou se deve ser descartado para não prejudicar os resultados a serem atingidos. Por exemplo, em uma análise de crédito, você avalia a movimentação bancária de determinado correntista e percebe um valor de crédito muito alto na conta, fora da média de valores creditados mensalmente. Se o problema proposto é a análise de fraude, esse *outlier* será útil, ou seja, se o objetivo é detectar anomalias na conta corrente, o que se deseja detectar, na verdade, são os *outliers*. Entretanto, se o problema proposto é analisar o comportamento do perfil de cliente com relação a seus créditos em conta corrente, tal *outlier* vai distorcer os valores e deve ser removido.

Análise de dados

Para a etapa de análise dos dados, podem ser realizadas as análises univariada, multivariada e de correlações. A **análise univariada** consiste em avaliar cada uma das variáveis isoladamente. A ideia é conhecer o comportamento de cada variável por meio de sua classificação como qualitativa (ordinal ou nominal) ou quantitativa (contínua ou discreta). Assim, o objetivo é analisar a ocorrência de seus possíveis valores, e o resultado é a definição de sua frequência de possíveis valores.



Exemplo

Em uma análise da variável *idade*, podemos obter, em uma coleta de dados, os seguintes valores: {18, 19, 18, 21, 21, 18}. A frequência dessa variável *idade* seria assim definida: {18 — 3 ocorrências, 19 — 1 ocorrência e 21 — 2 ocorrências}.

Já a **análise multivariada** estabelece relações entre duas ou mais variáveis. Por exemplo, a altura da pessoa mediante o sexo e a idade.

As correlações ocorrem quando dois acontecimentos, os quais não necessariamente são causalidades, tendem a ocorrer de forma sincronizada. Por exemplo, a inflação alta tende a aumentar o desemprego. Outro exemplo é o seguinte: se um cliente almoça todos os dias no mesmo restaurante, a tendência é que as variáveis “frequência semanal de almoço” e “satisfação com a comida” estejam relacionadas.

Apresentação e interpretação de dados

Para Medri (2011) existem duas formas de realizar a etapa de apresentação dos dados: por meio de uma apresentação tabular ou de uma apresentação gráfica. A **apresentação tabular** é a representação usando uma tabela, que deve ter alguns elementos essenciais, como título da tabela, títulos das colunas e corpo com o conjunto dos dados.

Já a **representação gráfica** deve ser autoexplicativa e de fácil compreensão. Existem diferentes tipos de gráficos para cada uma das variáveis que se quer representar, a exemplo dos gráficos de colunas, barras, linhas, setores, entre outros.

Essa etapa é uma das mais importantes, visto que serão apresentados os dados obtidos. Para isso deve-se escolher a melhor maneira de apresentar esses dados, seja tabular, seja por meio de gráficos, porém os gráficos escolhidos devem ser os adequados para os tipos de dados obtidos, como dados quantitativos ou qualitativos. Por exemplo: a variável *estado civil*, classificada como qualitativa nominal, permite ter a frequência de vezes que cada categoria aparece (casado = 26, solteiro = 18, separado = 8). Neste caso, o melhor tipo de gráfico para sua representação é o gráfico de barra.

A Figura 4 mostra a variável *estado civil* representada por um gráfico de radar. Perceba que fica evidente que tal escolha não é a melhor forma de sua representação, pois esse tipo de gráfico não deixa clara a correlação existente entre os valores da variável *estado civil* e sua frequência obtida.

Estado Civil	Frequência
Casado	26
Solteiro	18
Separado	8




Figura 4. Gráfico de radar.

A partir da apresentação dos dados, a etapa de interpretação dos dados permite definir o modelo a ser aplicado para o problema em questão. Como apresentado no Quadro 1, iniciamos com a análise dos dados para depois definir o modelo a ser utilizado.



Fique atento

Antes de começar a usar algoritmos, é importante você entender a estrutura dos dados que tem em mãos — por exemplo, presença de valores ausentes, distribuição de variáveis, correlação, desvio-padrão, etc.

Essas etapas servem como um roteiro para evitar que dados mal coletados, sem curadoria ou aplicados sem muito critério, possam introduzir distorções nas aplicações de aprendizado de máquina (*machine learning*). Um bom exemplo dessa distorção pode ser o uso do algoritmo de classificação chamado de KNN (*K-nearest neighbors*). A ideia desse algoritmo é poder classificar os valores, permitindo que novos valores possam ser classificados mediante o cálculo de K-vizinhos mais próximos. Agora, considere que, em uma coleta de dados com indivíduos para uma variável *sexo*, você obtém os seguintes valores: *M*, *F* e *10*. Os valores *M* e *F* representam a categoria válida, mas o valor *10* passa a ser um valor fora da escala. Se esse valor não for corrigido,

o algoritmo não encontrará uma boa relação entre os dados e, com isso, o resultado apresentado nos dados de treino será ruim.



Saiba mais

A aprendizagem de máquina (*machine learning*) é uma subárea da inteligência artificial. Trata-se do processo de uma máquina conseguir aprender sozinha a realizar determinada tarefa sem ter sido programada explicitamente para isso.

3 Objetivos e importância de uma análise exploratória de dados bem feita

A AED é uma etapa importante para um projeto de *analytics*, pois quebra a ideia de que *data science* é apenas a execução de algoritmos e que deve envolver apenas conceitos de aprendizado de máquina ou técnicas complexas para agregar valor. Toda fase de um projeto de *data science* pede uma análise exploratória, a qual permite entender o dado, conhecer as suas relações e extrair diversos *insights*. Uma AED bem feita possibilita encontrar tendências e extrair valor nos dados, incluindo o conhecimento.

Uma base de dados, quando submetida a uma análise, pode conter diferentes problemas, como dados ausentes (*missing values*), valores discrepantes, valores truncados, dados corrompidos ou dados incompletos. Um exemplo disso pode ser visto na Figura 5, que mostra uma base de dados para registrar a alocação de casas, considerando os seguintes dados: identificador, rua, número da casa, *status* de alocação, quantidade de quartos e banheiros.

Missing values						
Linha	ID	Rua	Nº	Alocada	Quartos	Banheiros
1	100		21	Sim	3	2
2	200	Rua João Vicente	33	222	4	3
3	300	Av João da Silva V	567	Não	1	1

Corrompido

Figura 5. Dados com erro.

Um erro de dado ausente (*missing value*) pode ser observado na linha 1, para a coluna *Rua*. Já a coluna *Alocada*, linha 2, contém um dado corrompido de tipo inteiro, uma vez que a coluna é representada por valor *string*. Neste caso, evidencia-se o que chamamos de ruído, pois esse campo apenas deve ser representado pelos valores *Sim* e *Não*. O objetivo desta etapa como um todo é avaliar uma base de dados e mapear os dados com erros, assim como tratar esses problemas.

Não resolver valores discrepantes, ou seja, valores inteiros em *string* e vice-versa, gera um problema de erro genérico de *string*, quando submetido a um algoritmo de aprendizado de máquina. A AED permite ajustar os dados para que possam ser submetidos a um classificador de forma correta.

Identificando outliers

Domínio pode ser conceituado como um conjunto de valores os quais representam determinado dado. Um exemplo pode ser aplicado no domínio do campo *cor*, representado pelos valores *azul*, *vermelho*, *verde*, *branco* e *preto*. Quando esse domínio apresenta valores que se diferenciam drasticamente de todos os outros, são pontos fora da curva.

Em outras palavras, um *outlier* é um valor que foge da normalidade e que pode (e provavelmente irá) causar anomalias nos resultados obtidos por meio de algoritmos e sistemas de análise. A Figura 6 mostra um exemplo de cadastro de trabalhadores solicitantes da aposentadoria e alguns dados são apresentados: código, nome completo, idade e último salário.

Linha	Código	Nome completo	Idade	Último salário
1	201	Antonio Nunes	64	
2	202	Maria da Silva	71	
3	203	Pedro Antunes de Oliveira	59	
4	204	João da Silva	475	

Outliers

Figura 6. Outliers.

Observe que a linha 4 da coluna *Idade* apresenta um grande afastamento das demais da série, ou seja, um valor de idade atípico, sendo então um valor inconsistente. A existência desse valor vai provocar prejuízos na interpretação dos resultados das análises aplicadas.

Novamente, a exploração dos dados permite entender os *outliers*, permitindo evitar visões negativas como resultado de uma análise, caso não seja, justamente, o que está sendo procurado. Realizar uma análise separada apenas com os *outliers* é uma abordagem útil quando se quer investigar casos extremos, como, por exemplo, desempregados que sempre solicitam seguro desemprego, alunos que só tiram notas máximas, empresas que apresentam alto lucro mesmo em tempos de alta inflação, casos de fraudes, entre outros.

Resolvendo problemas no pré-processamento

Um projeto de aprendizado de máquina utiliza, como amostragem, um conjunto de dados os quais contêm características representadas por valores. Cada uma dessas características se apresenta em uma escala de valores distintos, a exemplo das propriedades de um produto, em que a altura se apresenta em centímetros e o peso em gramas. Quando se aplicam esses dados em um algoritmo de *machine learning*, este poderá considerar mais o peso, por exemplo, ou seja, poderá dar mais importância a certas características devido a seus maiores valores, e não necessariamente a sua maior relevância.

No âmbito de um algoritmo de aprendizado, as características são tratadas como unidades, e seus valores, como magnitudes. Cada unidade deve ter pesos semelhantes. Para lidar com essas escalas diferentes, existem modelagens chamadas de pré-processamento, como reescalonar, normalizar e padronizar.

Reescalonar significa alterar a unidade de medida dos dados, convertendo em determinada proporção — por exemplo, converter peso de mililitros para litros. **Normalização** significa dividir por uma norma do vetor, por exemplo, subtrair dados do vetor menor e dividir pela subtração do valor máximo e valor mínimo, assim colocando os dados em uma faixa de 0 a 1. Já a **padronização** trata de subtrair os dados por uma medição de localização e dividir por uma média de escala, permitindo deixar os dados mais próximos da medida normal, possível. Um exemplo seria subtrair os valores pela média e dividir pelo desvio-padrão.

Podemos concluir então que a baixa qualidade dos dados prejudica a execução de um projeto analítico, prejudicando a aplicação de técnicas relacionadas ao aprendizado. A má qualidade dos dados é uma das maiores preocupações dos cientistas de dados, e pode colocar em risco os esforços de análise de *big data*, apesar das melhores intenções dos cientistas de dados e outros profissionais que trabalham com informações.

Normalmente, em projetos de grande magnitude, as empresas superestimam a resiliência dos algoritmos de aprendizado de máquina e subestimam os efeitos de dados com erros. A má qualidade dos dados produz resultados ruins e resulta em análises de negócio erradas. Os resultados dessas decisões prejudicarão o desempenho dos negócios e dificultarão o apoio a iniciativas futuras. Em projetos relacionados à aprendizagem de máquina, pode-se detectar uma qualidade de dados insatisfatória a partir de resultados que simplesmente parecem não fazer sentido, com base na experiência passada e atual.



Referências

BONAT, W. H.; KRAINSKI, E. T.; MAYER, F. P. *Introdução à análise exploratória de dados*. 38 slides. Material de aula do Departamento de Estatística da Universidade Federal do Paraná. Disponível em: http://cursos.leg.ufpr.br/ce001/slides/01_Analise_Exploratoria.pdf. Acesso em: 28 jun. 2020.

CAPÍTULO 1: análise exploratória de dados. [S. l., 2011]. Disponível em: http://www.each.usp.br/lauretto/SIN5008_2011/aula01/aula1. Acesso em: 28 jun. 2020.

MEDRI, W. *Análise exploratória de dados*. Londrina: [s. n.], 2011. Material de aula do Departamento de Estatística da Universidade Estadual de Londrina. Disponível em: http://www.uel.br/pos/estatisticaquantitativa/textos_didaticos/especializacao_estadistica.pdf. Acesso em: 28 jun. 2020.

NAVIDI, W. *Probabilidade e estatística para ciências exatas*. Porto Alegre: AMGH, 2012.

NUNES, C. E. *Aula3 Carlos: dado, informação, conhecimento e sabedoria*. [S. l.], 2015. 10 slides. Disponível em: <https://pt.slideshare.net/carlosnunes77/aula3-carlos>. Acesso em: 28 jun. 2020.

STANKEVIX, G. *Análise Exploratória de Dados*. [S. l., 2020]. Disponível em: <https://medium.com/@gabriel.stankevix/analise-explorat%C3%B3ria-de-dados-732007ddbfa>. Acesso em: 28 jun. 2020.

Leituras recomendadas

MACHADO, F. N. R. *Projeto de Data Warehouse: uma visão multidimensional*. São Paulo: Érica, 2000.

VIALI, L. *Série estatística multivariada: introdução*. [S. l., 199-?]. Disponível em: <http://www.pucrs.br/ciencias/viali/especializa/realizadas/ceea/multivariada/textos/Introducao.pdf>. Acesso em: 28 jun. 2020.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integridade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS