


ENGENHARIA DE CONHECIMENTO



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Visão holística dos dados na internet

Rafael Gastão Coimbra Ferreira

OBJETIVOS DE APRENDIZAGEM

- > Explicar o que são dados abertos, destacando suas principais características.
- > Diferenciar dados conectados de dados abertos.
- > Analisar o uso de dados conectados para o desenvolvimento de sistemas.

Introdução

Cada vez mais as populações buscam ter acesso a dados para obter informações e conhecimentos interrelacionados sobre um determinado assunto. Essa correlação possibilita obter melhor veracidade e integridade das informações dispostas. Em virtude dessa necessidade, órgãos têm oferecido seus dados em formato aberto, possibilitando que pessoas ou máquinas possam usar essas informações de maneira pessoal ou automatizada.

Neste capítulo, você vai estudar os dados abertos, suas principais características e como se diferenciam dos dados conectados. Vai também conferir exemplos de como os dados conectados são aplicados no desenvolvimento de sistemas.

Características dos dados abertos

Dados abertos são dados que podem ser acessados, utilizados, modificados e compartilhados por qualquer pessoa para diferentes finalidades (PORTAL BRASILEIRO DE DADOS ABERTOS, c2020). Para que possam ser considerados abertos, os dados devem ter as três características a seguir.

1. **Acesso e disponibilidade:** devem ser disponibilizados por completo, em formatos que facilitem a sua modificação e sem cobranças. Normalmente, estão disponíveis em portais na internet, muitas vezes por órgãos governamentais em portais do governo.
2. **Reutilização:** devem permitir o reuso, inclusive para utilização em outras bases de dados.
3. **Participação universal:** qualquer pessoa pode fazer o uso e distribuir os dados sem que exista alguma restrição quanto a isso.

Essas características foram resumidas em três leis por David Eaves, ativista dos dados abertos (PORTAL BRASILEIRO DE DADOS ABERTOS, c2020, documento *on-line*):

1. Se o dado não pode ser encontrado e indexado na Web, ele não existe;
2. Se não estiver aberto e disponível em formato compreensível por máquina, ele não pode ser reaproveitado; e
3. Se algum dispositivo legal não permitir sua replicação, ele não é útil.

Em 2007, um grupo de 30 pessoas se reuniu na Califórnia, Estados Unidos, para definir os princípios dos dados abertos governamentais e chegou aos oito princípios que seguem (PORTAL BRASILEIRO DE DADOS ABERTOS, c2020).

1. **Completos:** devem ser disponibilizados e não podem ter controle de privacidade, acesso ou segurança; precisam ser abertos para que possam ser usados de qualquer forma.
2. **Primários:** devem ser publicados da maneira mais detalhada possível; não devem ser sumarizados ou agrupados.
3. **Atuais:** devem ser publicados o mais rápido possível para não perder o valor; com o passar do tempo, alguns precisam ser atualizados.
4. **Acessíveis:** devem ser disponibilizados para o maior público possível; por isso, normalmente, são publicados na internet.
5. **Processáveis por máquina:** devem ter uma estrutura que facilite o processamento por máquinas, já que, em alguns casos, agentes são responsáveis pelo seu processamento.
6. **Acesso não discriminatório:** devem estar disponíveis a qualquer pessoa, sem a necessidade de registro ou identificação, visto que são públicos.
7. **Formatos não proprietários:** devem ser disponibilizados em formatos não proprietários, como será visto mais adiante em relação à qualidade dos dados abertos.

8. **Licenças livres:** não devem estar sujeitos a regulamentações de direitos autorais, patentes ou marcas, já que os dados podem ser utilizados para diferentes fins.

Os dados abertos possuem níveis de qualidade representados por estrelas de 1 a 5. A seguir serão descritos esses níveis.

- **1 estrela:** disponibilizar os dados em qualquer formato digitalizado, como em formato PDF.
- **2 estrelas:** disponibilizar os dados de forma estruturada, como no formato XLS, em vez de em formato digitalizado.
- **3 estrelas:** tornar os dados disponíveis em formato não proprietário, como CSV.
- **4 estrelas:** utilizar URIs (Identificador Universal de Recurso) para denotar coisas, com o objetivo de que pessoas possam apontar para seus dados. Para esse nível, dados da previsão do tempo, por exemplo, são apresentados utilizando um vocabulário, a exemplo do Meteo, para representar a previsão do tempo.
- **5 estrelas:** vincular os dados disponibilizados com outros dados a fim de oferecer um contexto. Nesse nível, utiliza-se o vocabulário Meteo, como no nível 4, mas o da DBpedia para contextualizar as informações apresentadas de temperatura e Celsius.

A Figura 1 apresenta as qualificações das publicações dos dados abertos utilizando os níveis de estrelas.




Figura 1. Esquema de 5 estrelas para publicação de dados abertos.

Fonte: Adaptada de Isotani e Bittencourt (2020a).

O conjunto de dados 5 estrelas forma o que se chama de **web semântica**, o conjunto de ontologias conectadas e disponíveis na internet com licença aberta. A Figura 2 apresenta as diversas ontologias conectadas. Cada categoria de dados, como governo, linguística e redes sociais, tem uma cor conforme a legenda.




Figura 2. Diagrama em nuvem das ontologias conectadas.

Fonte: Adaptada de The Linked Open Data Cloud (2020).

Uma ontologia nada mais é do que um conjunto para modelar relações entre as entidades em um domínio de interesse. Um dos exemplos da utilização de ontologias é o do governo brasileiro em relação ao orçamento federal: foi criada uma ontologia para contemplar categorias e classificações com base no “Manual técnico do orçamento”.

Cada vez mais ouvimos falar na transparência na gestão pública, e esse é um dos motivos para que os dados sejam abertos. Além disso, podemos citar como razões: contribuição de serviço inovadores ao cidadão, melhoria na qualidade dos serviços oferecidos por órgãos governamentais, surgimentos de novos negócios e obrigatoriedade por lei.

Diferenças entre dados conectados e dados abertos

Diversos dados são publicados diariamente na *web* em diferentes repositórios espalhados pelo mundo, mas é necessário estabelecer padrões para sua conexão, a fim de facilitar a construção desse banco de dados global. O termo **conectado** se refere a um conjunto de boas práticas para publicação e conexão de dados utilizando padrão da W3C (World Wide Web Consortium) (LAUFER, 2015).

Para um dado ser considerado conectado, ele deve obedecer aos quatro princípios a seguir (ÁVILA, 2017).

1. Utilizar URIs para definir coisas.
2. Utilizar de HTTP URIs para que os dados possam ser encontrados tanto por pessoas quanto por agentes.
3. Ao ser solicitado um dado por HTTP URIs, devem ser fornecidas todas as informações sobre ele em um formato de dados estruturados utilizando padrões como RDF (Resource Description Framework) e SPARQL (Protocol and RDF Query Language).
4. Possuir *links* para outras fontes de dados relacionados (usando URIs), possibilitando que se obtenham mais informações.

Os dados conectados não necessariamente precisam ser abertos. Por exemplo, uma empresa privada pode conectar seus dados, mas não precisa deixá-los abertos.

Para entender melhor a *web* de dados, é importante lembrar que a *web* de documentos (atual) utiliza o padrão HTML para acessar os dados — ou seja, utiliza *hiperlinks* para navegar entre as páginas —, enquanto a *web* de dados utiliza o padrão RDF para acessar dados das diferentes fontes.

Observe na Figura 3 o diagrama da relação entre *web* semântica, dados conectados, RDF e os diversos tipos de dados estruturados. Os dados conectados possuem dados em formato RDFa (o objetivo é permitir a utilização desses elementos em qualquer documento XHTML) e em outros formatos RDF.




Figura 3. Diagrama da relação entre *web semântica*, dados conectados e RDF.

Fonte: Isotani e Bittencourt (2020b, documento *on-line*).

Segundo Isotani e Bittencourt (2020b), foram definidas boas práticas para a publicação de dados abertos, quais sejam:

- preparar os *stakeholders* — ensinar os usuários que vão criar e manter a base de dados conectada;
- definir que se pretende publicar dados e conectar a outros dados;
- definir como os dados serão representados e como eles se relacionam com outros dados, independentemente da aplicação;
- os responsáveis pelos dados devem definir o tipo de licença que deverá ser usada;
- definir uso de boas práticas para URIs;
- utilizar vocabulário padrão;
- converter os dados da fonte original para uma representação adequada de dados conectados;
- definir quais serão as formas de acesso aos dados por pessoas e máquinas;
- divulgar o novo conjunto de dados conectados;
- o responsável pela publicação dos dados deve mantê-los publicados ao longo do tempo.

O Linked Data API, também chamado de LD API, oferece uma forma fácil de acessar os dados conectados na *web*, permitindo que sejam apresentados URIs com aplicação de filtros se necessário. A LD API é uma camada intermediária que oferece uma API *web* para acessar os dados (LAUFER, 2015). A Figura 4 apresenta exemplos de URIs da LD API que permitem acesso aos dados do orçamento federal brasileiro.

```

/doc/{ano}/Acao
/doc/{ano}/Acao/{codigo}
/doc/{ano}/Atividade
/doc/{ano}/Atividade/{codigo}
/doc/{ano}/CategoriaEconomica
/doc/{ano}/CategoriaEconomica/{codigo}
/doc/{ano}/ElementoDespesa
/doc/{ano}/ElementoDespesa/{codigo}
/doc/{ano}/Esfera
/doc/{ano}/Esfera/{codigo}
/doc/{ano}/Exercicio
/doc/{ano}/Exercicio/{identificador}
/doc/{ano}/FonteRecursos
/doc/{ano}/FonteRecursos/{codigo}
/doc/{ano}/Funcao
/doc/{ano}/Funcao/{codigo}
/doc/{ano}/GrupoNatDespesa
/doc/{ano}/GrupoNatDespesa/{codigo}
/doc/{ano}/IdentificadorUso
/doc/{ano}/IdentificadorUso/{codigo}
/doc/{ano}/ItemDespesa
/doc/{ano}/ItemDespesa/{codigo}
/doc/{ano}/ModalidadeAplicacao
/doc/{ano}/ModalidadeAplicacao/{codigo}
/doc/{ano}/OperacaoEspecial
/doc/{ano}/OperacaoEspecial/{codigo}
/doc/{ano}/Orgao
/doc/{ano}/Orgao/{codigo}
/doc/{ano}/PlanoOrcamentario
/doc/{ano}/PlanoOrcamentario/{codigo}
/doc/{ano}/Programa
/doc/{ano}/Programa/{codigo}
/doc/{ano}/Projeto
/doc/{ano}/Projeto/{codigo}
/doc/{ano}/ResultadoPrimario
/doc/{ano}/ResultadoPrimario/{codigo}
/doc/{ano}/Subfuncao
/doc/{ano}/Subfuncao/{codigo}
/doc/{ano}/Subtitulo
/doc/{ano}/Subtitulo/{codigo}
/doc/{ano}/UnidadeOrcamentaria
/doc/{ano}/UnidadeOrcamentaria/{codigo}

```

Figura 4. Padrões de URIs da Linked Data API do orçamento federal.

Fonte: Laufer (2015, documento *on-line*).

Utilizando o exemplo da Figura 4, para uma possível utilização do URI da primeira linha (`/doc/{ano}/Acao`), pode-se fazer uma consulta substituindo o `{ano}` pelo valor do ano que se quer obter os dados do orçamento federal.

Utilização de dados conectados para desenvolvimento de sistemas

Um dos grandes desafios na utilização dos dados abertos e conectados é permitir que tais dados possam ser disponíveis de maneira legível tanto para usuários humanos quanto para máquinas. No caso de máquinas, é preciso ter o processamento automatizado sobre os dados e, para isso, a representação desses dados em formato XML, RDF e JSON. No caso de humanos, os dados são representados em formatos DOC, TXT ou PDF, porque facilitam seu consumo pessoal em tarefas diárias, havendo pouco interesse de utilização em soluções sistematizadas.

A maioria dos órgãos acaba disponibilizando os dados em formatos que atendem mais aos usuários humanos do que às máquinas. Um exemplo disso são os dados educacionais publicados, que, em sua maioria, atendem somente a um público específico, formado por pessoas que buscam informações de forma pessoal, que não têm a intenção de produzir novos serviços ou aplicações. Logo, as necessidades são atendidas por dados publicados em formato PDF, por exemplo, facilitando a consulta de seu conteúdo de forma manual.



Fique atento

Nem todos os formatos não estruturados são definidos como proprietários, a exemplo de TXT e ODT. Um formato proprietário não estruturado dificulta sua utilização por sistemas automatizados pelo uso, por exemplo, de APIs (Application Programming Interface), as quais ampliam a sua utilização.

Muitos órgãos, a exemplo dos governamentais no Brasil, não possuem uma integração de todos os sistemas e seus dados, o que dificulta sua publicação, evidenciando a falta de interoperabilidade e federalização de informações. Assim, as demandas geradas não podem ser ofertadas em tempo hábil. No entanto, existe uma forte tendência gradativa dessa integração, facilitando a distribuição dos dados abertos conectados, principalmente com a aprovação da Lei de Acesso à Informação (LAI), que fortalece o direito de qualquer cidadão a ter acesso aos dados. Um exemplo é o aplicativo móvel desenvolvido pelo governo de Alagoas, o Diário Alagoas, que disponibiliza informações do Diário Oficial. Para acessar, basta informar o CPF.

Como uma possível solução desse desafio, surgem ferramentas que flexibilizam a interface entre o provimento e a disponibilização dos dados em diversos formatos que atendam aos diferentes públicos, como mencionado no

tópico anterior, por meio de vocabulários RDF para descrevê-los, pois podem ser utilizados em serializações como RDF/XML e RDF/JSON.

Na busca por ferramentas já utilizadas para atribuir significado a documentos da *web*, as que aparecem com mais evidência são os *frameworks* gratuitos, como Jena e Sesame. O Jena utiliza linguagem Java e fornece um API para extrair dados e projetar gráficos RDF. O Sesame oferece um API para o usuário ter acesso a seus repositórios, além de uma interface HTTP que suporta o protocolo SPARQL.

As IDEs Semantic Java têm a finalidade de oferecer um ambiente de desenvolvimento utilizando recursos com a linguagem Java. O banco de dados AllegroGraph é um repositório de dados baseado em triplas RDF que utiliza uma eficiente combinação de armazenamento e desempenho. OWLIM é um sistema de gerenciamento de banco de dados RDF que, como extensão do Sesame, serve para organizar, armazenar e gerenciar conteúdo na forma de dados semânticos, obtendo alto desempenho em escalabilidade, balanceamento e carga. Permite também a exportação em planilhas (ISOTANI; BITTENCOURT, 2020b).



Fique atento

Para a publicação de dados conectados, as aplicações enriquecem suas bases de conhecimento com eficiência. O ideal é que sejam publicados permitindo a interoperabilidade de dados na *web* por meio de vocabulários RDF, facilitando a sua utilização por serviços automatizados para o consumo de dados.

Exemplos sobre dados conectados

Um dos grandes desafios da área educacional no Brasil é o uso de dados conectados a repositórios educacionais abertos. Um exemplo é a base de dados da OBMEP, disponível no *site* da Olimpíada Brasileira de Matemática das Escolas Públicas e do Instituto Nacional de estudos e Pesquisa Educacionais Anísio Teixeira (INEP), importantes fontes de pesquisas para investigar e melhorar o desempenho de alunos e escolas. Por não estarem integradas, é mais difícil gerar aplicações para visualizar os resultados dessas escolas e o desempenho dos seus respectivos alunos. Por serem disponíveis em formato de arquivos PDF e CSV, dificultam a interoperabilidade dos dados.

Segundo Alcantara *et al.* (2015), existem vários problemas relacionados ao uso de aplicações sobre dados abertos conectados, como os listados a seguir.

- Qualidade dos dados quando se manuseia com dados incorretos ou incompletos.
- Falta de controle sobre as fontes de dados, promovendo indisponibilidade.
- Dados sigilosos.
- Domínio de vocabulários, como necessidade de entendimento dos vocabulários disponíveis para o domínio dos dados.
- Custo de enriquecimento, considerando o custo inicial para enriquecimento e estabelecimento de conexões entre os dados educacionais de origem.
- Redundância sobre os mesmos dados em diferentes origens.
- Custo computacional, porque, dependendo do volume da base de conhecimento, o potencial de interatividade sobre dados conectados pode demandar um maior custo computacional para processamento e disponibilidade dos dados.

A utilização de dados abertos conectados implica o uso de vocabulários RDF e permite que os sistemas compartilhem um modelo de representação. Além disso, permite a utilização de identificadores únicos (URIs) para cada recurso, diminuindo a possibilidade de duplicação na base. Para facilitar a interoperabilidade de dados entre tais sistemas, é importante que eles sejam desenvolvidos seguindo a especificação de um sistema baseado em ontologias, o que possibilita enriquecimento semântico à base de conhecimento.

Um bom exemplo da aplicação de ontologias é o da Globo.com, que possui um grupo de profissionais da *web* semântica responsável por organizar e distribuir todo o conteúdo produzido pela Globo. Procura unir de maneira semântica as páginas, integrando as informações correlacionadas a um determinado assunto. Foi desenvolvido o conceito de **ontologia-base** com o desenvolvimento de um API aberto, chamado Brainiak, que implementa os conceitos de dados conectados, disponibilizando a interoperabilidade entre as notícias publicadas em diferentes portais da Globo, como G1, SportTV, Globo Esporte, entre outros.

A W3C promove o uso da interoperabilidade entre conjuntos de dados compartilhados mediante a adoção de licenças, vocabulários e padrões. Descreve o uso das melhores práticas para essa distribuição dos dados, oferecendo benefícios, como o reuso de dados publicados, a definição dos dados por meio de metadados para facilitar seu entendimento, a confiança, por manter

a origem dos dados por metadados de proveniência, e a processabilidade, por permitir que sistemas possam utilizar os dados uma vez convertidos em formatos abertos, como JSON, CSV, RDF, XML, entre outros.

Cenário atual sobre dados abertos e conectados

O uso de dados abertos ainda não é muito comum no Brasil, porque pouco se acredita no conhecimento que se pode obter com eles. Diante disso, os órgãos governamentais no Brasil devem fomentar ações para a implantação de dados abertos, e o mercado deve absorver as novas tecnologias e ferramentas para a sua automatização.

Uma aplicação para a utilizar dados abertos e conectados são as **cidades inteligentes**, que visam otimizar o uso de recursos para que possam servir melhor aos cidadãos. Desse modo, busca-se oferecer serviços e sistemas com monitoramento e controle em tempo real. Na área pública, setores da saúde, do transporte e da segurança podem usar tecnologias de informação e comunicação (TIC), permitindo que dispositivos inteligentes gerem um grande volume de informações e conhecimento com a coleta dos dados abertos e painéis de dados analíticos.

Os dados abertos e conectados, portanto, são uma tendência irreversível, gerando benefícios à sociedade, melhorando a transparência do governo, facilitando as pesquisas, tanto no âmbito acadêmico quanto no profissional, e permitindo a geração de novos negócios.

Referências

ALCANTARA, W. *et al.* Desafios no uso de dados abertos conectados na educação brasileira. In: WORKSHOP DE DESAFIOS DA COMPUTAÇÃO APLICADA À EDUCAÇÃO, 4., 2015, Recife. *Anais [...]*. Porto Alegre: Sociedade Brasileira de Computação, 2015. p. 11-20. Disponível em: <https://sol.sbc.org.br/index.php/desafie/article/view/10036>. Acesso em: 4 dez. 2020.

ÂVILA, T. *Dados conectados*. [S. l.]: OKBR, 2017. Disponível em: <https://www.ok.org.br/noticia/dados-conectados/>. Acesso em: 10 nov. 2020.

ISOTANI, S.; BITTENCOURT, I. I. Estruturação de dados e dados abertos conectados. In: ISOTANI, S.; BITTENCOURT, I. I. *Dados abertos conectados*. [S. l.]: Novatec, 2020a. cap. 2. Disponível em: <https://ceweb.br/livros/dados-abertos-conectados//capitulo-2/#sh2.1>. Acesso em: 10 nov. 2020.

ISOTANI, S.; BITTENCOURT, I. I. Visão holística: da produção ao consumo de dados abertos. In: ISOTANI, S.; BITTENCOURT, I. I. *Dados abertos conectados*. [S. l.]: Novatec, 2020b. cap. 1. Disponível em: <https://ceweb.br/livros/dados-abertos-conectados//capitulo-1/#sh1.2>. Acesso em: 10 nov. 2020.

LAUFER, C. *Guia de web semântica*. São Paulo: Governo do Estado, 2015. Disponível em: <https://ceweb.br/publicacao/guia-de-web-semantic/>. Acesso em: 13 nov. 2020.

PORTAL BRASILEIRO DE DADOS ABERTOS. *O que são dados abertos?* [S. l.]: Portal Brasileiro de Dados Abertos, c2020. Disponível em: <https://dados.gov.br/pagina/dados-abertos>. Acesso em: 9 nov. 2020.

THE LINKED Open Data Cloud. [S. l.]: LOD Cloud Diagram, 2020. Disponível em: <https://lod-cloud.net/>. Acesso em: 10 nov. 2020.

Leituras recomendadas

BRASIL. Tribunal de Contas da União. *Cinco motivos para a abertura de dados na administração pública*. Brasília, DF: TCU, 2015. Disponível em: <https://portal.tcu.gov.br/biblioteca-digital/cinco-motivos-para-a-abertura-de-dados-na-administracao-publica.htm>. Acesso em: 4 dez. 2020.

EAVES.CA. *About David*. [S. l.]: eaves.ca, 2020. Disponível em: <https://eaves.ca/about-david/>. Acesso em: 9 nov. 2020.

INEP. *Dados abertos*. Brasília, DF: Inep, c2020. Disponível em: <http://inep.gov.br/dados>. Acesso em: 13 nov. 2020.

OLIMPÍADA Brasileira de Matemática das Escolas Públicas. Rio de Janeiro: OBMEP, 2020. Disponível em: <http://www.obmep.org.br>. Acesso em: 14 nov. 2020.

PORTAL BRASILEIRO DE DADOS ABERTOS. *Maturidade em dados abertos: entenda as 5 estrelas*. [S. l.]: Portal Brasileiro de Dados Abertos, 2013. Disponível em: <https://dados.gov.br/noticia/maturidade-em-dados-abertos-entenda-as-5-estrelas>. Acesso em: 10 nov. 2020.



Fique atento

Os links para sites da web fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais links.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS