



INTRODUÇÃO A BIG DATA E INTERNET DAS COISAS (IOT)

Izabelly Soares de Moraes

Aprendizado de máquina (*Machine Learning*)

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir aprendizado de máquina.
- Descrever algoritmos de aprendizado de máquina.
- Listar aplicações de aprendizado de máquina.

Introdução

No aprendizado de máquina, temos uma junção entre recursos computacionais, inteligência artificial, dados, dentre outros elementos. Esses sistemas devem estar aptos não só a memorizar dados, mas também a observá-los e explorá-los para que suas habilidades evoluam por meio da prática e, conseqüentemente, da construção do conhecimento.

Neste capítulo, você aprenderá conceitos fundamentais sobre o aprendizado de máquina, assim como seus poderosos algoritmos e, por fim, conhecerá algumas aplicações do aprendizado de máquina.

Conceitos sobre aprendizado de máquina

O termo aprendizado engloba alguma experiência ou prática sobre algum assunto. Neste caso, especificamente, o aprendizado de máquina remete à inserção desse conceito em máquinas computacionais. Porém, sempre há um propósito e, aqui, veremos a relação do aprendizado de máquina com os dados.

Antigamente, adquiriríamos conhecimento por meio de livros, pesquisas, entrevistas, entre outros meios, e esses conhecimentos eram aplicados ao desenvolvimento de métricas voltadas ao uso dos recursos computacionais. Com o tempo, além dos recursos, as tecnologias foram sendo aplicadas a outras vertentes, e uma delas é a inteligência artificial.

Nós, seres humanos, temos a capacidade de raciocinar, ao contrário de uma máquina. Apesar de atualmente podermos contar com esses artefatos para quase tudo, eles ainda desempenham apenas funcionalidades pré-programadas. É aí que entra a inteligência artificial, a qual, como o nome já diz, proporciona o conhecimento a esses mecanismos por meio de dados.

Conforme Amaral (2016), aprendizado de máquina computacional (AM) é a aplicação de técnicas computacionais com o objetivo de encontrar padrões ocultos em dados. Segundo o autor, esses padrões ocultos são aquelas características que não podem ser observadas tão claramente nos dados. Assim, ainda sob a ótica de Amaral (2016), além de estar relacionado à inteligência artificial, o aprendizado de máquina está interligado, também, com a estatística e, consequentemente, com a mineração de dados. Por esse motivo, o autor ainda ressalta a diferença entre ambos os termos e suas respectivas aplicações: enquanto o aprendizado de máquina trata de algoritmos que buscam reconhecer padrões em dados, a mineração de dados é a aplicação desses algoritmos em grandes conjuntos de dados em busca de informação e conhecimento.

Em torno desse tema, ainda podemos mencionar *Big Data*, a qual lida com grande quantidade de dados — se não fosse por esses conceitos, o aprendizado de máquina não teria ativo suficiente. Para Coppin (2010), na maioria dos problemas de aprendizado, a tarefa é aprender a classificar entradas de acordo com um conjunto finito (ou, às vezes, infinito) de classificações. Tipicamente, um sistema de aprendizado é dotado de um conjunto de dados de treinamento que foram classificados manualmente. O sistema, então, tenta aprender, a partir desses dados de treinamento, a como classificar esses mesmos dados (geralmente, uma tarefa relativamente fácil) e também a como classificar novos dados ainda não observados.

De acordo com Carvalho et al. (2011, p. 113), os algoritmos de treinamento são formados por um conjunto de regras bem definidas que especificam quando e como deve ser alterado o valor de cada peso. É interessante ressaltar alguns conceitos, os quais são trazidos a seguir, no Quadro 1.

Quadro 1. Conceitos do aprendizado de máquina

Treinamento	O treinamento faz parte do aprendizado de máquina, já que é devido ao uso de algoritmos e à inserção de dados que a máquina adquire os conhecimentos necessários para desempenhar as funções para as quais foi designada.
Indução	O processo de indução traz a procura de uma melhor hipótese, ou seja, de uma melhor resposta ou solução para determinada situação.
Regras	Limitam as possibilidades do algoritmo de aprendizado de máquina.
Hipóteses	São possíveis conclusões, ou seja, possíveis respostas predeterminadas e que são provadas, ou não, ao final.

Deve haver a caracterização dos dados, em que esses são analisados para definir tipo, que determina se os atributos do objeto são quantitativos ou números, ou qualidade, de acordo com a qual podem ser chamados de qualitativos, simbólicos (que são facilmente compreendidos por nós, humanos) ou categóricos (quando os atributos possuem valores em um conjunto finito).

Além do tipo, escalas são definidas e caracterizam quais operações podem ser realizadas com os valores de cada atributo.

As escalas podem ser:

- Nominais (quando os valores apresentados possuem nomes diferentes e não trazem muitas informações), como, por exemplo, RG, CPF.
- Ordinais, que estão relacionados à ordem das categorias, como, por exemplo, temperatura, se está frio ou quente.
- Intervalares, que são números que podem variar dentro de um intervalo, como, por exemplo, a temperatura variar entre 10 a 15 graus em dias de inverno em uma mesma região.
- Racionais, que trazem mais informações sobre o atributo, como, por exemplo, a quantidade de vezes que um aluno cursou tal disciplina.



Saiba mais

Um exemplo de tipo de dado qualitativo é o indicativo de se ele é grande, pequeno ou médio. Além disso, eles ainda podem ser contínuos, quando seu número de valor é indefinido, e discretos, quando os valores são definidos.

A exploração dos dados pode contribuir na definição de métricas coerentes e com o aprendizado de máquina. Um dos conceitos mais utilizados para isso é a estatística descritiva, cujo objetivo é resumir de maneira quantitativa as características mais relevantes de um conjunto de dados.

Ainda sobre a exploração dos dados, temos os dados univariados, com os quais, em um conjunto de dados, o mesmo valor de um atributo pode surgir mais de uma vez, ou seja, podem repetir-se, por exemplo, caso haja dados de cadastro de pessoas, e, em algum momento, o nome da mesma pessoa pode surgir mais de uma vez, com os mesmos dados de peso ou idade. Eles podem ser de: medidas de localidade (pontos de referências, que podem ser numéricos ou simbólicos), medidas de espalhamento (permitem a observação em relação à concentração de um conjunto de valores em um só valor — as medidas mais comuns são intervalo, variância, desvio padrão, dentre outras), medidas de distribuição, que são definidas por meio da média de um conjunto de valores. Os dados também podem ser multivariados, que são os dados que possuem mais de um atributo de entrada.

Outro fator primordial é o pré-processamento de dados, que é importante tendo em vista que os dados podem surgir das mais variadas fontes e qualquer anomalia (como ruídos, imperfeições, dados incorretos, duplicados, dentre outros) pode afetar todo o conjunto de dados. Para evitar esse tipo de situação, existem algumas técnicas de processamento. Dentre as mais variadas técnicas, podemos mencionar:

- **Eliminação manual de atributos:** pode ocorrer quando alguns valores de atributos passam a ser irrelevantes para o contexto.
- **Integração de dados:** traz a necessidade da identificação dos objetos e de seus respectivos conjuntos. Cada conjunto de dados pode representar diferentes atributos de um mesmo grupo de objetos.
- **Amostragem de dados:** a amostragem pode ocorrer por meio de uma representação dos dados originais.
- **Dados desbalanceados:** é um fator observado quando o conjunto de dados apresenta valores irregulares. Para isso, pode-se utilizar artifi-

cios para balancear os dados, como redefinição de conjunto de dados, classificadores para diferentes classes, dentre outros.

- **Limpeza dos dados:** ocorre para evitar dados incompletos, inconsistentes, redundantes e com ruídos.
- **Transformação dos dados:** ocorrem conversões simbólico-numéricas, numérico-simbólicas e transformações de atributos numéricos.
- **Redução de dimensionalidade:** podem ocorrer devido a agregação, seleção de atributos, técnicas de ordenação e de seleção de subconjuntos.

No geral, podemos afirmar que existem alguns tipos de aprendizado de máquina, dentre os quais podemos citar:

- **Supervisionado:** traz um objetivo estabelecido e pode ser dividido entre problemas de regressão e de classificação.
- **Não supervisionado:** quando o objetivo não está bem definido e temos o intuito de compreender melhor os dados para realizar o agrupamento.
- **Por reforço:** quando as saídas não estão bem definidas e as respostas só podem ser aferidas após algumas execuções.

No próximo tópico, você verá como isso tudo pode ser desempenhado por uma máquina.

Algoritmos de aprendizado de máquina

O aprendizado pode ocorrer de diversas formas, já que tudo dependerá do algoritmo que será utilizado. Mas o que seria algoritmo? **Algoritmo** nada mais é do que o passo a passo da resolução de um problema; neste caso, resolvemos por meio das linguagens de programação, já que temos que nos comunicar com os componentes computacionais. Essas linguagens traduzem para o computador o que nós, humanos, queremos que ele desempenhe.

Para isso, precisamos seguir alguns passos primordiais, até porque a máquina irá adquirir o conhecimento conforme os dados e as métricas que foram programadas anteriormente. A diversidade entre os problemas que são tratados com o uso de recursos computacionais faz com que haja a geração de um grande volume de dados oriundos de diferentes setores. Consequentemente, as máquinas acabam tendo que acompanhar a demanda social. Na inteligência artificial e no aprendizado de máquina, deve ocorrer o desenvolvimento de

métricas, a partir das quais as máquinas devem ser capazes de criar hipóteses e, assim, resolvê-las.

Conforme Carvalho et al. (2011, p. 2), um exemplo simples é a descoberta de uma hipótese na forma de uma regra ou conjunto de regras para definir que clientes de um supermercado devem receber material de propaganda de um novo produto, utilizando, para isso, dados de compras passados dos clientes cadastrados na base de dados do supermercado. A esse processo de indução de uma hipótese (ou aproximação de função) a partir da experiência passada, dá-se o nome **aprendizado de máquina (AM)**. Ainda sob o ponto de vista dos autores, os algoritmos de AM aprendem a induzir uma função ou hipótese capaz de resolver um problema a partir de dados que representam instâncias do problema a ser resolvido. Esses dados formam um conjunto, simplesmente denominado **conjunto de dados**.

Uma hipótese pode ser compreendida como uma ideia inicial, uma suposição de algo, ou seja, você sugere algo, mas, posteriormente, terá que comprovar se sua ideia está, ou não, correta. Métricas, nesse contexto, representam metodologias, que serão seguidas para comprovar ou até mesmo desenvolver novas hipóteses.

Sobre a hipótese, dizemos que há uma indução. Como exemplo, podemos imaginar um conjunto de dados de estudantes de uma escola, em que cada aluno, ou seja, cada objeto, possuirá seus atributos. Nesse contexto, os atributos, que representam as características de um objeto, podem ser chamados também de variáveis. Como atributos, podemos citar nome, idade, sexo, ano escolar, dentre outros.

Um algoritmo de aprendizado de máquina aprende por meio dos dados, que são denominados conjunto de treinamento, ou seja, é um modelo ou hipótese que relaciona os valores dos atributos de entrada e o conjunto de treinamento ao valor de saída. Nem sempre os dados obtidos são regulares, ou seja, são livres de anomalias. Por isso, o objetivo do algoritmo é o de ser capaz de indicar uma hipótese, ou seja, uma possível solução correta diante de dados diversos, mas que podem ter algo em comum e que, claro, sejam relevantes para se atingir o objetivo esperado.

Os algoritmos podem utilizar formas de representações diversas para cada hipótese. Podemos destacar, aqui, alguns tipos, como redes neurais, árvores de decisão ou até mesmo vieses (Figura 1).




Figura 1. Diferentes vieses de representação.

Fonte: Carvalho et al. (2011, p. 5).

O viés é responsável pela restrição das hipóteses a serem visitadas no espaço de busca, ou seja, essa busca retrata a maneira com que o algoritmo procura pela melhor hipótese conforme seus dados de treinamento. Além do viés de busca, podemos citar, também, o viés de representação, como mostrado na Figura 1. O aprendizado requer algumas tarefas de aprendizado, as quais são: preditivas, que buscam antecipar, e descritivas, que buscam descrever um conjunto de dados.

A Figura 2, a seguir, mostra a hierarquia existente no aprendizado indutivo.




Figura 2. Hierarquia de aprendizado.

Fonte: Carvalho et al. (2011,p. 6)

No topo da Figura 2, vemos o aprendizado indutivo, processo pelo qual são realizadas as generalizações a partir dos dados. Tem-se, em seguida, os tipos de aprendizado supervisionado (preditivo) e não supervisionado (descritivo).

No **aprendizado supervisionado ou preditivo**, os métodos recebem como entrada dados rotulados e usam esses dados e seus atributos para determinar um novo conjunto de dados desconhecidos (CARVALHO et al., 2011; DIAS; PASCUTTI; SILVA, 2016). Os algoritmos do aprendizado supervisionado passam por uma etapa denominada treinamento, na qual o classificador vai aprender um determinado padrão de acordo com os dados utilizados para treinar o sistema (FERREIRA JÚNIOR, 2015). O aprendizado supervisionado resolve problemas de:

- **Regressão:** mapeiam um exemplo em um valor real. Um exemplo de regressão é prever o tempo de internação de um paciente em um hospital.
- **Classificação:** associa a descrição de um objeto a uma classe. Um exemplo de classificação é determinar a doença de um paciente pelos seus sintomas.

No **aprendizado não supervisionado ou descritivo**, agrupam-se objetos de acordo com suas características (FERREIRA JÚNIOR, 2015). Essa aprendizagem recebe dados do tipo $\{x_1, x_2, \dots, x_n\}$ e encontra associações entre esses dados (DIAS; PASCUTTI; SILVA, 2016). O aprendizado não supervisionado resolve problemas de (CARVALHO et al., 2011, p.6).

- **Agrupamento:** os dados são agrupados de acordo com sua similaridade.
- **Sumarização:** busca encontrar uma descrição simples e compacta para um conjunto de dados.
- **Associação:** consiste em encontrar padrões frequentes de associações entre os atributos de um conjunto de dados

Além dos aprendizados supervisionados e não supervisionados, existe o aprendizado semissupervisionado, que é utilizado quando os problemas possuem uma pequena quantidade de dados rotulados e os dados não rotulados são utilizados para constituir o conjunto de treinamento (DIAS; PASCUTTI; SILVA, 2016).

Vários algoritmos foram desenvolvidos para implementar os aprendizados supervisionado e não supervisionado. O Quadro 2, a seguir, apresenta alguns desses algoritmos (FERREIRA JÚNIOR, 2015; SILVA, 2016; DIAS; PASCUTTI; SILVA, 2016; CARVALHO et al., 2011).

Quadro 2. Algoritmos para aprendizado supervisionado e não supervisionado

Modelo	Tipo	Algoritmo	Características
Supervisionado	Regressão	Regressão linear	Recebe valores de determinadas variáveis e, por meio de equações, traz estimativas, as quais passam a ser aplicadas por outras variáveis.
	Classificação	Naïve Bayes	Busca calcular a probabilidade de algo após as variáveis terem sido caracterizadas anteriormente.
		Algoritmo máquina vetor de suporte	Constrói um modelo indicando onde o objeto se enquadra, utilizando um classificador e um analisador por regressão (linear binário não probabilístico).
		Regressão logística	Possibilita a definição de características semelhantes a determinados grupos de variáveis.
		Árvores de decisão	Realizam uma procura <i>top-down</i> nos dados calculando todas as árvores possíveis. Quando a árvore é muito complexa, seu tamanho é reduzido para que ela seja o mais generalista possível. Para classificar um elemento, a árvore é percorrida e, quando uma instância encontra a folha, a sua classe é a classe da folha correspondente.
		Redes neurais artificiais	É baseado no sistema de aprendizagem biológico, formado pela interligação dos neurônios. Assim como nos neurônios, o sistema conecta várias unidades simples, que recebem a informação de outros elementos (entradas) e enviam as informações processadas para outros elementos. Esses algoritmos aprendem exemplos e generalizam conceitos.
		K-Vizinhos mais próximos	A classificação de um item é realizada comparando as similaridades do item a ser classificado com os dados de treinamento.

(Continua)

(Continuação)

Quadro 2. Algoritmos para aprendizado supervisionado e não supervisionado

Modelo	Tipo	Algoritmo	Características
Não super- visionado	Agrupamento	K-Means	É um algoritmo particional, que divide os dados em grupos (<i>clusters</i>) não interseccionados, em que um objeto faz parte apenas de um grupo. O algoritmo encontra a melhor divisão de X dados em K grupos, agrupando os dados semelhantes. Cada grupo é representado pelo seu centro e cada dado é incluído no grupo que está mais próximo.
		Hierárquicos	A sequência de partições aninhadas são geradas baseadas em uma matriz de proximidade. O resultado desses algoritmos depende da ordem de entrada dos dados.
		Grafos	Algoritmos realizam o agrupamento utilizando grafos de proximidade.

Fonte: Adaptado de Ferreira Junior (2015), Silva (2016), Dias, Pascutti e Silva (2016) e Carvalho et al. (2011).

Aplicações do aprendizado de máquina

Assim como a diversidade dos algoritmos, existem diversos exemplos de aplicações do aprendizado de máquina, e um bem interessante é mencionado no Guia do Google (GOOGLE CLOUD, 2017), que relata que o objetivo da inteligência artificial (IA) vai além da simples automatização de tarefas que antes eram manuais.

No contexto do varejo on-line, por exemplo, os algoritmos de aprendizado de máquina são capazes de processar e analisar volumes imensos de dados de consumidores conforme os compradores em potencial navegam na loja on-line ou no aplicativo para dispositivos móveis de um varejista. Quanto mais dados o modelo processar, mais ele se aproxima de compreender quando e por que um comprador específico decidirá fazer uma determinada compra. Em algum momento, esse aprendizado se torna preditivo, permitindo que o varejista selecione o produto certo para uma determinada pessoa no

momento certo. Este nível de personalização, antes atingido por pequenos comerciantes de cidadezinhas que sabiam os nomes e idades dos filhos da cliente, agora se tornou algo possível em grande escala (GOOGLE CLOUD, 2017, documento on-line).

No entanto, esses conceitos não são aplicados apenas no mercado de negócios financeiros, mas também na área da agricultura, da saúde, dentre outras. A demanda social exige cada vez mais recursos naturais e, com o tempo, as companhias de energia buscam novas fontes e melhorias em seus processos, de modo que o aprendizado de máquina pode ser nesse contexto. Conforme Carvalho et al. (2011, p. 326), algoritmos de aprendizado de máquina têm sido utilizados em diversas aplicações, relacionados tanto a aspectos operacionais, como distribuição, exploração, geração de recursos energéticos, quanto a aspectos relacionados a planejamento e comercialização de energia. Nessas aplicações, os algoritmos têm sido utilizados principalmente em ferramentas de otimização e de suporte à tomada de decisão. Dentre as principais aplicações, podem ser listadas: previsão de carga, de preço; planejamento reativo, de expansão de sistemas de distribuição, de redistribuição de alimentadores, de agendamento de geradores, de minimização de perdas; controle da operação; proteção de sistemas de energia; composição de fontes energéticas; previsão de rompimento de dutos, dentre outros.

Na área da saúde estes algoritmos estão sendo utilizados para mapear características comuns a diversos contextos, como epidemias, por exemplo. Na prática, ocorre o armazenamento dos dados e algoritmos desempenham suas funções sob eles, determinando os dados relevantes para o processo, como idade, sexo, quantas vezes o paciente contraiu aquela doença, dentre outras informações. Ainda nesse universo, as ferramentas computacionais dão agilidade ao armazenamento de informações sobre os pacientes, sejam dados presentes ou antigos, que trazem um histórico e, às vezes, contribuem para a formação de alguns diagnósticos.

Outros exemplos são citados por Cortez e Morais (2007 apud CARVALHO et al., 2011, p. 324), que mostram como algoritmos de AM podem ser utilizados para a prevenção de incêndios florestais. Nesse trabalho, cinco algoritmos de AM tiveram sua acurácia preditiva comparada: algoritmo de indução de árvores de decisão, florestas aleatórias, máquinas de vetores de suporte, modelo de regressão múltipla e redes neurais. Os dados originais tinham atributos relacionados a coordenadas da área de incêndio, mês do ano, dia da semana, condições atmosféricas, temperatura, umidade relativa do ar, velocidade do vento e precipitação atmosférica. Técnicas de transformação converteram atributos qualitativos em quantitativos, e técnicas de seleção foram utilizadas para selecionar os atributos mais relevantes. Os melhores resultados foram obtidos por máquinas de vetores de suporte com quatro

atributos, dados meteorológicos relacionados a temperatura, umidade relativa do ar, precipitação pluviométricas e velocidade do vento.

Cada algoritmo agirá diante das necessidades apresentadas por cada situação. Dessa forma, eles podem ser desenvolvidos com o intuito de solucionar problemas demonstrados pelos negócios das empresas.



Fique atento

Enquanto a mineração de dados traz métricas sobre a extração das informações diante de um conjunto de dados, o aprendizado de máquina constrói e aplica estudos nos sistemas para que possa adquirir conhecimentos com os dados.



Referências

AMARAL, F. *Introdução à ciência de dados: mineração de dados e big data*. Rio de Janeiro: Alta Books, 2016.

CARVALHO, A. C. P. L. F. et al. *Inteligência artificial: uma abordagem de aprendizagem de máquina*. Rio de Janeiro: LTC, 2011.

COPPIN, B. *Inteligência artificial*. Rio de Janeiro: LTC, 2010.

DIAS, M. F. R.; PASCUTTI, P. G.; SILVA, M. L. Aprendizado de máquina e suas aplicações em bioinformática. *Revista Semioses*, v. 10, n. 1, 2016. Disponível em: <<http://apl.unisuam.edu.br/revistas/index.php/Semioses/article/view/1070>>. Acesso em: 17 jan. 2019.

FERREIRA JÚNIOR, M. M. *Modelos computacionais baseados em aprendizado de máquina para classificação e agrupamento de variedade de tucumã*. 2015. 142 f. Dissertação (Mestrado em Ciência e Tecnologia para Recursos Amazônicos) - Universidade Federal do Amazonas, Itacoatiara, 2015. Disponível em: <<https://tede.ufam.edu.br/handle/tede/4739>>. Acesso em: 17 jan. 2019.

GOOGLE CLOUD. *Guia sobre análise de dados e aprendizado de máquina para CIO*. 2017. Disponível em: <https://lp.google-mkto.com/rs/248-TPC-286/images/Guide_to_Data_Analytics_%26_Machine_Learning_portuguese.pdf>. Acesso em: 17 jan. 2019.

SILVA, M. C. R. *Aprendizagem de máquina em apoio ao diagnóstico em ortopedia*. 2016. 132 f. Dissertação (Mestrado em Engenharia Elétrica) - Pontifícia Universidade Católica de Campinas, Campinas, 2016. Disponível em: <<http://tede.bibliotecadigital.puc-campinas.edu.br:8080/jspui/handle/tede/902>>. Acesso em: 17 jan. 2019.

Leituras recomendadas

MITCHELL, T.M. *Machine learning*. New York: McGraw-Hill, 1997.

ROSA, J. L. G. *Fundamentos da inteligência artificial*. Rio de Janeiro: LTC, 2011.

SOUTO, M. C. P. et al. *Técnicas de aprendizado de máquina para problemas de biologia molecular*. In: CONGRESSO DA SOCIEDADE BRASILEIRA DE COMPUTAÇÃO, 23., 2003, Campinas. Anais... Porto Alegre: SBC, 2003. Disponível em: <<http://www.cin.ufpe.br/~mcps/ENIA2003/jaia2003-14-08.pdf>>. Acesso em: 17 jan. 2019.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS