


PROCESSAMENTO DE LINGUAGEM NATURAL

Michel Bernardo Fernandes da Silva



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Classificação de textos — introdução ao aprendizado supervisionado

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir a área de *machine learning*.
- Descrever exemplos de aplicações de *machine learning* para classificação de textos.
- Identificar os elementos que compõem as soluções de classificação de textos.

Introdução

Neste capítulo, você aprenderá os conceitos de *machine learning* (ou “aprendizado de máquina”) e seus diferentes tipos, além de exemplos de suas aplicações na classificação de textos analisando a finalidade e a área de aplicação, como empresas comerciais, instâncias governamentais e as áreas de Direito, Ciências Sociais e Medicina. Por fim, identificará os elementos que fazem parte desse tipo de técnica e as etapas para a realização da classificação de textos.

1 Definição de *machine learning*

A implementação de técnicas de aprendizado automático se tornou uma das áreas de interesse de pesquisa em inteligência artificial (IA) ou, em inglês, *artificial intelligence* (AI), diante da capacidade de aprender com experiências ter passado a ser um elemento fundamental para a evolução das espécies de seres vivos e que poderia ser implementada em máquinas. Uma premissa fundamental desse ramo IA reside no fato de que os sistemas podem aprender com dados, identificar padrões e tomar decisões com mínima interferência

humana, utilizando as percepções tanto para agir quanto para melhorar a habilidade de agir do agente no futuro.

De acordo com o SAS Institute (2019), empresa de *software* líder no mercado de Analytics, pode-se definir o aprendizado de máquina ou *machine learning* como um método de análise de dados que possibilita criar modelos analíticos automaticamente.

Contudo, inicialmente, é preciso diferenciar o conceito de IA e o de aprendizado de máquina: de acordo com Russell e Norvig (2013, p. 5), “Inteligência Artificial pode ser definida como estudo de agentes que recebem percepções do ambiente e executam ações e cada agente implementa uma função que mapeia sequências de percepções em ações. Por sua vez, o *machine learning* é uma vertente específica da IA que treina máquinas para aprender com dados”.

Assim, aplicações de *machine learning* são projetadas para aprender e melhorar ao longo do tempo, quando expostas a novos dados, como no caso dos sistemas de reconhecimento de voz, tradutores de textos, detecção de fraudes e veículos autônomos de diversos fabricantes, os últimos com capacidade de dirigir sem auxílio do motorista e que estão em testes principalmente nos Estados Unidos. Outras aplicações são anúncios em tempo real em páginas Web e dispositivos móveis, algoritmos que identificam quem é a pessoa que está em uma foto postada no Facebook, além da previsão de falhas em equipamentos, novos modelos de precificação, previsão de falhas em equipamentos, filtragem de *spams* no *e-mail*, etc.

Segundo Russell e Norvig (2013), o projeto de um elemento de aprendizagem é influenciado por três questões importantes:

1. os componentes do elemento de desempenho que devem ser aprendidos;
2. a representação a ser utilizada para os componentes;
3. a realimentação a ser disponibilizada para aprender esses componentes.



Link

Na página do *site* do SAS Institute, uma das empresas líderes no mercado de Analytics, é possível verificar do que se trata o *machine learning* e qual é a sua importância, detalhando-o com exemplos de aplicação, acesso a relatórios, diferenças entre *machine learning* e inteligência artificial e mineração de dados.

<https://qr.go.page.link/ZjMmV>

Classificações de aprendizado de máquina

O aprendizado de máquina tem diferentes classificações, sendo a mais frequente aquela que o divide em aprendizado supervisionado, não supervisionado e por reforço. No caso do aprendizado supervisionado (*supervised learning*), existe um conjunto pré-definido de pares de dados entradas/saídas, em que as entradas são compostas por diversos atributos relativos aos objetos que se deseja reconhecer, como padrões e tendências. Há um treinamento com base nos dados pré-definidos, e o programa precisa tomar decisões precisas quando recebe novos dados. Por exemplo, é possível utilizar uma série de dados de recursos humanos com *posts* no Facebook ou *tweets* no Twitter marcados como positivos, neutros e negativos visando à criação de um classificador de análise de sentimento.

Já na aprendizagem não supervisionada (*unsupervised learning*), o programa busca encontrar padrões e relações em um conjunto de dados, sendo informados somente os dados de entrada, já que os padrões de saída são aprendidos pelo próprio sistema de aprendizado. Por exemplo, uma análise de conjunto de *e-mails* recebido por um funcionário que deseja realizar um agrupamento automático desses *e-mails* relacionado a temas semelhantes, sem que o programa tenha obtido conhecimento prévio sobre os dados de entrada.

Em geral, um sistema de aprendizado dispõe de um conjunto de dados de treinamento classificados manualmente, com base nos quais o sistema buscará aprender, a partir dos dados de treinamento, como classificar esses dados e como classificar novos dados ainda não observados.


Por fim, na aprendizagem por reforço (*reinforcement learning*), o agente de aprendizagem adquire conhecimento sobre seu processo a partir do reforço ou da recompensa. Por exemplo, uma multa de trânsito indica para o agente que seu comportamento foi inadequado. Dessa forma, a aprendizagem por reforço também contempla o subproblema de entender como o ambiente funciona.

Existem técnicas de aprendizado para cada uma das classificações de aprendizado. No aprendizado supervisionado, há as redes neurais artificiais com treinamento supervisionado, árvores de decisão, etc.

A técnica de árvore de decisão (*decision tree*) utiliza um gráfico de árvore ou modelo de decisões e suas consequências, além de representar visualmente um algoritmo, deixando claro as consequências de cada decisão.

Uma árvore de decisão chega à sua decisão por meio da execução de uma sequência de testes. Cada nó interno na árvore equivale a um teste do valor de um dos atributos de entrada, A_i , e as ramificações dos nós são classificadas com os valores possíveis do atributo, $A_i = v_{ik}$. Cada nó de folha na árvore especifica o valor a ser retornado pela função. Tal representação parece ser muito desejada para os seres humanos e diversos manuais do tipo “como fazer” são escritos basicamente como uma única árvore de decisão que pode se estender por centenas de páginas.

Na Figura 1, é apresentada uma árvore de decisão com os critérios de escolha da decisão de esperar ou não de uma mesa em um restaurante (RUSSELL; NORVIG, 2013, p. 812). Nesse caso, o objetivo é aprender uma função para o predicado objetivo *VaiEsperar*. Os exemplos são processados pela árvore a partir da raiz e seguem a ramificação apropriada até alcançar uma folha. Por exemplo, uma situação com *Clientes* = Cheio e *EsperaEstimada* = 0-10 será classificada como positiva, isto é, *esperaremos por uma mesa*.



Outro tipo de aprendizagem refere-se à aprendizagem profunda (*deep learning*), uma categoria de algoritmos de *machine learning* que utiliza redes neurais artificiais para a geração de modelos. Essa técnica foi bem-sucedida na resolução de problemas de reconhecimento de imagem. As redes neurais artificiais são inspiradas nas redes neurais biológicas e compreendem uma rede de nós interconectados que compõem um modelo, utilizadas, de maneira geral, quando de um volume de entrada muito grande, o que torna abordagens convencionais não apropriadas.

Segundo Baranauskas e Monard (2000), um programa de aprendizagem ou *inducer* tem como objetivo a geração de um bom classificador para um conjunto de instâncias já classificadas. O classificador pode ser utilizado para classificar instâncias não rotuladas com a finalidade de prever corretamente o rótulo de cada instância ainda não classificada.

Pode-se definir um atributo ou uma *feature* como a descrição ou característica de um aspecto da instância. Os atributos podem ser divididos em atributo nominal (p. ex., cor e país de nascimento) ou contínuo (p. ex., altura e peso, passíveis de representar por números reais). Já os *features* são utilizados como preditores de variáveis ou variáveis independentes, compreendendo colunas na base de dados.

Uma instância é uma lista fixa de valores de atributos e descreve a entidade sobre a qual estamos lidando, por exemplo, dados médicos sobre uma doença.

Uma classe ou um rótulo corresponde a uma característica especial em aprendizado supervisionado que descreve o fenômeno de interesse, a tarefa de aprendizado e a realização de predições com base nele.

Um conjunto de dados ou *dataset* é uma coleção de instâncias classificadas, isto é, rotuladas. Normalmente, os valores de uma classe de rótulos podem ter um conjunto discreto de classes, no caso de uma classificação, ou valores reais, quando de uma regressão.

Dado um conjunto de instâncias de treino, o programa de aprendizagem gera um classificador que, a partir de uma nova instância, poderá prever com precisão o rótulo dessa nova instância.

2 Aplicações de *machine learning* para classificação de textos

O uso do conhecimento da linguagem é o que distingue aplicações de processamento de linguagem de outros sistemas de processamento de dados. As tentativas iniciais de traduzir de uma língua para outra computacionalmente não obtiveram resultados satisfatórios, tornando-se alvo de muitas críticas em relação à inutilidade da tradução automática. Um projeto da Agência Central de Inteligência (CIA) dos Estados Unidos investiu milhões de dólares no desenvolvimento de um *software* capaz de traduzir do russo para o inglês.



Saiba mais

Um mito existente em relação à tradução automática remonta à década de 1950, período no qual se deram os primeiros sistemas de tradução do russo para o inglês. Para testar o sistema, colocou-se uma frase em inglês que foi traduzida para o russo e, posteriormente, essa frase em russo se traduzia para o inglês. A entrada era o texto *The spirit is willing, but the flesh is weak*, isto é, “o espírito está pronto, mas a carne é fraca”, uma parte do verso São Mateus 26:41. Contudo, a saída do programa foi *The vodka is good, but the meat is rotten*: “a vodka é boa, mas a carne está estragada”.

As primeiras técnicas de classificação de texto foram utilizadas majoritariamente para sistemas de recuperação da informação. Com o avanço tecnológico, os problemas de classificação de texto foram amplamente estudados e abordados em muitas aplicações reais, principalmente com as mudanças recentes no processamento de linguagem natural (PLN, ou *natural language processing* [NLP]) e na mineração de texto. Com isso, diversos pesquisadores desejam desenvolver aplicativos que utilizem métodos de classificação de texto em áreas como Medicina, Ciências Sociais, Psicologia, Engenharia e Direito.

A maioria das tarefas de PLN em que se tem aplicado o aprendizado de máquina refere-se àquelas que podem ser tratadas como problemas de classificação, nas quais se objetiva associar a cada palavra de um texto uma etiqueta que indique a sua classificação. O aprendizado normalmente é induzido por um *corpus* de treino que contém exemplos corretamente classificados.

O conhecimento adquirido pelo aprendizado normalmente é representado por um conjunto de probabilidades contextuais ou por um conjunto de regras de transformações, passíveis de utilização para a classificação de novos textos.

A recuperação de informações busca localizar dados em documentos não estruturados que atendem a uma necessidade de informação dentro de numerosas coleções de documentos. Com o rápido crescimento da informação *on-line*, particularmente no formato de texto, a classificação de texto se tornou uma técnica significativa para gerenciar esse tipo de dado. Por exemplo, o Google provê uma recuperação de informação e serviços de tradução entre idiomas nos quais um usuário pode realizar uma consulta em sua língua nativa para pesquisar coleções de dados em outros idiomas. O Google traduz a consulta, encontra as páginas mais relevantes e as traduz automaticamente para a língua nativa do usuário (JURAFSKY; MARTIN, [2020]). O processo de recuperação da informação baseia-se em técnicas e recursos com dados para criar estruturas de índices, além de organizar e recuperar as informações com eficiência.

Uma de suas aplicações frequentes por empresas de diversos são os *chatbots*, programas ou robôs utilizados em *chats* de *sites*, mídias sociais para realizar o atendimento de clientes como se fossem atendentes reais. Esses robôs respondem a perguntas, repassam orientações, indicam soluções e uma série de outras ações com base em informações constantes em seus bancos de dados (RODRIGUES, 2017), podendo se basear em IA e utilizar o PLN. Inicialmente, é necessário determinar em que contexto o *chatbot* operará, o que fará parte da etapa de treino, como já mencionado. Quanto maior a abrangência, mais demorado e complexo será o desenvolvimento. Para seu funcionamento, ele precisa ser carregado de intenções e ser integrado a bases de dados que contenham as informações de que eles precisam para responder aos usuários.

Um *chatbot* fundamentado em PLN buscará a resposta mais coerente a partir da interpretação da mensagem do usuário, tal qual uma conversa, e não seguirá um fluxo-padrão, pois um usuário poderá fazer uma pergunta que exigirá que o *bot* solicite uma nova informação para continuar e outro pode entrar e já fornecer toda a informação necessária, quebrando a ordenação de um *script* pré-definido.

Já a filtragem de informações se refere à seleção da informação relevante e à retirada de informações irrelevantes a partir de um fluxo de dados recebidos. Uma aplicação prática dessa filtragem de informações é identificar *e-mails* indesejados ou *spam*.



Link

Outra aplicação relevante da filtragem de informações é uma ferramenta utilizada como detector de *fake news*, que processará o texto para identificar características de escrita, como palavras usadas ou classes gramaticais mais frequentes, e utilizá-las em um modelo de aprendizado de máquina que classificará a notícia em verdadeira ou falsa. O texto deve ter pelo menos 100 palavras, pois o sistema foi “treinado” para essa característica.

<https://qrgo.page.link/Lseha>

Com o crescimento acelerado de mídias sociais, os usuários podem expressar suas ideias e opiniões por fóruns, *tweets*, *sites* para avaliação de produtos, vídeos, *posts*, o que levou à realização da mineração de opiniões ou análise de sentimentos (*sentiment analysis*) que busca identificar o conteúdo de opinião e determinar o sentimento, a atitude ou as percepções dos usuários de internet em relação a um produto, serviço, marca ou assunto previamente definido. Normalmente, a classificação da opinião é polarizada em positivo, negativo e neutro.

Já os sistemas de recomendação sugerem itens aos usuários com base no perfil de interesse do usuário e na descrição de um item. O perfil do usuário pode ser aprendido por meio de *feedback* dos usuários, por consulta de resultados de pesquisas ou relatório próprios, itens e recursos autoexplicados (filtro ou condições nas consultas) no perfil de uma pessoa. Quando acessamos uma página do serviço de *streaming* por assinatura, o *site* oferece recomendações personalizadas para nos ajudar a encontrar vídeos do nosso interesse. Isso é realizado com base em um sistema de recomendações a partir do que nós assistimos e da nota que demos a outros títulos, do que pessoas com mesmos interesses assistiram, da informação do filme (p. ex., gênero, ano de lançamento, atores), do horário e tempo em que assistimos, e da plataforma de acesso ao *site*.

Outra aplicação consiste na sumarização de documentos, utilizada para resumir os documentos, podendo empregar palavras e frases inexistentes no documento original, como ao determinar os assuntos de um *e-mail* com base no seu conteúdo.

Empresas comerciais e organizações estão progressivamente utilizando mídias sociais para *marketing* — com a mineração de opiniões de mídias sociais como Facebook, Twitter, Reclame Aqui, etc., as empresas obtêm insumos relevantes para aumentar rapidamente suas vendas e lucros. A classificação de textos e documentos representa uma ferramenta poderosa para buscar seus clientes mais facilmente.

Já existem diversas ferramentas de monitoramento de mídias sociais que analisam em tempo real a quantidade de postagens e o sentimento para o objeto monitorado, além de poder ser empregada em instâncias governamentais.



Exemplo

Um exemplo de aplicação da análise de sentimento é mostrado a seguir, em que se avaliaram *tweets* relacionados aos programas do Governo Federal, como Bolsa Família, Minha Casa, Minha Vida, Mais Médicos e Programa Nacional de Acesso ao Ensino Técnico em Emprego (Pronatec).




Figura 2. (a) Exemplos de *tweets* classificados por polaridade. (b) Análise de sentimento por programa.

Fonte: Oliveira et al. (2019, p. 245–246).

Aplicações de classificação de textos nas ciências sociais

Nas últimas décadas, a classificação de textos e categorização de documento é aplicada para entender o comportamento humano, com enfoque na mineração da linguagem contida em notas informais e no conjunto de textos como mensagens SMS e de WhatsApp, além de mídias sociais. Esses estudos enfatizam abordagens quanto à frequência de ocorrência de uma palavra, isto é, com que frequência uma palavra aparece no documento, ou uma característica baseada no dicionário *linguistic inquiry word count* (LIWC).

Aplicações de classificação de textos nas áreas da saúde


A maior parte das informações textuais no domínio da área médica é obtida de forma desestruturada ou por uma narrativa com termos ambíguos e erros de ortografia e gramaticais, já que precisam ser disponibilizadas instantaneamente pelas consultas entre médicos e pacientes em diferentes estágios de diagnóstico e tratamento.

Os códigos utilizados na medicina, como a Classificação Internacional de Doenças (CID), consistem em atribuir os diagnósticos médicos a classes de valores específicos de um numeroso conjunto de categorias. Tal codificação é uma área de aplicação de saúde em que técnicas de classificação de texto podem ser extremamente valiosas.

A classificação de texto também é aplicada no desenvolvimento da Medical Subject Headings (MeSH), uma enorme lista da National Library of Medicine que contém palavras-chave ou tópicos que se aplicam a quaisquer conceitos médicos ou biomédicos, atualizados anualmente. Outra área de aplicação refere-se à ontologia genética ou *gene ontology* (GO), um dos principais temas da bioinformática, que trata da unificação da representação do gene e do produto do gene, ou seja, atributos em todas as espécies.

3 Elementos que compõem as soluções de classificação de textos

Segundo Kowsari *et al.* (2019), a maioria dos sistemas de classificação de texto e categorização de documentos pode ser decomposta em quatro fases: extração de recursos, reduções de dimensão, classificador seleção e avaliações. Uma visão geral da estrutura e da implementação técnicas de sistemas de classificação de texto se dá em termos do *pipeline*, a sequência de operação ou linha de montagem mostrada na Figura 3.




Inicialmente, um conjunto de dados de texto bruto consiste na entrada de dados no *pipeline*. Em geral, os conjuntos de dados de texto contêm sequências de texto em documentos como $D = \{X_1, X_2, \dots, X_N\}$, onde X_i se refere a um fração de dados, ou seja, documento, ou segmento de texto, com o número s de sentenças, de modo que cada sentença inclua palavras w_s com letras l_w . Cada ponto é rotulado com um valor de classe de um conjunto de k diferentes índices de valores discretos (Figura 4).

Em seguida, é criado um conjunto estruturado focado nos propósitos de treinamento, etapa denominada extração de recursos, que se referem, normalmente, aos textos e documentos representados por conjuntos de dados desestruturados. Entretanto, as sequências de texto desestruturadas devem ser convertidas em um espaço de características estruturadas quando se utiliza a modelagem matemática, como de um classificador. Inicialmente, os dados necessitam passar por um tratamento, a fim de omitir caracteres e palavras desnecessários.

Como um conjunto de textos ou documentos contém muitas palavras únicas, as etapas de pré-processamento de dados podem se atrasar em razão do tempo elevado para processamento e utilização de memória. Esses fatos justificam a etapa de redução de dimensões, uma parte opcional do *pipeline* que pode fazer parte do sistema de classificação.


O passo mais significativo na categorização consiste na escolha do melhor algoritmo de classificação. Sem a compreensão conceitual de cada algoritmo, a escolha do algoritmo mais eficiente pode não ser eficiente. Existem diversos algoritmos como os classificadores Naive Bayes, Rocchio e Ensemble do tipo Bagging, além do Boosting, de regressão logística.

Uma das formas clássicas para gerar uma superfície de decisão se dá pelo uso de um hiperplano de separação, que pode ser ou não perpendicular ao eixo.



Entretanto, dependendo do conjunto de dados, as classes podem ser separadas por uma forma não geométrica, casos em que se pode aplicar o algoritmo do k -ésimo vizinho mais próximo ou *K-Nearest Neighbors algorithm* (KNN).

Nessa abordagem, define-se um número de vizinhos (k) a serem utilizados para a classificação, com a classe que estiver mais presente entre os k vizinhos mais próximos de um novo exemplo. No caso da Figura 5, o ponto x_i definirá o rótulo deste.



Saiba mais

O algoritmo Naive Bayes é um classificador probabilístico muito utilizado em *machine learning*. Baseado no teorema de Bayes, desenvolvido pelo inglês Thomas Bayes (1702–1761), ele desconsidera a correlação entre as variáveis.

Outra parte do *pipeline* consiste na etapa de avaliação, que se divide em duas partes: a previsão do conjunto de teste e a avaliação do modelo. É fundamental entender como ocorre o desempenho do modelo para utilizar e desenvolver métodos de classificação de texto.

Geralmente, sistemas de classificação de texto contêm quatro níveis de escopo: nível de documento, em que o algoritmo obtém categoriais relevantes para o documento completo; nível de parágrafo, em que as classificações relevantes ocorrem para um único parágrafo ou uma parte do documento; nível da sentença, na qual são analisadas as categorias de sentença únicas ou parte de um parágrafo; e nível de frase, em que o algoritmo obtém categoriais relevantes de frases dentro de uma sentença.

Um conceito importante nesse contexto são as expressões regulares ou *regular expressions* (RE), a notação padronizada para caracterização de cadeias de caracteres ou *strings*, utilizada em qualquer sequência de caracteres alfanuméricos (letras, números, espaços, pontuações ou tabulações). O espaço é considerado um caractere como qualquer outro e representado pelo símbolo `\`.

As expressões regulares de pesquisa necessitam de um padrão que desejamos para pesquisar e de um *corpus*, isto é, um conjunto de textos escritos e registros orais em determinada língua que servirá como base para pesquisa e análise.

Um autômato de estados finitos representa uma estrutura matemática utilizada para implementar expressões regulares, sendo uma das mais significativas ferramentas da linguística computacional.

Pré-processamento e limpeza do texto

A maioria dos conjuntos de dados contém muitas palavras desnecessárias, como interrupções, erros ortográficos e gírias. Em muitos algoritmos, especialmente os de aprendizado estatístico e probabilístico, o ruído e as características desnecessárias podem ter efeitos adversos no desempenho do sistema. Por essa razão, existem técnicas e métodos para limpeza do texto e pré-processamento de conjunto de dados de texto (JURAFSKY; MARTIN, [2020]).



Fique atento

A tokenização é um método de pré-processamento que quebra fluxos de texto em palavras, frase, símbolo ou outros elementos significativos chamados *tokens*. Seu objetivo principal é investigar palavras em uma sentença. Tanto a classificação de texto quanto a mineração de textos compreendem analisadores que processam a tokenização de documentos.

Vamos aplicar a tokenização à seguinte frase:

“Depois de ir ao parque, ela decidiu fazer compras no mercado.”


Nesse caso, os *tokens* seriam:

{“Depois” “de” “ir” “ao” “parque” “ela” “decidiu” “fazer” “compras” “no” “mercado”}

A classificação de texto e documento inclui muitas palavras que não contêm informações importantes para serem usados em algoritmos de classificação, como {"um/uma", "sobre", "acima", "através", "depois", "novamente", "para"...}. A técnica mais comum para lidar com essas palavras consiste em removê-las dos textos e documentos, resultando em um conjunto com todas as palavras significativas para interpretação do texto.

Os textos e documentos contêm também caracteres desnecessários, como pontuação e caracteres especiais, importantes para sua compreensão, embora possam atrapalhar o algoritmo de classificação.

Outro ponto relevante refere-se às letras maiúsculas e minúsculas em uma frase, já que, dado que os documentos consistem em diversas sentenças, essa variação pode ser muito problemática quando da classificação de documentos extensos. Uma abordagem comum para essa questão consiste em transformar todas as letras em minúsculas, ainda que possa causar problemas significativos na interpretação de algumas palavras — por exemplo, o pronome “ti” e a sigla “TI”, para Tecnologia de Informação, terão a mesma representação. Na Figura 6, há uma representação do processamento básico de um texto.



Uma etapa opcional do pré-processamento corresponde aos erros de digitação ou *typos*, na forma reduzida em inglês, muito frequentes em textos e documentos, especialmente em conjuntos de textos de mídia sociais, como o Twitter e o Facebook. Muitos algoritmos, técnicas e métodos abordam esses problemas no PNL.



Referências

BARANAUSKAS, J. A.; MONARD, M. C. *Reviewing some Machine Learning Concepts and Methods*. São Carlos: ICMC-USP, 2000. 52 p. (Relatórios Técnicos do ICMC-USP, 102).

JURAFSKY, D. S.; MARTIN, J. H. *Speech and language processing*. 3. ed. Upper Saddle River: Prentice Hall, [2020]. No prelo. Disponível em: <https://web.stanford.edu/~jurfasky/slp3/>. Acesso em: 14 mar. 2020.

KOWSARI, K. *et al.* Text Classification Algorithms: A Survey. *Information*, [S. l.], v. 10, n. 150, p. 1–68, 2019. Disponível em: <https://arxiv.org/abs/1904.08067>. Acesso em: 14 mar. 2020.

OLIVEIRA, D. J. S. *et al.* A aplicação da técnica de análise de sentimento em mídias sociais como instrumento para as práticas da gestão social em nível governamental. *Revista de Administração Pública*, Rio de Janeiro, v. 53, n. 1, p. 235–251, jan./fev. 2019. Disponível em: http://www.scielo.br/scielo.php?script=sci_abstract&pid=S0034-76122019000100235&lng=pt&nrm=iso&tlng=pt. Acesso em: 14 mar. 2020.

RODRIGUES, N. Ebook: Guia sobre Chatbots – Seu negócio ainda vai ter um. *Cedro Technologies*, Uberlândia; Patos de Minas; São Paulo, 21 jul. 2017. Disponível em: <https://blog.cedrotech.com/ebook-guia-sobre-chatbots-para-sua-empresa/>. Acesso em: 14 mar. 2020.

RUSSELL, S.; NORVIG, P. *Inteligência artificial*. 3. ed. Rio de Janeiro: Elsevier, 2013. 1056 p.

SAS INSTITUTE. Machine Learning: O que é e qual sua importância. *SAS Institute*, Cary, 8 mar. 2019. Disponível em: https://www.sas.com/pt_br/insights/analytics/machine-learning.html. Acesso em: 14 mar. 2020.

TRAVIZAN NETO, A. *Classificação de traços de personalidade através de Linguagem Natural aplicada a ambientes virtuais de aprendizagem*. Orientadora: Márcia Aparecida Fernandes. 2017. 31 f. Trabalho de Conclusão de Curso (Graduação em Ciência da Computação) – Universidade Federal de Uberlândia, Uberlândia, 2017. Disponível em: <https://repositorio.ufu.br/handle/123456789/25258>. Acesso em: 14 mar. 2020.



Fique atento

Os *links* para *sites* da Web fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS