

Apresentação: Análise multivariada de dados

Com o avanço tecnológico, as diversas informações geradas em variadas áreas do conhecimento estão sendo coletadas e armazenadas em bancos de dados e estão disponíveis para análises de melhoria na tomada de decisões. Parte dessas informações pode ser analisada e interpretada com estatística simples; no entanto, outra parte necessita de técnicas estatísticas multivariadas mais complexas para converter dados em conhecimentos.

Entre essas técnicas está a análise multivariada de dados, que é um conjunto de modelos estatísticos que examinam padrões em dados multidimensionais, considerando, ao mesmo tempo, diversas variáveis de dados. Essa análise pode examinar fenômenos mais complexos e encontrar padrões de dados que representam com mais precisão o mundo real.

Nesta Unidade de Aprendizagem, você aprenderá a conceituar e a conduzir a análise multivariada e conhecerá os tipos de visualização e suas respectivas variáveis.

Bons estudos.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- Conceituar a análise multivariada.
- Descrever as formas de condução de uma análise multivariada de dados.
- Identificar o tipo de visualização e as respectivas variáveis envolvidas.

Infográfico: Análise multivariada de dados


Determinar a forma de análise sobre um conjunto de dados é importante para saber qual rumo tomar durante um problema ou uma pesquisa, e existem maneiras de melhor escolher a técnica que poderá ser abordada. O conjunto de técnicas para a realização de análise multivariada é dividido em dois grandes grupos, as de dependência e as de interdependência, sendo que cada técnica depende do problema.

No Infográfico a seguir, veja as dicas de como escolher a melhor técnica para realizar as análises multivariadas de dados conforme o problema tratado.

DEFINIÇÃO DE QUAL TIPO DE ANÁLISE DA DADOS DEVE SER APLICADO

Existem diversas formas de realizar uma análise sobre os dados, especialmente se, no conjunto de dados avaliado, existirem inúmeros atributos.

A seguir, você verá um mapa que auxilia a encontrar a melhor forma de análise:



Com esse passo a passo, fica mais fácil chegar à definição sobre qual tipo de análise realizar acerca de um conjunto de dados.

É importante notar que, no esquema, as técnicas de dependência se inclinam para o lado esquerdo, enquanto as técnicas de interdependência estão à direita da imagem.



A técnica de dependência pode ser compreendida por uma ou mais variáveis possuírem relação entre si.

Ou seja, **as variáveis explicam ou contribuem para o valor de outras variáveis**, que podem ou não ser variáveis independentes.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Análise multivariada de dados


A efetiva análise de uma gama de dados multivariados pode determinar uma eficiente compreensão dos dados, por meio de técnicas regressivas multivariadas, de escalas de dados, entre outros parâmetros.

No capítulo Análise multivariada de dados, da obra *Preparação e análise exploratória de dados*, serão analisados conceitos que tratam desse tema, além das técnicas utilizadas para a avaliação dos dados e dos gráficos de representação desses dados.

Boa leitura.

PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Rafael Albuquerque



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Análise multivariada de dados

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Conceituar análise multivariada.
- Descrever as formas de condução de uma análise multivariada de dados.
- Identificar o tipo de visualização e as respectivas variáveis envolvidas.

Introdução

Devido à grande quantidade de dados disponível, nas mais diversas áreas, realizar a análise dos dados passou a ser uma necessidade. A tarefa de analisar dados existe há muito tempo, mas esse processo sempre foi muito custoso e demorado. Com os avanços tecnológicos e, principalmente, da computação, a análise de dados passou a ser mais viável. Dentro do conjunto de técnicas de análise de dados, existe a análise multivariada, uma tarefa que exige a realização de cálculos avançados para processar fenômenos complexos, cujos resultados podem quase prever o futuro ou extrair informações despercebidas.

Com o passar do tempo, várias técnicas de análise de dados multivariada se tornaram acessíveis para grandes empresas e, mais tarde, para todos com acesso a um computador. Além do avanço de *hardware*, cada dia mais surgem pacotes computacionais que permitem que seja realizada, rapidamente, a análise de uma grande quantidade de dados complexos, de uma forma mais simples e amigável.

Neste capítulo, você vai estudar a análise multivariada. Vai ver quais são as maneiras de conduzir uma análise multivariada de dados e quais os tipos de visualização são possíveis. Além disso, vai estudar as variáveis envolvidas nesse tipo de análise.

1 Conceito de análise multivariada de dados

Uma análise multivariada de dados bem-sucedida significa, em muitos casos, uma maior capacidade de tomada de decisões em um cenário complexo. Esse processo envolve técnicas estatísticas que suportem uma análise sobre uma combinação multivariada dos dados. Conforme Hair *et al.* (2009), muitas dessas técnicas são extensões de métodos que analisam a distribuição de apenas uma ou duas variáveis, chamados de análise univariada e bivariada, respectivamente. A análise bivariada é bastante aplicada em situações que necessitem realizar uma classificação cruzada, fazer correlação, análise de variância e regressão de dados. Hair *et al.* (2009) destacam ainda que, para um problema ser considerado sob uma perspectiva multivariada, todas as variáveis envolvidas devem ser aleatórias e relacionadas, de modo que seus efeitos não sejam expressivamente interpretados de maneira separada.

Embora a análise multivariada tenha uma base bem estabelecida nas estatísticas univariada e bivariada, a extensão desses domínios para um conjunto de dados no domínio multivariado carrega consigo conceitos adicionais (VIALI, [199-?]). De acordo com Hair *et al.* (2009), esses conceitos vão desde a necessidade de uma compreensão conceitual com base em dados mais simples e partindo de ações analisáveis no cenário multivariado — também nomeada como variável estatística — até pontos específicos, que lidam com os tipos de escalas de medida empregadas e as questões estatísticas de testes de significância e níveis de confiança.

Uma análise multivariada é assim denominada devido à sua forma, que permite a análise de mais de duas fontes de informações de maneira simultânea, para obter um melhor resultado de relação da representação do problema. Esses dados também podem ser apresentados como uma matriz de informações, como pode ser observado na Figura 1. Cada linha de observação da Figura 1 corresponde a uma amostra de cada variável, onde x_{ij} é a medida da variável j sobre o item ou indivíduo i .

Observação	variável 1	variável 2	variável 3	...	variável k
Obs ₁	x_{11}	x_{12}	x_{13}	...	x_{1k}
Obs ₂	x_{21}	x_{22}	x_{23}	...	x_{2k}
⋮	⋮	⋮	⋮	⋮	⋮
Obs _{n}	x_{n1}	x_{n2}	x_{n3}	...	x_{nk}

Figura 1. Exemplo de abordagem multivariada.

Fonte: Estatística... ([201-?], documento on-line).

Uma análise multivariada carrega consigo conceitos fundamentais para uma aplicação bem-sucedida sobre qualquer técnica multivariada. Conforme Hair *et al.* (2009), existem dois conceitos amplamente abordados, como o conceito de variável estatística e de escalas de medida, veja a seguir.

- **Variável estatística:** alicerce da análise multivariada, a variável estatística é uma combinação linear de variáveis. A maneira de determinar quais variáveis serão analisadas depende muito da visão holística do pesquisador sobre o problema a ser analisado. Uma variável estatística de n variáveis ponderadas (X_1 até X_n) pode ser enunciada em sua escrita matemática como $(w_1X_1 + w_2X_2 + w_3X_3 + \dots + w_nX_n)$, onde X_n é a variável observada e w_n é o peso determinado pela técnica multivariada.
- **Escalas de medida:** analisar um dado envolve identificar e medir a sua variação em um conjunto de dados variáveis, sejam essas variáveis dependentes, sejam independentes. Nesse contexto, as variáveis podem ser classificadas como métricas e não métricas. As escalas de medidas **métricas** apontam para dados métricos, os quais são utilizados em quantidade ou grau em relação a algum atributo em particular, como uma forma de avaliar a relevância de determinado atributo. As duas escalas de medida métrica são escalas intervalares e de razão. Essas duas escalas permitem fazer análises no mais alto nível de precisão de medida. Já as escalas de medidas **não métricas** apontam diferenças entre tipos de variáveis, ou natureza das variáveis, com indicações da presença ou ausência de uma característica ou propriedade.

Em análises de dados multivariados, normalmente é distribuída alguma responsabilidade de peso sobre cada variável. Ainda existe um fator que impacta diretamente na qualidade, que é o chamado erro de medida. Segundo Hair *et al.* (2009), **erro de medida** é o grau em que os valores observados correspondem aos valores “verdadeiros”, ou de comum valor esperado, para determinada variável. O erro de medido pode estar ligado a várias formas de coleta desses dados, desde a imprecisão da medida até a falta de manejo dos responsáveis por obter dados. Ademais, a análise multivariada se divide em **técnicas exploratórias** de simplificação da estrutura de variabilidade dos dados, em uma tentativa de sintetizar as variáveis, e em **técnicas de inferência**.

2 Formas de condução de uma análise multivariada de dados

Conforme Hair *et al.* (2009), existem duas categorias de técnica possíveis para realizar a condução de uma análise multivariada, as de dependência e interdependência, cada uma procurando um tipo de relacionamento entre os dados. As **técnicas de dependência** podem ser definidas como as técnicas nas quais uma variável ou conjunto de variáveis é dependente de outras variáveis, no sentido de causa e efeito. Em outras palavras, essas técnicas podem descrever ou prever os valores de outras variáveis. Já as **técnicas de interdependência** não podem definir nenhuma variável ou grupo de variável como independente ou dependente, pois todas as variáveis são analisadas simultaneamente, para serem entendidos os padrões subjacentes dos dados.

Entre os muitos fatores que diferenciam os diversos modelos multivariados, um dos principais fatores que geralmente são levados em consideração para a escolha de qual técnica utilizar é a natureza dos dados, que pode ser métrica e não métrica. De acordo com Hair *et al.* (2009), os dados métricos são utilizados quando indivíduos diferem em quantia ou grau em relação a um atributo em particular, por exemplo idade (20 anos), temperatura (25°C) e lucro (R\$ 100,00). Os dados não métricos descrevem diferenças em tipo ou natureza, indicando a presença ou ausência de uma característica ou propriedade (HAIR *et al.*, 2009), por exemplo, tamanho da casa (pequeno, médio, grande).

Técnicas de dependência

Nas técnicas de dependência, o modelo é alimentado com dados de entrada, especificando quais variáveis são independentes e quais são dependentes. As variáveis independentes são as que o modelo tentará prever ou explicar. As variáveis dependentes são aquelas em que se estuda o quanto elas afetam as independentes. Dessa forma, as técnicas de dependência buscam estabelecer um relacionamento de causa–efeito, sendo que cada técnica se diferencia em relação ao número de variáveis independentes que elas suportam e a natureza das variáveis envolvidas. Veja a seguir como e quando essas técnicas podem ser usadas.

Regressão múltipla

Conforme Hair *et al.* (2009), regressão múltipla é o método de análise apropriado quando o problema de pesquisa envolve uma única variável dependente métrica, considerada como relacionada a duas ou mais variáveis independentes métricas. Em outras palavras, o objetivo da regressão múltipla é realizar previsões de mudanças sobre a variável dependente como resposta a mudanças nas variáveis independentes. Sempre que ocorrer o interesse em prever a quantia ou magnitude da variável dependente, a regressão múltipla será útil.



Exemplo

Despesas mensais com jantares fora de casa (variável dependente) podem ser previstas a partir de informações referentes a renda familiar, tamanho da família e idade do(a) chefe da família (variáveis independentes).

Análise conjunta

A análise conjunta é uma técnica emergente de dependência que tem trazido nova sofisticação para a avaliação de objetos, como novos produtos, serviços ou ideias (HAIR *et al.*, 2009). Testa todas as combinações de níveis nas variáveis não métricas e observa o valor do valor dependente em cada uma delas. Essa análise é capaz de avaliar a importância dos atributos, bem como dos níveis de cada atributo. É amplamente usada no domínio comercial, onde é possível examinar a aceitação do usuário (a variável dependente) sobre produtos de atributos variados (variáveis independentes) sem desperdiçar muitos recursos.

Análise discriminante múltipla

A análise discriminante múltipla (MDA, *multiple discriminant analysis*) é a técnica multivariada adequada quando a única variável dependente é dicotômica (por exemplo, masculino–feminino) ou multicotômica (por exemplo, alto–médio–baixo); portanto é uma análise não métrica (HAIR *et al.*, 2009). A análise discriminante é aplicável em situações nas quais a amostra total pode ser dividida em grupos baseados em uma variável dependente não métrica que caracteriza diversas classes conhecidas. Conforme Hair *et al.* (2009), os objetivos primários da análise discriminante múltipla são entender diferenças de grupos e prever a probabilidade de que uma entidade (indivíduo ou objeto) pertencerá a uma classe ou grupo em particular com base em diversas variáveis independentes métricas. Por exemplo, distinguir os usuários que são consumidores de marcas nacionais dos usuários consumidores de marcas importadas.

Análise multivariada de variância e covariância

A análise de variância multivariada (MANOVA, *multivariate analysis of variance*) e a análise de covariância multivariada (MANCOVA, *multivariate analysis of covariance*) são técnicas usadas para medir o efeito de muitas variáveis independentes não métricas em duas ou mais variáveis métricas dependentes. A **análise multivariada de variância** é uma técnica estatística que pode ser usada para explorar simultaneamente as relações entre diversas variáveis independentes categóricas (geralmente chamadas de tratamentos) e duas ou mais variáveis dependentes métricas (HAIR *et al.*, 2009). Já a **análise multivariada de covariância**, conforme Hair *et al.* (2009), pode ser usada com MANOVA para remover (após o experimento) o efeito de quaisquer variáveis independentes métricas não controladas (conhecidas como covariáveis estatísticas) sobre as variáveis dependentes.

Análise de correlação canônica

A análise de correlação canônica pode ser vista como uma extensão lógica da análise de regressão múltipla. A análise de regressão múltipla envolve uma única variável dependente métrica e várias variáveis independentes métricas. Com a análise canônica, o objetivo é correlacionar simultaneamente diversas variáveis dependentes métricas e diversas variáveis independentes métricas (HAIR *et al.*, 2009). Em outras palavras, o objetivo é obter um conjunto de pesos para as variáveis dependentes e independentes, que fornece a correlação simples máxima entre o conjunto de variáveis dependentes e o de variáveis independentes.

Modelagem de equações estruturais

De acordo com Kumar, Singh e Mishra (2013) e Hair *et al.* (2009), essa técnica tenta encontrar diferentes equações de relacionamento para cada variável dependente. Uma maneira de ver a modelagem de equações estruturais é enxergá-la como uma técnica que decompõe um problema de muitas variáveis independentes em várias regressões múltiplas e as calcula simultaneamente. Em seu sentido mais simples, a modelagem de equações estruturais fornece a técnica de estimação apropriada e mais eficiente para uma série de equações de regressão múltipla separadas estimadas simultaneamente (HAIR *et al.*, 2009).

Técnicas de interdependência

As técnicas de interdependência analisam todas as variáveis simultaneamente em um esforço para encontrar uma estrutura subjacente a todo o conjunto de variáveis ou indivíduos (HAIR *et al.*, 2009; KUMAR; SINGH; MISHRA, 2013). Em outras palavras, essas técnicas buscam descrever padrões nos dados sem realizar suposições sobre as variáveis.

Análise fatorial

Conforme Hair *et al.* (2009), a análise fatorial visa a reduzir a dimensionalidade dos dados, reduzindo o número de variáveis de dados. Ela detecta grupos de variáveis com alta correlação, ou seja, busca entender quais variáveis estão altamente correlacionadas com outras. Ao usar a análise fatorial para condensar as informações em um conjunto menor de novas variáveis, os padrões se tornam menos diluídos e mais fáceis de analisar. As escalas são então integradas na estimação das relações entre variáveis dependentes e independentes no modelo estrutural.

Análise de *cluster*

A análise de *cluster* ou de agrupamentos é uma técnica analítica para desenvolver subgrupos significativos de indivíduos ou objetos. Especificamente, o objetivo é classificar uma amostra de entidades (indivíduos ou objetos) em um número menor de grupos mutuamente excludentes, com base nas similaridades entre as entidades (HAIR *et al.*, 2009). Na análise de agrupamentos, diferentemente da análise discriminante, os grupos não são predefinidos; em vez disso, a técnica é usada para identificar os grupos.



Exemplo

Em dados comerciais, a análise de *cluster* pode resultar no reconhecimento de um grupo de consumidores com características semelhantes e que compram determinados produtos com muita frequência.

Escala multidimensional

No escalonamento multidimensional (também conhecido como mapeamento perceptual), o objetivo é transformar julgamentos de consumidores sobre similaridade ou preferência (por exemplo, preferência por lojas ou marcas) em distâncias representadas em um espaço multidimensional (HAIR *et al.*, 2009). Um uso comum do dimensionamento multidimensional é detectar quais produtos têm um perfil de consumidor semelhante.

Análise de correspondência

De acordo com Hair *et al.* (2009), a análise de correspondência é uma técnica de interdependência recentemente desenvolvida, que facilita o mapeamento perceptual de objetos (por exemplo, produtos, pessoas) em um conjunto de atributos não métricos. A análise de correspondência fornece uma representação multivariada de interdependência para dados não métricos que não é possível com outros métodos. Por exemplo, essa técnica poderia correlacionar marcas de celular (marca A, marca B, marca C) com perfis de consumidores (adolescentes, adultos, idosos).

3 Tipos de visualização e suas respectivas variáveis

Uma das maneiras de avaliarmos dados multivariados é visualmente. Ferramentas de *data warehouse*, de inteligência artificial e de visualização de dados são exemplos desse método e têm sido amplamente adotadas pelas organizações devido à sua eficácia em abstrair as informações corretas, interpretar e compreender os resultados de forma mais direta.



Fique atento

As figuras mostradas a seguir plotadas utilizando algumas bibliotecas, como Pandas (leitura da base de dados), Matplotlib (plotagem) e Seaborn (personalização das plotagens), em conjunto a linguagem de programação Python.

Caso queira desenvolver o código para replicar essas representações gráficas, sugerimos que você se atenha à documentação do Seaborn, na qual poderá encontrar diversas formas de manuseio.

Antes de abordarmos a representação multivariada, vamos explorar uma base de dados que nos norteará, para uma melhor explanação das formas visuais que poderemos encontrar para analisar esta base. A base de dados contém dados para avaliação da qualidade de vinho branco (*white wine*) e vinho vermelho (*red wine*), com as variáveis descritas em colunas, como mostra a Figura 2.

```

white_wine = pd.read_csv('winequality-white.csv', sep=';')
red_wine = pd.read_csv('winequality-red.csv', sep=';')

# armazena os tipos de vinhos como um atributo
red_wine['wine_type'] = 'red'
white_wine['wine_type'] = 'white'

# agrupar os índices de qualidade dos vinhos em rótulos qualitativos de qualidade
red_wine['quality_label'] = red_wine['quality'].apply(lambda value: 'low'
                                                    if value <= 5 else 'medium'
                                                    if value <= 7 else 'high')
red_wine['quality_label'] = pd.Categorical(red_wine['quality_label'],
                                          categories=['low', 'medium', 'high'])
white_wine['quality_label'] = white_wine['quality'].apply(lambda value: 'low'
                                                         if value <= 5 else 'medium'
                                                         if value <= 7 else 'high')
white_wine['quality_label'] = pd.Categorical(white_wine['quality_label'],
                                             categories=['low', 'medium', 'high'])

# reúne as bases de vinhos branco e vermelho
wines = pd.concat([red_wine, white_wine])

# mistura a ordem dos dados de modo randômico
wines = wines.sample(frac=1, random_state=42).reset_index(drop=True)

# apresenta os primeiros 5 registros
wines.head()

```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol	quality	wine_type	quality_label
0	7.0	0.17	0.74	12.8	0.045	24.0	126.0	0.99420	3.26	0.38	12.2	8	white	high
1	7.7	0.64	0.21	2.2	0.077	32.0	133.0	0.99560	3.27	0.45	9.9	5	red	low
2	6.8	0.39	0.34	7.4	0.020	38.0	133.0	0.99212	3.18	0.44	12.0	7	white	medium
3	6.3	0.28	0.47	11.2	0.040	61.0	183.0	0.99592	3.12	0.51	9.5	6	white	medium
4	7.4	0.35	0.20	13.9	0.054	63.0	229.0	0.99688	3.11	0.50	8.9	6	white	medium

Figura 2. Amostra da base de dados para medir a qualidade de vinhos.

Fonte: Adaptada de Sarkar (2018).



Saiba mais

Acompanhe a seguir a tradução dos atributos da base de dados, mostradas na Figura 2:

- *fixed acidity*: acidez fixa;
- *volatile acidity*: acidez volátil;
- *citric acid*: ácido cítrico;
- *residual sugar*: açúcar residual;
- *chlorides*: cloretos;
- *free sulfur dioxide*: dióxido de enxofre livre;
- *total sulfur dioxide*: dióxido de enxofre total;
- *density*: densidade;
- *sulphates*: sulfatos;
- *alcohol*: álcool;
- *quality*: qualidade;
- *wine_type*: tipo_vinho;
- *quality_label*: selo_qualidade;
- *high*: alta;
- *medium*: média;
- *low*: baixa.

Em uma análise visual de modo singular, ou seja, visualizando apenas um dos atributos ao ponto de olhar cada atributo, podemos usar o tipo de apresentação em histogramas, como visto na Figura 3. Ela mostra a distribuição dos valores encontrados em cada atributo da base de dados.

Visualizações em uma dimensão são bastante úteis e práticas para quando temos dados em formato discreto ou contínuo. No entanto, nem sempre são suficientes para obtermos uma análise mais detalhada sobre determinada relação entre valores. Por exemplo, se quiséssemos avaliar o nível de correlação entre cada atributo da base, talvez a geração de vários gráficos únicos sobre cada atributo gerasse desgaste, além de dificultar um pouco a análise. É por isso que, muitas vezes, para este tipo de problema de correlação, utilizamos ferramentas de visualização de correlação em forma matricial, como visto na Figura 4.




Figura 3. Distribuição dos valores dos atributos da base de dados.

Fonte: Adaptada de Sarkar (2018).

```
# Matriz de correlação Heatmap
f, ax = plt.subplots(figsize=(10, 6))
corr = wines.corr()
hm = sns.heatmap(round(corr,2),
                  annot=True,
                  ax=ax,
                  cmap="coolwarm",
                  fmt='.2f',
                  linewidths=.05)
f.subplots_adjust(top=0.93)
```




Figura 4. Apresentação da correlação entre os atributos.

Fonte: Adaptada de Sarkar (2018).

Na Figura 4, você pode observar que a cor do gradiente varia conforme a aproximação ou o afastamento dos dados correlacionados. O mesmo pode ser visto na Figura 5, com a apresentação do gráfico de dispersão (*scatter*) para alguns atributos da base.

```
# Plotagem com pares de Scatter
cols = ['density', 'residual sugar', 'total sulfur dioxide', 'fixed acidity']
pp = sns.pairplot(wines[cols], size=1.8, aspect=1.8,
                  plot_kws=dict(edgecolor="k", linewidth=0.5),
                  diag_kind="kde", diag_kws=dict(shade=True))

fig = pp.fig
fig.subplots_adjust(top=0.93, wspace=0.3)
```




Figura 5. Apresentação de bicornrelação entre quatro atributos da base.

Fonte: Adaptada de Sarkar (2018).

A visualização em três dimensões é válida quando precisamos observar dimensões além das correlacionais dos dados, como visto na Figura 5, em que você pode ver uma plotagem de dispersão (*scatter*) para uma comparação de grupos de vinhos brancos e vermelhos. A Figura 6 mostra as correlações e padrões e compara os tipos de vinhos para as variáveis apontadas em cada imagem.

```
# Plotagem em Scatter com Hue para visualização para dados em 3-D
cols = ['density', 'residual sugar', 'total sulfur dioxide', 'fixed acidity', 'wine_type']
pp = sns.pairplot(wines[cols], hue='wine_type', size=1.8, aspect=1.8,
                 palette={"red": "#FF9999", "white": "#FFE888"},
                 plot_kws=dict(edgecolor="black", linewidth=0.5))
fig = pp.fig
fig.subplots_adjust(top=0.93, wspace=0.3)
```




Figura 6. Apresentação tridimensional dos dados com plotagem do tipo *scatter*.

Fonte: Adaptada de Sarkar (2018).

Agora, imagine que você precisa visualizar os dados contínuos das imagens em uma perspectiva em três dimensões. Para isso, você pode então utilizar dois eixos, de modo a representar a largura e o comprimento, e um eixo adicional, que representa o eixo de profundidade, como você pode ver na Figura 7.

```
# Visualização em 3-D para dados numéricos com plotagem em Scatter  
# comprimento, largura e profundidade  
fig = plt.figure(figsize=(8, 6))  
ax = fig.add_subplot(111, projection='3d')  
  
xs = wines['residual sugar']  
ys = wines['fixed acidity']  
zs = wines['alcohol']  
ax.scatter(xs, ys, zs, s=50, alpha=0.6, edgecolors='w')  
  
ax.set_xlabel('Residual Sugar')  
ax.set_ylabel('Fixed Acidity')  
ax.set_zlabel('Alcohol')
```




Figura 7. Apresentação tridimensional dos dados com plotagem do tipo *scatter* com noção de profundidade.

Fonte: Adaptada de Sarkar (2018).

É possível também utilizar gráficos em barra para representar três categorias com valores discretos (valores inteiros, como 0, 1, 2, 3...) com aproveitamento da utilização de tonalidade, assim como facetas e subparcelas, criando assim, um suporte para a terceira dimensão. Observe a Figura 8 — ela apresenta a frequência de cada uma das dimensões, o que facilita sua compreensão.

```
# Visualização 3-D com dados categóricos usando plotagem em barras
# com conceitos de hue e facets(representado por col)
fc = sns.factorplot(x="quality", hue="wine_type", col="quality_label",
                    data=wines, kind="count",
                    palette={"red": "#FF9999", "white": "#FFE888"})
```




Figura 8. Apresentação tridimensional dos dados com plotagem do tipo barra e dados categóricos, introduzindo a noção de matiz (*hue*) e facetas (*facets*).

Fonte: Adaptada de Sarkar (2018).

Existe também a possibilidade de utilizarmos outras formas de visualização em dimensões, como a 4D e a 6D, trazendo novas perspectivas de apresentação para um problema. Além dos gráficos de barra e dispersão, é possível avaliar também os gráficos de densidade, muito úteis quando se deseja conhecer a forma da distribuição dos dados. Por exemplo, suponha que você precise avaliar o nível de sulfato sobre os vinhos branco e vermelho da base de dados. Neste caso, poderíamos utilizar o gráfico de densidade para analisar que os níveis de sulfato encontrados nos vinhos vermelhos são maiores do que os encontrados nos vinhos brancos, e que o nível de álcool é suavemente maior e menor nos vinhos brancos, conforme mostra a Figura 9.

```
# Visualização em 3-D com mistura com gráficos de densidade  
# com conceitos de hue para dimensão categórica  
ax = sns.kdeplot(white_wine['sulphates'], white_wine['alcohol'],  
                 cmap="YlOrBr", shade=True, shade_lowest=False)  
ax = sns.kdeplot(red_wine['sulphates'], red_wine['alcohol'],  
                 cmap="Reds", shade=True, shade_lowest=False)
```




Figura 9. Densidade de sulfato sobre os vinhos branco e vermelhos.

Fonte: Adaptada de Sarkar (2018).

A análise de dados via gráfico é uma ferramenta bastante poderosa, pois pode trazer à tona diversas informações extremamente difíceis de encontrar com a visualização dos números dos atributos apenas. Conhecer esses conceitos, portanto, é extremamente importante para a realização de uma análise multivariada, assim como o conhecimento sobre as técnicas e formas de apresentação da estatística, distribuição, dispersão e densidade dos dados.



Referências

ESTATÍSTICA e matrizes. [S. l., 201-?]. Disponível em: https://edisciplinas.usp.br/plugin-file.php/3381174/mod_resource/content/1/02_Introdu%C3%A7%C3%A3oMultivaria da_Matrizes.pdf. Acesso em: 7 jul. 2020.

HAIR, J. F. et al. *Análise multivariada de dados*. 6. ed. Porto Alegre: Bookman, 2009.

KUMAR, S.; SINGH, S. K.; MISHRA, P. Multivariate analysis: an overview. *Journal of Dentofacial Sciences*, v. 2, n. 3, p. 19–26, 2013.

SARKAR, D. The art of effective visualization of multi-dimensional data: strategies for effective data visualization. In: TOWARDS DATA SCIENCE. [S. l.], 2018. Disponível em: <https://towardsdatascience.com/the-art-of-effective-visualization-of-multi-dimensional-data-6c7202990c57>. Acesso em: 7 jul. 2020.

VIALI, L. *Série estatística multivariada*: introdução. [S. l., 199-?]. Disponível em: <http://www.pucrs.br/ciencias/viali/especializa/realizadas/ceea/multivariada/textos/Introducao.pdf>. Acesso em: 7 jul. 2020.

Leitura recomendada

LEONI, R. C.; SAMPAIO, N. A. de S.; CORREA, S. M. Estatística multivariada aplicada ao estudo da qualidade do ar. *Revista Brasileira de Meteorologia*, v. 32, n. 2, p. 235–241, 2017. Disponível em: <https://www.scielo.br/pdf/rbmet/v32n2/0102-7786-rbmet-32-02-0235.pdf>. Acesso em: 7 jul. 2020.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Dica do Professor: Análise multivariada de dados

Existem muitas técnicas multivariadas disponíveis para a análise de dados, porém elas dependem de algumas questões envolvidas em cada aplicação.

Dessa forma, fica claro que, para realizar uma análise multivariada de forma eficiente, é preciso muito mais do que apenas escolher uma técnica. O ideal é projetar uma visão geral de como será feita a análise, pois os detalhes a serem analisados dependem muito do problema tratado. Para isso, deve haver um planejamento, e esse planejamento geralmente é executado em seis passos.

Na Dica do Professor, você conhecerá e analisará cada um desses passos, que estão divididos da seguinte forma: definição do problema, desenvolvimento do plano, avaliação das suposições, ajuste geral do modelo, interpretação da(s) variável(eis) e validação do modelo.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Saiba mais: Análise multivariada de dados

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Métodos quantitativos interpretativos na educação em ciências: abordagens para análise multivariada de dados

Um avanço na direção do desenvolvimento dos chamados métodos mistos, principalmente quanto à análise quantitativa interpretativa.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Trinta anos de análise multivariada de dados no campo da gestão estratégica: uma revisão sistemática

Descreve a utilização de técnicas de análise multivariada de dados em pesquisas sobre gestão estratégica. Este estudo consiste em uma revisão sistemática da literatura científica.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

O que você precisa saber sobre análise multivariada?

A análise multivariada verifica quais variáveis impactam em outras e de que forma é esse impacto, o quanto impacta e permite realizar projeções por meio de modelos matemáticos, estimando valores dentro de certos cenários estipulados.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Apresentação: Machine Learning: Agrupamento das Flores

1. OBJETIVO

Neste experimento, você vai conhecer o funcionamento de métodos de aprendizado para a tarefa de análise de agrupamentos, em especial o algoritmo *k-means*, de aprendizado não supervisionado, muito simples e eficaz. Para isso, você vai utilizar uma base de dados composta de descrições de instâncias de três tipos de flores íris, que deverão ser agrupadas corretamente pelo algoritmo.

Ao final deste experimento, você deverá ser capaz de:

- reconhecer o que é a tarefa de análise de agrupamentos;
- reconhecer o funcionamento do algoritmo *k-means*;
- identificar as principais métricas para avaliação de resultados do algoritmo *a priori*;
- implementar e testar uma versão do algoritmo *k-means* utilizando a base de dados de flores íris.

2. ONDE UTILIZAR ESSES CONCEITOS?

A análise de agrupamentos pode ser utilizada em diversas tarefas do cotidiano, como: segmentação de mercado e de clientes; domínio médico; segmentação de imagem; e detecção de anomalias.

3. O EXPERIMENTO

O experimento consiste em utilizar um algoritmo de agrupamento para encontrar *clusters* dentro do *dataset* das flores íris.

Serão fornecidos vários dados diferentes, em formato de tabela, divididos em duas colunas. Na sequência, você vai parametrizar e executar o algoritmo sobre esses dados, avaliando a técnica utilizada para distinguir os dados em grupos diferentes, prevendo onde novos dados cairiam no modelo.

4. SEGURANÇA

Para esta prática, você deve se assegurar de que não há *softwares* maliciosos instalados em seu computador, para não haja interferências em sua implementação. Para isso, recomenda-se o uso de

um antivírus atualizado.

5. CENÁRIO

A prática acontecerá em um ambiente semelhante a um software utilizado no computador.

Sumário teórico: Machine Learning: Agrupamento das Flores

AGRUPAMENTO DAS FLORES

INTRODUÇÃO

O agrupamento é uma técnica não supervisionada de *machine learning* que permite, a partir de um conjunto de dados não rotulados, encontrar alguma estrutura interna desses dados na forma de grupos.

Segundo Almeida, Carvalho e Menino (2020), em aprendizado de máquina, o agrupamento é a técnica utilizada para separar um conjunto de dados em diferentes grupos (chamados de *clusters*, em inglês), de acordo com características ou atributos em comum.

A Figura 1 apresenta um conjunto de itens (a) e três formas diferentes de fazer um agrupamento. O agrupamento (b) separou os itens em dois *clusters*, um pela forma elíptica/arredondada e o outro pela forma retangular. O agrupamento (c) separou os itens em dois *clusters*, de acordo com o preenchimento (cor cinza ou branca), e o agrupamento (d) separou os itens em quatro *clusters*, conforme a forma e o preenchimento.

a)




Figura 1 – Itens agrupados de maneiras diferentes. Fonte: Adaptada de Faceli *et al.* (2021).

Em *machine learning*, a técnica de agrupamento é amplamente utilizada em diversas tarefas, como sistemas de recomendação de novos produtos, de acordo com pesquisas anteriores realizadas pelo usuário, ou de filmes e séries em serviços de *streaming*, a partir do histórico de exibição dos assinantes. Além desses exemplos, também podemos citar:

- segmentação de mercado;
- análise de dados estatísticos;
- análise de redes sociais;
- segmentação de imagem;
- detecção de anomalias.

PRINCIPAIS ESTRATÉGIAS DE AGRUPAMENTOS

Em geral, são três as principais estratégias de agrupamentos: agrupamento por partição, agrupamento hierárquico e agrupamento por densidade. Vejamos as explicações a seguir:

O **agrupamento por partição** cria partições no espaço em que o conjunto de dados está inserido, separando os dados em diferentes partições. Cada partição representa um *cluster*, e cada dado pode pertencer a um único *cluster*.

Sobre o **agrupamento hierárquico**, este agrupa os dados em grupos de forma hierárquica, tanto em uma abordagem *top-down* (iniciando com um grande grupo e dividindo-o em grupos menores) quanto *bottom-up* (iniciando com um grupo para cada dado e formando grupos maiores). Nessa abordagem, temos uma noção de hierarquia entre os *clusters*, ou seja, um *cluster* pode conter outros *clusters* menores dentro dele e, dessa forma, um mesmo dado pode fazer parte, ao mesmo tempo, de mais de um *cluster*.

Já o **agrupamento por densidade** forma grupos com base em regiões do espaço que tenham uma grande densidade de dados, separando-os por regiões que tenham uma baixa densidade.

De forma geral, podemos separar a tarefa de agrupamento em cinco etapas:

1. **Preparação dos dados de entrada:** nesta etapa, é feita a normalização, transformação e limpeza dos dados, de forma que possam ser utilizados em algum algoritmo de agrupamento.
2. **Definição da medida de proximidade:** de acordo com o contexto da tarefa e o tipo de dados, escolhemos uma função de similaridade (ou dissimilaridade) que será utilizada em nosso algoritmo.
3. **Agrupamento dos dados:** a aplicação do algoritmo de agrupamento de fato.
4. **Validação:** análise dos resultados gerados pelo algoritmo de agrupamento.
5. **Interpretação dos resultados:** aqui, a interpretação é mais subjetiva. Queremos compreender e descrever a relação entre os elementos de um mesmo *cluster* e sua natureza.

Um dos principais algoritmos de agrupamento é o *k-means*. É um algoritmo de agrupamento por partição muito simples e amplamente conhecido (FACELI *et al.*, 2021).

Segundo Faceli *et al.* (2021), o *k-means* particiona o conjunto de dados em *k clusters*, em que o valor de *k* é fornecido pelo usuário. Esses *clusters* são formados de acordo com alguma medida de similaridade, como a distância euclidiana entre dois pontos.

Em resumo, o algoritmo escolhe *k* pontos no espaço, chamados centroides, normalmente inicializados randomicamente, e atribui cada dado a um *cluster* (representado pelo centroide), de acordo com sua similaridade.

Após todos os dados terem sido atribuídos a algum *cluster*, os centroides são recalculados, e cada dado tem sua similaridade com os centroides recalculada também, podendo ser atribuído para outro *cluster*, cujo centroide lhe é mais similar.

Esse processo se repete até que não haja mais mudanças nos centroides ou seja alcançado um número máximo definido de iterações. O algoritmo *k-means* está descrito em pseudocódigo na Figura 2.

```
Iniciar os valores de centroides dos k clusters

Enquanto houver alterações no centroide, repetir:
  Iterar conjunto de dados fazendo para cada instância:
    Calcular a função de distância entre a instância e o centroide dos clusters.
    Vincular a instância ao cluster mais próximo.
  Fim da iteração
  Iterar cada conjunto de dados fazendo para cada cluster:
    Calcular o novo centroide
  Fim da iteração
Fim da repetição
```

Figura 2 – Pseudocódigo do algoritmo *k-means*. Fonte: Lenz et al. (2021, p. 51).

A Figura 3 demonstra uma execução do algoritmo *k-means* com um valor de $k = 4$ e seis iterações até a convergência. Inicialmente, são escolhidos quatro centroides de forma aleatória (+ verdade, + vermelho, + lilás e + amarelo). Depois disso, os dados são atribuídos ao *cluster* cujo valor é mais similar aos centroides.

A cada iteração, os centroides são recalculados e atualizados, de maneira que os dados são redistribuídos em seus *clusters* mais similares.




Figura 3 – Exemplo de execução do algoritmo *k-means* com $k = 4$ e seis iterações até a convergência. Fonte: Agor153 (2012).

REFERÊNCIAS BIBLIOGRÁFICAS

AGOR153. K-means convergence to a local minimum. **Wikimedia Commons**, 2012. Disponível em: https://commons.wikimedia.org/wiki/File:K-means_convergence_to_a_local_minimum.png. Acesso em: 31 maio 2022.

ALMEIDA, A.; CARVALHO, F.; MENINO, F. Introdução ao *machine learning*. **GitHub**, 2020. Disponível em: <https://github.com/dataAt/introducao-ao-machine-learning>. Acesso em: 31 maio 2022.

FACELI, K. *et al.* **Inteligência artificial: uma abordagem de aprendizado de máquina**. São Paulo: LTC, 2021.

LENZ, M. L. *et al.* **Fundamentos de aprendizagem de máquina**. Porto Alegre: Sagah, 2020.

Roteiro: Machine Learning: Agrupamento das Flores



INSTRUÇÕES GERAIS


1. Neste experimento, você irá aprender a utilizar um algoritmo clássico de classificação (clustering) para segmentação de dados de acordo com categorias.
2. Utilize a seção **“Recomendações de Acesso”** para melhor aproveitamento da experiência virtual e para respostas às perguntas frequentes a respeito do Laboratório Virtual.
3. Caso não saiba como manipular o Laboratório Virtual, utilize o **“Tutorial”** presente neste Roteiro.
4. Caso já possua familiaridade com o Laboratório Virtual, você encontrará as instruções para realização desta prática na subseção **“Procedimentos”**.
5. Ao finalizar o experimento, responda aos questionamentos da seção **“Avaliação dos Resultados”**.

RECOMENDAÇÕES DE ACESSO

DICAS DE DESEMPENHO

Para otimizar a sua experiência no acesso aos laboratórios virtuais, siga as seguintes dicas de desempenho:

- **Feche outros aplicativos e abas:** Certifique-se de fechar quaisquer outros aplicativos ou abas que possam estar consumindo recursos do seu computador, garantindo um desempenho mais eficiente.
- **Navegador Mozilla Firefox:** Recomendamos o uso do navegador



[Mozilla Firefox](#), conhecido por seu baixo consumo de recursos em comparação com outros navegadores, proporcionando uma navegação mais fluida.

- **Aceleração de hardware:** Experimente habilitar ou desabilitar a aceleração de hardware no seu navegador para otimizar o desempenho durante o acesso aos laboratórios virtuais.
- **Requisitos mínimos do sistema:** Certifique-se de que seu computador atenda aos requisitos mínimos para acessar os laboratórios virtuais. Essa informação está disponível em nossa

[Central de Suporte.](#)

- **Monitoramento do sistema:** Utilize o Gerenciador de Tarefas (*Ctrl + Shift + Esc*) para verificar o uso do disco, memória e CPU. Se estiverem em 100%, considere fechar outros aplicativos ou reiniciar a máquina para otimizar o desempenho.
- **Teste de velocidade de internet:** Antes de acessar, realize um teste de velocidade de internet para garantir uma conexão estável e rápida durante o uso dos laboratórios virtuais.
- **Atualizações do navegador e sistema operacional:** Mantenha seu navegador e sistema operacional atualizados para garantir compatibilidade e segurança durante o acesso aos laboratórios.

PRECISA DE AJUDA?

Em caso de dúvidas ou dificuldades técnicas, visite nossa Central de Suporte para encontrar artigos de ajuda e informações para usuários. Acesse a [Central de Suporte](#) através do link: <https://suporte-virtual.algetec.com.br>

Se preferir, utilize os QR Codes abaixo para entrar em contato via [WhatsApp](#) ou ser direcionado para a [Central de Soporte](#). Estamos aqui para ajudar! Conte conosco!



DESCRIÇÃO DO LABORATÓRIO

PROCEDIMENTOS

ENTENDENDO O PROBLEMA

Leia os textos contidos no menu de etapas para entender mais sobre o problema proposto.

CONFIGURANDO OS DADOS

Configure a simulação no menu “Simulação” e selecione o conjunto de dados que deseja trabalhar. Você pode utilizar os conjuntos fixos oferecidos pelo simulador ou importar copiando e colando o texto do arquivo .csv. Siga para a aba de parametrização do algoritmo, selecione $K=2$ e randomize a posição inicial dos centroides.

ANALISANDO AS SOLUÇÕES

Execute o algoritmo e avance o passo a passo para entender o seu funcionamento. Siga para a análise da solução e verifique as zonas de cada centroide através das áreas pintadas no submenu de resultado. Retorne ao menu de parametrização e experimente novas posições iniciais para os centroides e observe os resultados. Retorne novamente ao menu de parametrização e execute novamente o algoritmo para valores diferentes de K .

ANALISANDO OUTROS CONJUNTOS

Repita o procedimento 2 e 3 para outros conjuntos de dados

AVALIANDO OS RESULTADOS

Siga para a seção “Avaliação dos Resultados” e responda de acordo com o que foi observado no experimento, associando também com os conhecimentos aprendidos sobre o tema.

AVALIAÇÃO DOS RESULTADOS

1. Explique a consequência de variar as posições iniciais dos centroides.
2. Entendendo a influência dos fenômenos observados, qual seria o K otimizado para o conjunto de dados escolhidos?
3. Qual seria a posição final dos centroides com este K otimizado para o conjunto de dados escolhido considerando a influência das condições iniciais no resultado final?

TUTORIAL

ENTENDENDO O PROBLEMA

Leia os textos contidos no menu de etapa clicando com o botão esquerdo do mouse sobre as categorias para avançar.

The screenshot displays the Algetec simulation interface. On the left, a vertical menu lists the following steps: 'Problema', 'Base de dados', 'Machine Learning', 'Métodos de agrupamento', 'Conceito: Centroide', 'Algoritmo K-means Clustering', 'Condições iniciais ideais', and 'Escolhendo o valor de K'. The 'Problema' step is currently selected and highlighted with a red border. The main area on the right is titled 'Problema proposto' and contains a descriptive text about the objective of the laboratory: to classify a set of data using clustering methods to predict and classify new data. Below the text, three scatter plots illustrate the K-Mean process. The first plot, 'Antes do K-Mean', shows a single cluster of grey data points. The second plot, 'Depois do K-Mean', shows the data points clustered into three groups: blue, yellow, and purple. The third plot shows a new data point (grey) being classified into one of the existing groups (Grupo 1 or Grupo 2).

Finalize a leitura e clique com o botão esquerdo do mouse no menu “Simulação” para avançar para a configuração da simulação.

Escolhendo o valor de K

Conforme aumenta o número de grupos, a tendência é que o somatório das distâncias se torne menor, então um desafio é escolher um número de grupos que represente bem os dados analisados sem que haja um sobreajuste que atrapalhe na previsão de novos dados ou demande muito processamento computacional. Uma forma comum de resolver esse problema é utilizar o método do cotovelo (em inglês, Elbow Method), que consiste em resolver o algoritmo para diferentes valores de K até encontrar o último número de grupos em que a variação do somatório das distâncias é razoavelmente significativa.

Somatório das distâncias

Valores de K

Valores de K	Somatório das distâncias
1	200
2	100
3	25
4	15
5	10
6	5
7	2
8	1
9	0

CONFIGURANDO OS DADOS

Configure a simulação clicando com o botão esquerdo do mouse sobre a base de dados. É possível inserir os dados manualmente alterando os valores de X e Y ou importando o texto .csv.

Configurações dos dados

Banco de dados carregado:

X	Y
5.1	3.5
4.6	2
3.5	2.1
7	4
10.5	7.7
10.6	7.8

Bases de dados predefinidas:

Exemplo inicial

Iris Dataset (Amostra aleatória)

Comprimento de Sépala, Largura de Sépala

5.1,3.5

4.9,3

4.7,3.2

4.6,3.1

5.3,6

5.4,3.9

Importar texto .csv acima

>> Utilizar esta base de dados <<

Gere os dados clicando com o botão esquerdo do mouse sobre o botão “Gerar e importar dados”.

algetec+ ETAPAS SIMULAÇÃO

Configuração dos dados
Parametrização do algoritmo
Visualização dos resultados
Análise da solução

Configurações dos dados

Banco de dados carregado:

X	Y
5.1	3.5
4.6	3.2
5.4	3.9

Gerador de amostra

 **Iris Setosa** ☒
 **Iris versicolor** ☒
 **Iris Virginica** ☐

Número de amostras por variedade: 5

Característica 1: Comprimento da Sépala (cm)
Característica 2: Largura da Sépala (cm)

>> Gerar e Importar dados <<

Bases de dados predefinidas:

Exemplo inicial
Iris Dataset (Amostra aleatória)

Comprimento de Sépala, Largura de Sépala
5.1,3.5
4.9,3
4.7,3.2
4.6,3.1
5.3,6
5.4,3.9

Importar texto .csv acima

Siga para a aba de parametrização clicando com o botão esquerdo do mouse sobre o botão “Parametrização do algoritmo”.

algetec+ ETAPAS SIMULAÇÃO

Configuração dos dados
Parametrização do algoritmo
Visualização dos resultados
Análise da solução

Configurações dos dados

Banco de dados carregado:

Comprimento da Sépala (cm)	Largura da Sépala (cm)
5.2	4.1
5.3	3.7
4.9	3
5.1	3.8
5	3.4
6.6	2.9
5.6	2.7
6.1	2.9
5.1	2.5
5.1	3.5

+ - 🗑️ >> Utilizar esta base de dados <<


Bases de dados predefinidas:

Exemplo inicial
Iris Dataset (Amostra aleatória)

Comprimento de Sépala, Largura de Sépala
5.1,3.5
4.9,3
4.7,3.2
4.6,3.1
5.3,6
5.4,3.9

Importar texto .csv acima

Randomize the position of the centroids by clicking with the left mouse button on the button "Randomize centroids".



ANALISANDO AS SOLUÇÕES

Execute the algorithm by clicking with the left mouse button on the button "Executar algoritmo K-means".




Para entender o funcionamento avance o passo a passo clicando com o botão esquerdo do mouse sobre as setas localizadas na parte inferior da tela.




Siga para a análise de solução clicando com o botão esquerdo do mouse sobre o botão “Análise da solução”.



Verifique as zonas de cada centroide através das áreas pintadas no submenu.



Retorne ao menu de parametrização e repita o procedimento alterando os valores de K.



ANALISANDO OUTROS CONJUNTOS

Repita os procedimentos 2 e 3 deste roteiro alterando o conjunto de dados.

AVALIANDO OS RESULTADOS

Siga para a seção “Avaliação dos Resultados” e responda de acordo com o que foi observado nos experimentos, associando também com os conhecimentos aprendidos sobre o tema.

Pré-teste: Machine Learning (de fixação, não avaliativo)

Sobre as diferentes estratégias de agrupamento, considere as três afirmações a seguir:

- 1)
- I. No agrupamento por partição, um mesmo dado só pode pertencer a um cluster de cada vez.
 - II. O agrupamento baseado em densidade agrupa seus dados de forma hierárquica, de modo que um mesmo dado pode fazer parte de mais de um cluster ao mesmo tempo.
 - III. O k-means é um exemplo de algoritmo de agrupamento que utiliza uma estratégia de agrupamento por densidade.

Qual(is) afirmação(ões) está(ão) correta(s)?

- A) Apenas II.
- B) Apenas I.
- C) I, II e III.

Agrupamento é a tarefa de encontrar grupos (clusters) de dados similares em um dataset. A tarefa de agrupamento pode ser separada, de forma mais geral, em cinco etapas. Assinale a alternativa que apresenta a ordem correta das etapas em uma tarefa de agrupamento.

- 2)
- A) Preparação dos dados de entrada; definição da medida de proximidade; validação; agrupamento dos dados; e interpretação dos resultados.
 - B) Preparação dos dados de entrada; agrupamento dos dados; definição da medida de proximidade; validação; e interpretação dos resultados.
 - C) Preparação dos dados de entrada; definição da medida de proximidade; agrupamento dos dados; validação; e interpretação dos resultados.

O agrupamento é considerado uma técnica de aprendizado não supervisionado. O aprendizado é a capacidade de um agente melhorar sua performance com base em experiências passadas. Sobre o aprendizado e a diferença entre aprendizado supervisionado e não supervisionado, assinale a alternativa correta.

- 3)
- A) O aprendizado supervisionado se preocupa em dividir os dados em clusters únicos, enquanto o não supervisionado se preocupa em dividi-los em clusters de forma hierárquica.
 - B) O aprendizado supervisionado separa os dados em grupos conforme a densidade de uma vizinhança, delimitando os grupos de acordo com espaços menos densos. Já o aprendizado não supervisionado é uma abordagem que separa os dados em grupos hierárquicos.
 - C) O aprendizado supervisionado conta com um conjunto de dados em que já temos uma resposta correta esperada, chamada de rótulo, e treinamos nosso modelo com esses dados. Já

para o aprendizado não supervisionado, não temos nenhuma indicação da saída esperada para a função de nosso modelo.

4) O algoritmo k-means é um dos mais utilizados para a tarefa de agrupamento. Ele se baseia na distribuição de centroides em um espaço de dados e atribui a cada instância de dado um cluster com base nesses centroides. Sobre o objetivo da função de proximidade no algoritmo k-means, assinale a alternativa correta.

- A)** Calcular a distância de cada instância de dado do dataset para o centroide do cluster em cada iteração do algoritmo. A instância será alocada para o cluster em que tenha a menor distância para seu centroide.
- B)** Calcular a distância entre os centroides dos clusters.
- C)** Calcular a distância entre cada par de instância de dados.

5) O aprendizado é a capacidade de um agente melhorar sua performance por meio da análise de suas experiências passadas. Entre os algoritmos de aprendizado, um dos mais utilizados é o k-means, para encontrar clusters de dados em um dataset. Para a execução do k-means, não desejamos que nossos dados contenham um rótulo indicando a saída esperada do algoritmo. Sobre os dados não serem rotulados, assinale a alternativa correta.

- A)** O k-means é um algoritmo que utiliza uma estratégia de agrupamento hierárquica.
- B)** O k-means é um algoritmo não supervisionado cujo objetivo é justamente encontrar agrupamentos que possam indicar relações desconhecidas entre os dados.
- C)** Não é possível utilizar funções de proximidade em dados rotulados.

Experimento: Machine Learning: Agrupamento das Flores

Conteúdo interativo disponível na plataforma de ensino!

Pós-teste: Machine Learning (de fixação, não avaliativo)

1) O k-means é um algoritmo de agrupamento muito utilizado por sua simplicidade e bons resultados. É inicializado utilizando centroides aleatórios, que são atualizados a cada iteração do algoritmo. Qual é a condição de parada do algoritmo k-means?

- A) Quando os valores dos centroides chegam a zero.
- B) Após todos os dados serem atribuídos a algum cluster.
- C) Quando existe a convergência dos dados para os centroides, isto é, não há mudanças de clusters para nenhuma instância de dado.

2) Um dataset é um conjunto de dados em que podemos aplicar algoritmos de aprendizado de máquina para extrair novas informações relevantes. Um dataset muito famoso é o de flores íris. Nele, quando utilizamos algoritmos de agrupamento, idealmente queremos separar os dados em três clusters diferentes. Assinale a alternativa que contenha a razão correta para buscarmos esse número de clusters no dataset.

- A) Porque é um dataset em que cada instância tem três atributos.
- B) Porque existem três valores diferentes para o atributo tipo de flor.
- C) Porque é o número de iterações necessárias para o algoritmo convergir.

3) O k-means é um algoritmo de aprendizado não supervisionado utilizado para encontrar agrupamentos em um dataset. Sobre o algoritmo k-means, considere as afirmações a seguir:

- I. O algoritmo k-means busca maximizar a similaridade intragrupos e minimizar a intergrupos.
- II. O número de clusters é definido automaticamente.
- III. É um algoritmo de partição.

Qual(is) afirmação(ões) está(ão) correta(s)?

- A) Apenas I.
- B) Apenas II.
- C) Apenas I e III.

4) O dataset de flores íris é um dos mais tradicionais na área de aprendizado de máquina. Nele, cada instância de flor é descrita por cinco atributos: largura e comprimento de pétala, tamanho e comprimento de sépala e tipo de flor. O atributo tipo de flor é utilizado quando aplicamos algum algoritmo de aprendizado supervisionado. Porém, para algoritmos de aprendizado não supervisionado, como os de agrupamento, esse atributo não é considerado.

Assinale a alternativa que contenha a razão correta para não considerarmos o atributo tipo de flor em algoritmos de aprendizado não supervisionado.

- A)** O atributo tipo de flor é o rótulo do dado. Como a tarefa de agrupamento é uma técnica de aprendizado não supervisionado, não há necessidade de um rótulo.
- B)** Para melhorar o desempenho computacional do algoritmo k-means.
- C)** Porque é um atributo do tipo string.

5) Em aprendizado de máquina, existem várias técnicas adequadas para tarefas diferentes. Não existe uma única técnica que seja eficiente para qualquer tipo de problema. Para o caso do k-means, assinale a alternativa que contenha uma tarefa que ele é capaz de resolver.

- A)** Temos um conjunto de imagens anotadas com suas devidas classes e queremos gerar um modelo capaz de classificar novas imagens.
- B)** Temos uma base de dados de compradores e queremos segmentá-la em grupos de diferentes perfis.
- C)** Temos uma base de dados de compras em supermercados e queremos encontrar itens que são comprados juntos com frequência.

Atividade 2 (A2)

- 1) A análise multivariada de dados pode ser dividida em dois grupos de técnicas, as técnicas de dependência e as de interdependência.

Considerando esses dois grupos de técnicas, qual das alternativas a seguir conceitua corretamente as técnicas de dependência?

- A) Quando nenhuma variável ou grupo de variáveis for independente ou dependente, pois todas são analisadas simultaneamente para entender os padrões subjacentes dos dados.
- B) Quando uma variável ou conjunto de variáveis for identificado como a variável dependente a ser prevista ou explicada por outras variáveis conhecidas como variáveis independentes.
- C) Quando as variáveis dependentes forem as técnicas cujo modelo tentará prever ou explicar, e as variáveis independentes são aquelas estudadas a respeito do quanto elas afetam as variáveis dependentes.
- D) Quando as técnicas buscam descrever padrões nos dados sem realizar suposições sobre as variáveis, usando apenas intercorrelação estrutural das variáveis.
- E) Quando as técnicas dependem de uma outra técnica para conseguirem realizar análise sobre os dados, sendo que as variáveis são todas independentes entre si.

- 2) As técnicas de dependência buscam estabelecer um relacionamento de causa e efeito. Entre elas, existem as técnicas de regressão múltiplas e a técnica de correlação canônica.

Qual a principal diferença entre essas duas técnicas?

- A) A análise de regressão múltipla correlaciona simultaneamente diversas variáveis dependentes métricas e diversas variáveis independentes métricas, enquanto a correlação canônica envolve uma única variável dependente métrica e várias variáveis independentes métricas.
- B) A análise de regressão múltipla correlaciona simultaneamente diversas variáveis dependentes não métricas e diversas variáveis independentes não métricas, enquanto a correlação canônica envolve uma única variável dependente não métrica e várias variáveis independentes não métricas.
- C) A análise de regressão múltipla envolve diversas variáveis dependentes não métricas e uma variável independente não métrica, enquanto a correlação canônica envolve simultaneamente

diversas variáveis dependentes não métricas e diversas variáveis independentes não métricas.

- D) A análise de regressão múltipla envolve uma única variável dependente não métrica e várias variáveis independentes não métricas, enquanto a correlação canônica envolve simultaneamente diversas variáveis dependentes não métricas e diversas variáveis independentes não métricas.
 - E) A análise de regressão múltipla envolve uma única variável dependente métrica e várias variáveis independentes métricas, enquanto a correlação canônica envolve simultaneamente diversas variáveis dependentes métricas e diversas variáveis independentes métricas.
- 3) **As técnicas de análise multivariada ganharam muita evidência por permitirem que organizações criem conhecimento, melhorando, com isso, suas tomadas de decisão.**

Qual das seguintes alternativas conceitua corretamente uma análise multivariada de dados?

- A) É um conjunto de modelos estatísticos que busca descobrir se há uma relação entre duas variáveis diferentes.
- B) É a forma mais simples de análise de dados, por meio da qual os dados que estão sendo analisados contêm apenas três variáveis.
- C) É um conjunto de modelos estatísticos que examina padrões em dados multidimensionais, considerando, ao mesmo tempo, diversas variáveis de dados.
- D) É um conjunto de modelos estatísticos que examina padrões em dados multidimensionais, e consideram-se apenas as variáveis métricas.
- E) É um conjunto de modelos estatísticos que examina padrões em dados multidimensionais, e consideram-se apenas variáveis não métricas.

- 4) **Análises multivariadas são conceituadas de modo a efetuar uma aplicação bem-sucedida.**

Sobre esses conceitos, marque a resposta correta quanto ao que cada um faz:

- A) Existem dois conceitos em destaque: o conceito de variável estatística e o de escalas de medidas. Sobre o primeiro, as variáveis estatísticas combinam os dados de maneira não linear, enquanto as escalas de medida, outro conceito muito utilizado, são responsáveis por medir as variáveis dependentes e independentes.
- B) Existem dois conceitos em destaque: o conceito de variável estatística e o de escalas de medidas. Sobre o primeiro, as variáveis estatísticas combinam os dados de maneira não linear,

enquanto as escalas de medida, outro conceito muito utilizado, são responsáveis por medir as variáveis independentes.

- C) Existem dois conceitos em destaque: o conceito de variável estatística e o de escalas de medidas. Sobre o primeiro, as variáveis estatísticas combinam os dados de maneira linear, enquanto as escalas de medida, outro conceito muito utilizado, são responsáveis por medir as variáveis dependentes e independentes.
 - D) Existem dois conceitos em destaque: o conceito de variável estatística e o de escalas de medidas. Sobre o primeiro, as variáveis estatísticas são responsáveis por medir as variáveis dependentes e independentes, enquanto as escalas de medida, outro conceito muito utilizado, combinam os dados de maneira linear.
 - E) Existem dois conceitos em destaque: o conceito de variável estatística e o de escalas de medidas. Sobre o primeiro, as variáveis estatísticas são responsáveis por medir somente as variáveis dependentes, enquanto as escalas de medida, outro conceito muito utilizado, combinam os dados de maneira linear.
- 5) **Sabe-se que a visualização dos dados, dependendo da perspectiva, pode mostrar uma relação mais fiel aos dados lidos.**

Sobre a correlação de todos os atributos de uma base, qual o melhor tipo de representação dessa correlação?

- A) Para informar a correlação dos atributos, um gráfico em barras consegue apresentar essa correlação.
- B) A forma de representação denominada *heatmap* apresenta a correlação numérica entre os atributos da base.
- C) Formas de bicorrelação também apresentam dados numéricos de correlação.
- D) Gráficos com representações em densidade normalmente são utilizados para representar correlação numérica dos atributos.
- E) A forma de representação denominada *heatmap* não é uma boa representação, pois fornece apenas correlação entre dois atributos.