


PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Leandro Botelho Alves de Miranda



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Tratando *outliers* em Pandas e Numpy

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir *outliers*.
- Identificar *outliers* usando o método dos intervalos interquartis e *box-plots*.
- Determinar a remoção, ou não, de *outliers*, de acordo com as características da base de dados.

Introdução

A partir de alguns cenários em ciência de dados, a variabilidade ou dispersão dos dados univariados pode ser bastante esparsa. Isso geralmente acontece devido à presença de *outliers*. Para lidar com esse tipo de informação nos dados, é necessário que pesquisadores tenham conhecimento sobre a definição de *outliers* e como diferenciá-los de ruídos. Além disso, é importante o pesquisador saber identificar essas amostras, a partir de métodos como o do intervalo interquartil e de visualizações como *box-plots*.

Para este estudo, o método de Tukey está presente como estratégia de identificação. Após a detecção da presença de *outliers*, o pesquisador necessita identificar quando um *outlier* deve ser removido ou não de uma base de dados. Assim, a partir dos resultados do método de Tukey, o especialista de dados obtém o conhecimento necessário para a remoção dos *outliers* e o impacto dessa tarefa sobre os dados.

Neste capítulo, você vai estudar a definição de *outliers* e vai compreender como identificar *outliers* usando o método de intervalos interquartis e *box-plots*. Por fim, você vai verificar como determinar a remoção de *outliers* de acordo com as características do conjunto de dados.

1 *Outliers*

A **detecção de outliers** (FREEMAN, 1995) engloba aspectos de um amplo espectro de técnicas. Muitas técnicas empregadas para detectar *outliers* são fundamentalmente idênticas. A detecção de *outliers* tem sido usada há séculos para detectar e, quando apropriado, remover observações anômalas dos dados. *Outliers* surgem devido a falhas mecânicas, mudanças no comportamento do sistema, comportamento fraudulento, erro humano, erro do instrumento ou simplesmente por desvios naturais nas populações. Sua detecção pode identificar falhas e fraudes do sistema antes que aumentem, com consequências potencialmente catastróficas. Eles podem identificar erros e remover seu efeito contaminante no conjunto de dados e, assim, purificar os dados para processamento.

Os métodos originais de detecção de valores discrepantes eram arbitrários, mas, hoje, são usadas técnicas sistemáticas e baseadas em princípios, extraídas da ciência da computação e da área de estatística. A forma mais simples de detecção de valores discrepantes é uma análise de valor extremo de dados unidimensionais. Nesse caso, o princípio fundamental para descobrir *outliers* é determinar as caudas estatísticas da distribuição subjacente e assumir que valores muito grandes ou muito pequenos são *outliers*. Para aplicar esse tipo de técnica a um conjunto de dados multidimensional, a análise é realizada em uma dimensão de cada vez. Em tal análise multivariável, *outliers* são amostras que têm combinações incomuns com outras amostras no espaço multidimensional.

Um *outlier* é um ponto de dados diferente dos dados restantes. *Outliers* também são referidos como anormalidades, discordantes, desviantes e anomalias (AGGARWAL, 2015). Enquanto o **ruído** pode ser definido como exemplos errados (ruído de classe) ou erros nos valores dos atributos (ruído do atributo), *outlier* é um conceito mais amplo, que inclui não apenas erros, mas também dados discordantes, que podem surgir da variação natural dentro da população ou do processo. Assim, os *outliers* geralmente contêm informações interessantes e úteis sobre o sistema subjacente. Essas particularidades têm sido exploradas no controle de fraudes, nos sistemas de detecção de intrusão, na detecção de robôs na *web*, na previsão do tempo, na aplicação da lei e em diagnósticos médicos (FREEMAN, 1995).

2 Método do intervalo interquartil e *box-plots* para a identificação de outliers

Para um analista de dados, estudar a variabilidade dos dados é uma estratégia para detecção de *outliers*, especialmente quando os dados são sumarizados. Uma técnica para identificar valores discrepantes é o **método interquartil (IQ)**. O método IQ é uma técnica útil para descrever o comportamento dos dados. Sejam os quartis inferior e superior (definidos como o 25° e o 75° percentil), o quartil inferior é representado por Q1, o quartil superior é representado por Q3, e a diferença ($Q3 - Q1$) é chamada de **intervalo IQ** ou método do intervalo IQ, sendo também indicada por IQR.

O **gráfico box-plot** usa a mediana e os quartis inferior e superior, valores máximos e mínimos para a sua construção, como você pode ver na Figura 1. Um *box-plot* é construído desenhando-se um *box* (caixa) entre os quartis superior e inferior, com uma linha sólida desenhada através da caixa para localizar o mediano. As seguintes informações são necessárias para identificar valores extremos nas caudas da distribuição:

cerca interna inferior: $Q1 - 1,5 * IQ$

cerca interna superior: $Q3 + 1,5 * IQ$

cerca externa inferior: $Q1 - 3 * IQ$

cerca externa superior: $Q3 + 3 * IQ$




Figura 1. Diferentes partes do *box-plot*.

Um ponto além de uma cerca interna em qualquer lado é considerado um *outlier* moderado. Um ponto além de uma cerca externa é considerado um *outlier* extremo. É possível ter *outliers* com valores marginais razoáveis (ou seja, o valor “parece” normal quando se confina a uma dimensão), mas, devido a combinações lineares ou não lineares de atributos múltiplos, essas observações revelam padrões incomuns em relação ao resto da população. A remoção de todos os *outliers* possíveis e prováveis é referida como o método IQ, enquanto, no método de Tukey, apenas os *outliers* prováveis são descartados.



Saiba mais

Além de *box-plots*, gráficos como *scatterplots* e histogramas podem auxiliar na visualização de *outliers* em variáveis univariáveis.

O **método de Tukey** (BEYER, 1981) se aplica simultaneamente ao conjunto de todas as comparações de pares $\{\mu_i - \mu_j\}$. O **coeficiente de confiança** para o conjunto, quando todos os tamanhos de amostra são iguais, é exatamente $(1 - \alpha)$. Para tamanhos de amostra desiguais, o coeficiente de confiança é maior do que $(1 - \alpha)$. O método de Tukey considera todas as possíveis diferenças entre pares de médias ao mesmo tempo.

O método de Tukey usa a **distribuição de amplitude estudentizada** (*studentized range* — q). Suponha que temos (r) observações independentes $(y_1, \dots, y_r)$ de uma distribuição normal com média (μ) e variância (σ^2) . Suponha que (w) seja o intervalo desse conjunto, ou seja, o máximo menos o mínimo. Agora, suponha que temos uma estimativa (s^2) da variância (σ^2) que é baseada em (v) graus de liberdade e é independente de (y_i) . Assim, a amplitude estudentizada é:

$$q_{r,v} = \frac{w}{s}$$

Como exemplo, suponha $(r) = 5$ e $(v) = 10$. O 95° percentil é $(q_{0,05; 5, 10}) = 4,65$. Isso significa:

$$P \left\{ \frac{w}{s} \leq 4,65 \right\} = 0,95$$

Portanto, se tivermos cinco observações de uma distribuição normal, a probabilidade (P) é 0,95 de que seu intervalo não seja mais de 4,65 vezes maior do que uma estimativa de desvio padrão de amostra independente, para a qual o estimador tem 10 graus de liberdade.

Outliers em dados multivariados

Os métodos padrão e amplamente usados com base na distância consistem em calcular a **distância de Mahalanobis** (MCLACHLAN, 1999). Essa classe de métodos usa apenas o espaço de distância para sinalizar observações atípicas. A distância de Mahalanobis (MD) para a i -ésima observação é dada por:

$$MD_i = \sqrt{(x_i - \bar{x})^t - C^{-1}(x_i - \bar{x})}$$

sendo:

$$C = \frac{1}{n-1} X^t X$$

onde X é a matriz de dados de tamanho $n \times p$, em que p é o número de variáveis e n é o número de observações. Ainda, x_i é uma observação (uma linha de X), $\bar{x}$ é o vetor médio, e C é a matriz de covariância de amostra que fornece informações sobre a estrutura de covariância dos dados.

Para identificar candidatos *outlier*, MD^2 é calculado e comparado a um valor de corte igual ao quantil 0,975 da distribuição qui-quadrado, com m graus de liberdade, sendo m o número de variáveis. Isso vem do fato de que MD^2 de dados normais multivariados segue uma distribuição qui-quadrado. Portanto, uma observação é considerada como um candidato *outlier* se:

$$MD > \sqrt{(\chi)^2_{m,0.975}}$$



Fique atento


Pode-se observar que os tamanhos das amostras devem ser iguais ao se utilizar a abordagem da amplitude estudentizada.

3 Remoção de *outliers* na prática

Existem muitas técnicas para detectar *outliers*, e não existe uma abordagem única que funcione para todos os casos. Este capítulo descreve uma abordagem comumente útil baseada nos métodos IQ e Tukey para detecção de *outliers*, além do uso de *box-plots*. Como descrito na seção anterior, se houver um *outlier*, ele será plotado como um ponto no *box-plot*, mas a outra população será agrupada e exibida como caixas. Veja o código a seguir como exemplo.

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```

O gráfico da Figura 2 mostra três pontos entre 10 e 12 — estes são *outliers*, pois não estão incluídos na caixa de outra observação, ou seja, em nenhum lugar perto dos quartis. Aqui, você pode ver um *outlier* univariado — ou seja, a coluna DIS é apenas para verificar o *outlier*.



O gráfico de caixa usa o método IQR para exibir dados e *outliers* (formato dos dados). Porém, para obter uma lista de *outliers* identificados, precisaremos usar a fórmula matemática e recuperar os dados *outlier*. Vejamos como se pode usar o *box plot* e o IQR para encontrar a lista de *outliers*.

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```

Como agora temos as pontuações do IQR, é hora de controlar os valores discrepantes. No código a seguir, você pode ver um exemplo:

```
Q1 = boston_df.quantile(0.25)
Q3 = boston_df.quantile(0.75)
IQR = Q3 - Q1
print(IQR)
```

```
CRIM      3.595038
ZN        12.500000
INDUS     12.910000
CHAS      0.000000
NOX       0.175000
RM        0.738000
AGE       49.050000
DIS       3.088250
RAD       20.000000
TAX       387.000000
PTRATIO   2.800000
B         20.847500
LSTAT     10.005000
dtype: float64
```

O código a seguir cria um *dataframe* pandas com amostras que contêm *outliers* em suas variáveis.

```
df_outliers = boston_df[((boston_df < (Q1 - 1.5 * IQR)) | (boston_df > (Q3 + 1.5 * IQR))).any(axis=1)]
```

O código a seguir fornece uma saída com alguns valores verdadeiros e falsos. O ponto de dados em que temos False significa que esses valores são válidos, enquanto True indica a presença de um *outlier*.

```
(df_outliers < (Q1 - 1.5 * IQR)) | (df_outliers > (Q3 + 1.5 * IQR))
```


CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	
18	False	False	False	False	False	False	False	False	False	False	False	True	False
25	False	False	False	False	False	False	False	False	False	False	False	True	False
27	False	False	False	False	False	False	False	False	False	False	False	True	False
32	False	False	False	False	False	False	False	False	False	False	False	True	False
34	False	False	False	False	False	False	False	False	False	False	False	True	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...
477	True	False	False	False	False	False	False	False	False	False	False	False	False
478	True	False	False	False	False	False	False	False	False	False	False	False	False
479	True	False	False	False	False	False	False	False	False	False	False	False	False
489	False	False	False	False	False	False	False	False	False	False	False	True	False
490	False	False	False	False	False	False	False	False	False	False	False	True	False

232 rows x 13 columns

Agora que sabemos como detectar os *outliers*, é importante entender se eles precisam ser removidos ou corrigidos. A função a seguir retorna a variável univariada sem os *outliers*.

```
import numpy as np
def apagar_outlier(valores):

    factor = 1.5

    q3, q1 = np.percentile(valores, [75, 25])

    iqr = q3 - q1

    parte_baixa = q1 - (iqr * factor)

    parte_alta = q3 + (iqr * factor)

    return [v for v in valores if v > parte_baixa and v < parte_alta]
```

Caso queira identificar quais são os *outliers* e os seus respectivos índices em uma amostra univariada, veja a função abaixo. Neste exemplo, você pode ver os respectivos *outliers* para a variável `boston_df['DIS']`. O resultado nos mostra *outliers* que estão acima da cerca interna superior.

```
import numpy as np
def identificar_outlier(valores):

    factor = 1.5

    q3, q1 = np.percentile(valores, [75, 25])

    iqr = q3 - q1

    parte_baixa = q1 - (iqr * factor)

    parte_alta = q3 + (iqr * factor)

    return valores[(valores < parte_baixa) | (valores > parte_alta)]
```

```

outliers = identificar_outlier(boston_df['DIS'])
outliers

351      10.7103
352      10.7103
353      12.1265
354      10.5857
355      10.5857
Name: DIS, dtype: float64

```

Para a abordagem multivariada, você pode ver o uso da distância de Mahalanobis. Esta é a distância entre um ponto e uma distribuição, e não entre dois pontos distintos. É efetivamente um equivalente multivariado da distância euclidiana. A seguir, você pode ver um exemplo de código que implementa a distância de Mahalanobis.

Neste exemplo, é utilizada uma variável `mcd` que recebe uma matriz de covariância sem centralizar os dados. Ao utilizar a função `fit`, é calculada uma matriz com as distâncias de Mahalanobis em relação a todas as amostras do dataset. Depois, é feita uma ordenação de forma decrescente em relação às amostras utilizadas no estudo.

```

import glob
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.covariance import MinCovDet
%matplotlib inline

mcd = MinCovDet(assume_centered=True, random_state=42)
cov = mcd.fit(boston_df)
distancias = pd.DataFrame(cov.dist_, index=boston_df.index, columns=['Distancia Mahalanobis'])
resultados = pd.concat([boston_df, distancias], axis=1)
resultados.sort_values(by='Distancia Mahalanobis', ascending=False).head()

```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	Distância de Mahalanobis
380	88.9762	0.0	18.1	0.0	0.671	6.968	91.9	1.4165	24.0	666.0	20.2	396.90	17.21	6567160069
418	73.5341	0.0	18.1	0.0	0.679	5.957	100.0	1.8026	24.0	666.0	20.2	16.45	20.62	4446.383970
405	67.9208	0.0	18.1	0.0	0.693	5.683	100.0	1.4254	24.0	666.0	20.2	384.97	22.98	3596.353859
410	51.1358	0.0	18.1	0.0	0.597	5.757	100.0	1.4130	24.0	666.0	20.2	2.60	10.11	2123.012477
414	45.7461	0.0	18.1	0.0	0.693	4.519	100.0	1.6582	24.0	666.0	20.2	88.27	36.98	1563.509815

Esses valores indicam potencialmente amostras que apresentam um alto grau de distância em relação ao resto da distribuição. Consequentemente, há uma grande chance de essas amostras serem marcadas como *outliers*.



Referências

AGGARWAL, C. C. *Outlier analysis*. New York: Springer, 2015.

BEYER, H. Book review: TUKEY, J. W. *Exploratory data analysis*. Addison-Wesley Publishing Company Reading, Mass.—London, UK. *Biometrical Journal*, v. 23, n. 4, p. 413–414, 1981.

FREEMAN, J. Book selection: Outliers in statistical data (3rd edition). *Journal of the Operational Research Society*, v. 46, p. 1034–1035, 1995.

MCLACHLAN, G. Mahalanobis distance. *Resonance*, v. 4, p. 20–26, 1999.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS