

Apresentação

Vivemos em uma era marcada pelo uso intenso da tecnologia, em que grandes volumes de dados são gerados constantemente em diferentes áreas. Nesse contexto, técnicas de análise de dados tornam-se essenciais para interpretar informações, identificar padrões e apoiar a tomada de decisão. Entre essas técnicas, a **análise de componentes principais (PCA)** se destaca por reduzir a dimensionalidade dos dados, minimizando a perda de informações e facilitando sua interpretação em aplicações de aprendizagem de máquina.

Além disso, em ciência de dados, também é fundamental analisar valores que se distanciam de forma anormal do conjunto de observações, chamados de **outliers**. Esses valores podem aumentar a variabilidade dos dados e comprometer análises estatísticas. Para identificá-los, podem ser utilizados métodos como o **intervalo interquartis** e os **box-plots**, com apoio de ferramentas como a biblioteca **Pandas**. A partir dessa análise, é possível decidir pela remoção ou manutenção dos outliers, conforme as características da base de dados.

Bons estudos.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- Conceituar a análise de componentes principais (PCA).
- Descrever a metodologia da PCA.
- Identificar aplicações da PCA no contexto de aprendizagem de máquina.
- Definir outliers.
- Identificar outliers usando intervalo interquartis e box-plots.
- Determinar a remoção, ou não, de outliers conforme as características da base de dados.

Infográfico: Tratando outliers em Pandas e Numpy

Para o tratamento de *outliers* em um conjunto de amostras, o analista de dados precisa conhecer o comportamento da distribuição sob o conjunto de dados estudado. Para isso, é importante o uso de bibliotecas de visualização de dados, as quais permitem a compreensão dos resultados de forma mais clara.

Neste Infográfico, conheça o conceito de *outliers* para variáveis numéricas e o método de intervalo interquartil. Veja também como fazer a remoção de *outliers* por meio de códigos em Python.

OUTLIERS

Os *outliers*, também referidos, segundo Aggarwal (2015), como **anormalidades**, **discordantes**, **desviantes** e **anomalias**, representam um conjunto de amostras que estão distantes de uma distribuição de dados. Os valores discrepantes podem ter um efeito desproporcional nos resultados estatísticos, como a média, o que pode resultar em interpretações enganosas.



CAUSAS

Os *outliers* podem ter várias causas como:

Erro de medição ou entrada.

Corrupção de dados.

Valores discrepantes reais (desempenho acima do normal de um atleta).


IDENTIFICAÇÃO

Não há uma maneira precisa de definir e identificar *outliers* em geral devido às especificidades de cada conjunto de dados. Em vez disso, é preciso interpretar as observações brutas e decidir se um valor é atípico ou não.



MÉTODO INTERVALAR INTERQUANTIL E BOX-PLOTS

Para o uso do método interquartil, um *box-plot* informa, mais ou menos, sobre a distribuição dos dados, dando uma ideia do quanto eles estão realmente espalhados, o seu alcance e a sua distorção.



- ➔ **Mínimo:** valor mínimo no conjunto de dados.
- ➔ **Máximo:** valor máximo no conjunto de dados.
- ➔ **Diferença entre mínimo e máximo:** intervalo do conjunto de dados.
- ➔ **Mediana:** ponto central, também chamada de segundo quartil dos dados.
- ➔ **Q1:** primeiro quartil dos dados (25% dos dados estão entre o mínimo e Q1).
- ➔ **Q3:** terceiro quartil dos dados (75% dos dados estão entre o mínimo e Q3).
- ➔ **Diferença entre Q3 e Q1:** intervalo interquartil ou IQR.

Para detectar os *outliers* usando esse método, define-se um novo intervalo (intervalo de decisão), e qualquer ponto de dados fora desse intervalo é considerado como *outlier* e é devidamente tratado. O intervalo é o seguinte:

Limite inferior:
 $(Q1 - 1,5 * IQR)$

Limite superior:
 $(Q3 + 1,5 * IQR)$

Qualquer ponto de dados menor que o limite inferior ou maior que o limite superior é considerado um *outlier*.

REMOÇÃO DE OUTLIERS

Este exemplo de código em **Python** representa a remoção de *outliers*:

```
Q1 = dataset_df.quantile(0.25)
Q3 = dataset_df.quantile(0.75)
IQR = Q3 - Q1

dataset_df < (Q1 - 1.5 * IQR) | (dataset_df > (Q3 + 1.5 * IQR))
```

Em que `dataset_df` representa o *dataset* utilizado no experimento.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Tratando outliers em Pandas e Numpy

Os *outliers* são amostras muito presentes em análise de dados. Trata-se de uma observação que apresenta uma distância anormal em relação a outros valores, em uma amostra aleatória de um conjunto de dados.


Para se chegar a análises robustas, é importante a compreensão dos conceitos de *outliers*, desde a formulação matemática até a implementação de ferramentas para a detecção e a remoção de *outliers* utilizando bibliotecas em Python.

No capítulo Tratando *outliers* em Pandas e Numpy, da obra *Preparação e análise exploratória de dados*, base teórica desta Unidade de Aprendizagem, você estudará os *outliers*, sua identificação por meio do método do intervalo interquartis e *box-plots*, e sua remoção, ou não, de acordo com as características da base de dados.

Boa leitura.

PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Leandro Botelho Alves de Miranda



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Tratando *outliers* em Pandas e Numpy

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir *outliers*.
- Identificar *outliers* usando o método dos intervalos interquartis e *box-plots*.
- Determinar a remoção, ou não, de *outliers*, de acordo com as características da base de dados.

Introdução

A partir de alguns cenários em ciência de dados, a variabilidade ou dispersão dos dados univariados pode ser bastante esparsa. Isso geralmente acontece devido à presença de *outliers*. Para lidar com esse tipo de informação nos dados, é necessário que pesquisadores tenham conhecimento sobre a definição de *outliers* e como diferenciá-los de ruídos. Além disso, é importante o pesquisador saber identificar essas amostras, a partir de métodos como o do intervalo interquartil e de visualizações como *box-plots*.

Para este estudo, o método de Tukey está presente como estratégia de identificação. Após a detecção da presença de *outliers*, o pesquisador necessita identificar quando um *outlier* deve ser removido ou não de uma base de dados. Assim, a partir dos resultados do método de Tukey, o especialista de dados obtém o conhecimento necessário para a remoção dos *outliers* e o impacto dessa tarefa sobre os dados.

Neste capítulo, você vai estudar a definição de *outliers* e vai compreender como identificar *outliers* usando o método de intervalos interquartis e *box-plots*. Por fim, você vai verificar como determinar a remoção de *outliers* de acordo com as características do conjunto de dados.

1 *Outliers*

A **detecção de outliers** (FREEMAN, 1995) engloba aspectos de um amplo espectro de técnicas. Muitas técnicas empregadas para detectar *outliers* são fundamentalmente idênticas. A detecção de *outliers* tem sido usada há séculos para detectar e, quando apropriado, remover observações anômalas dos dados. *Outliers* surgem devido a falhas mecânicas, mudanças no comportamento do sistema, comportamento fraudulento, erro humano, erro do instrumento ou simplesmente por desvios naturais nas populações. Sua detecção pode identificar falhas e fraudes do sistema antes que aumentem, com consequências potencialmente catastróficas. Eles podem identificar erros e remover seu efeito contaminante no conjunto de dados e, assim, purificar os dados para processamento.

Os métodos originais de detecção de valores discrepantes eram arbitrários, mas, hoje, são usadas técnicas sistemáticas e baseadas em princípios, extraídas da ciência da computação e da área de estatística. A forma mais simples de detecção de valores discrepantes é uma análise de valor extremo de dados unidimensionais. Nesse caso, o princípio fundamental para descobrir *outliers* é determinar as caudas estatísticas da distribuição subjacente e assumir que valores muito grandes ou muito pequenos são *outliers*. Para aplicar esse tipo de técnica a um conjunto de dados multidimensional, a análise é realizada em uma dimensão de cada vez. Em tal análise multivariável, *outliers* são amostras que têm combinações incomuns com outras amostras no espaço multidimensional.

Um *outlier* é um ponto de dados diferente dos dados restantes. *Outliers* também são referidos como anormalidades, discordantes, desviantes e anomalias (AGGARWAL, 2015). Enquanto o **ruído** pode ser definido como exemplos errados (ruído de classe) ou erros nos valores dos atributos (ruído do atributo), *outlier* é um conceito mais amplo, que inclui não apenas erros, mas também dados discordantes, que podem surgir da variação natural dentro da população ou do processo. Assim, os *outliers* geralmente contêm informações interessantes e úteis sobre o sistema subjacente. Essas particularidades têm sido exploradas no controle de fraudes, nos sistemas de detecção de intrusão, na detecção de robôs na *web*, na previsão do tempo, na aplicação da lei e em diagnósticos médicos (FREEMAN, 1995).

2 Método do intervalo interquartil e *box-plots* para a identificação de outliers

Para um analista de dados, estudar a variabilidade dos dados é uma estratégia para detecção de *outliers*, especialmente quando os dados são sumarizados. Uma técnica para identificar valores discrepantes é o **método interquartil** (IQ). O método IQ é uma técnica útil para descrever o comportamento dos dados. Sejam os quartis inferior e superior (definidos como o 25° e o 75° percentil), o quartil inferior é representado por Q1, o quartil superior é representado por Q3, e a diferença ($Q3 - Q1$) é chamada de **intervalo IQ** ou método do intervalo IQ, sendo também indicada por IQR.

O **gráfico box-plot** usa a mediana e os quartis inferior e superior, valores máximos e mínimos para a sua construção, como você pode ver na Figura 1. Um *box-plot* é construído desenhando-se um *box* (caixa) entre os quartis superior e inferior, com uma linha sólida desenhada através da caixa para localizar o mediano. As seguintes informações são necessárias para identificar valores extremos nas caudas da distribuição:

cerca interna inferior: $Q1 - 1,5 * IQ$

cerca interna superior: $Q3 + 1,5 * IQ$

cerca externa inferior: $Q1 - 3 * IQ$

cerca externa superior: $Q3 + 3 * IQ$




Figura 1. Diferentes partes do *box-plot*.

Um ponto além de uma cerca interna em qualquer lado é considerado um *outlier* moderado. Um ponto além de uma cerca externa é considerado um *outlier* extremo. É possível ter *outliers* com valores marginais razoáveis (ou seja, o valor “parece” normal quando se confina a uma dimensão), mas, devido a combinações lineares ou não lineares de atributos múltiplos, essas observações revelam padrões incomuns em relação ao resto da população. A remoção de todos os *outliers* possíveis e prováveis é referida como o método IQ, enquanto, no método de Tukey, apenas os *outliers* prováveis são descartados.



Saiba mais

Além de *box-plots*, gráficos como *scatterplots* e histogramas podem auxiliar na visualização de *outliers* em variáveis univariáveis.

O **método de Tukey** (BEYER, 1981) se aplica simultaneamente ao conjunto de todas as comparações de pares $\{\mu_i - \mu_j\}$. O **coeficiente de confiança** para o conjunto, quando todos os tamanhos de amostra são iguais, é exatamente $(1 - \alpha)$. Para tamanhos de amostra desiguais, o coeficiente de confiança é maior do que $(1 - \alpha)$. O método de Tukey considera todas as possíveis diferenças entre pares de médias ao mesmo tempo.

O método de Tukey usa a **distribuição de amplitude estudentizada** (*studentized range* — q). Suponha que temos (r) observações independentes $(y_1, \dots, y_r)$ de uma distribuição normal com média (μ) e variância (σ^2) . Suponha que (w) seja o intervalo desse conjunto, ou seja, o máximo menos o mínimo. Agora, suponha que temos uma estimativa (s^2) da variância (σ^2) que é baseada em (v) graus de liberdade e é independente de (y_i) . Assim, a amplitude estudentizada é:

$$q_{r,v} = \frac{w}{s}$$

Como exemplo, suponha $(r) = 5$ e $(v) = 10$. O 95° percentil é $(q_{0,05; 5, 10}) = 4,65$. Isso significa:

$$P \left\{ \frac{w}{s} \leq 4,65 \right\} = 0,95$$

Portanto, se tivermos cinco observações de uma distribuição normal, a probabilidade (P) é 0,95 de que seu intervalo não seja mais de 4,65 vezes maior do que uma estimativa de desvio padrão de amostra independente, para a qual o estimador tem 10 graus de liberdade.

Outliers em dados multivariados

Os métodos padrão e amplamente usados com base na distância consistem em calcular a **distância de Mahalanobis** (MCLACHLAN, 1999). Essa classe de métodos usa apenas o espaço de distância para sinalizar observações atípicas. A distância de Mahalanobis (MD) para a i -ésima observação é dada por:

$$MD_i = \sqrt{(x_i - \bar{x})^t - C^{-1}(x_i - \bar{x})}$$

sendo:

$$C = \frac{1}{n-1} X^t X$$

onde X é a matriz de dados de tamanho $n \times p$, em que p é o número de variáveis e n é o número de observações. Ainda, x_i é uma observação (uma linha de X), $\bar{x}$ é o vetor médio, e C é a matriz de covariância de amostra que fornece informações sobre a estrutura de covariância dos dados.

Para identificar candidatos *outlier*, MD^2 é calculado e comparado a um valor de corte igual ao quantil 0,975 da distribuição qui-quadrado, com m graus de liberdade, sendo m o número de variáveis. Isso vem do fato de que MD^2 de dados normais multivariados segue uma distribuição qui-quadrado. Portanto, uma observação é considerada como um candidato *outlier* se:

$$MD > \sqrt{(\chi)^2_{m,0.975}}$$



Fique atento


Pode-se observar que os tamanhos das amostras devem ser iguais ao se utilizar a abordagem da amplitude estudentizada.

3 Remoção de *outliers* na prática

Existem muitas técnicas para detectar *outliers*, e não existe uma abordagem única que funcione para todos os casos. Este capítulo descreve uma abordagem comumente útil baseada nos métodos IQ e Tukey para detecção de *outliers*, além do uso de *box-plots*. Como descrito na seção anterior, se houver um *outlier*, ele será plotado como um ponto no *box-plot*, mas a outra população será agrupada e exibida como caixas. Veja o código a seguir como exemplo.

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```

O gráfico da Figura 2 mostra três pontos entre 10 e 12 — estes são *outliers*, pois não estão incluídos na caixa de outra observação, ou seja, em nenhum lugar perto dos quartis. Aqui, você pode ver um *outlier* univariado — ou seja, a coluna DIS é apenas para verificar o *outlier*.



O gráfico de caixa usa o método IQR para exibir dados e *outliers* (formato dos dados). Porém, para obter uma lista de *outliers* identificados, precisaremos usar a fórmula matemática e recuperar os dados *outlier*. Vejamos como se pode usar o *box plot* e o IQR para encontrar a lista de *outliers*.

```
import seaborn as sns
sns.boxplot(x=boston_df['DIS'])
```

Como agora temos as pontuações do IQR, é hora de controlar os valores discrepantes. No código a seguir, você pode ver um exemplo:

```
Q1 = boston_df.quantile(0.25)
Q3 = boston_df.quantile(0.75)
IQR = Q3 - Q1
print(IQR)
```

```
CRIM      3.595038
ZN        12.500000
INDUS     12.910000
CHAS      0.000000
NOX       0.175000
RM        0.738000
AGE       49.050000
DIS       3.088250
RAD       20.000000
TAX       387.000000
PTRATIO   2.800000
B         20.847500
LSTAT     10.005000
dtype: float64
```

O código a seguir cria um *dataframe* pandas com amostras que contêm *outliers* em suas variáveis.

```
df_outliers = boston_df[((boston_df < (Q1 - 1.5 * IQR)) | (boston_df > (Q3 + 1.5 * IQR))).any(axis=1)]
```

O código a seguir fornece uma saída com alguns valores verdadeiros e falsos. O ponto de dados em que temos `False` significa que esses valores são válidos, enquanto `True` indica a presença de um *outlier*.

```
(df_outliers < (Q1 - 1.5 * IQR)) | (df_outliers > (Q3 + 1.5 * IQR))
```

CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	
18	False	False	False	False	False	False	False	False	False	False	False	True	False
25	False	False	False	False	False	False	False	False	False	False	False	True	False
27	False	False	False	False	False	False	False	False	False	False	False	True	False
32	False	False	False	False	False	False	False	False	False	False	False	True	False
34	False	False	False	False	False	False	False	False	False	False	False	True	False
...	...	...	...	...	...	...	...	...	...	...	...	...	...
477	True	False	False	False	False	False	False	False	False	False	False	False	False
478	True	False	False	False	False	False	False	False	False	False	False	False	False
479	True	False	False	False	False	False	False	False	False	False	False	False	False
489	False	False	False	False	False	False	False	False	False	False	False	True	False
490	False	False	False	False	False	False	False	False	False	False	False	True	False

232 rows x 13 columns

Agora que sabemos como detectar os *outliers*, é importante entender se eles precisam ser removidos ou corrigidos. A função a seguir retorna a variável univariada sem os *outliers*.

```
import numpy as np
def apagar_outlier(valores):

    factor = 1.5

    q3, q1 = np.percentile(valores, [75, 25])

    iqr = q3 - q1

    parte_baixa = q1 - (iqr * factor)

    parte_alta = q3 + (iqr * factor)

    return [v for v in valores if v > parte_baixa and v < parte_alta]
```

Caso queira identificar quais são os *outliers* e os seus respectivos índices em uma amostra univariada, veja a função abaixo. Neste exemplo, você pode ver os respectivos *outliers* para a variável `boston_df['DIS']`. O resultado nos mostra *outliers* que estão acima da cerca interna superior.

```
import numpy as np
def identificar_outlier(valores):

    factor = 1.5

    q3, q1 = np.percentile(valores, [75, 25])

    iqr = q3 - q1

    parte_baixa = q1 - (iqr * factor)

    parte_alta = q3 + (iqr * factor)

    return valores[(valores < parte_baixa) | (valores > parte_alta)]
```

```

outliers = identificar_outlier(boston_df['DIS'])
outliers

351      10.7103
352      10.7103
353      12.1265
354      10.5857
355      10.5857
Name: DIS, dtype: float64

```

Para a abordagem multivariada, você pode ver o uso da distância de Mahalanobis. Esta é a distância entre um ponto e uma distribuição, e não entre dois pontos distintos. É efetivamente um equivalente multivariado da distância euclidiana. A seguir, você pode ver um exemplo de código que implementa a distância de Mahalanobis.

Neste exemplo, é utilizada uma variável `mcd` que recebe uma matriz de covariância sem centralizar os dados. Ao utilizar a função `fit`, é calculada uma matriz com as distâncias de Mahalanobis em relação a todas as amostras do dataset. Depois, é feita uma ordenação de forma decrescente em relação às amostras utilizadas no estudo.

```

import glob
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.covariance import MinCovDet
%matplotlib inline

mcd = MinCovDet(assume_centered=True, random_state=42)
cov = mcd.fit(boston_df)
distancias = pd.DataFrame(cov.dist_, index=boston_df.index, columns=['Distancia Mahalanobis'])
resultados = pd.concat([boston_df, distancias], axis=1)
resultados.sort_values(by='Distancia Mahalanobis', ascending=False).head()

```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	B	LSTAT	Distância de Mahalanobis
380	88.9762	0.0	18.1	0.0	0.671	6.968	91.9	1.4165	24.0	666.0	20.2	396.90	17.21	6567.160069
418	73.5341	0.0	18.1	0.0	0.679	5.957	100.0	1.8026	24.0	666.0	20.2	16.45	20.62	4446.383970
405	67.9208	0.0	18.1	0.0	0.693	5.683	100.0	1.4254	24.0	666.0	20.2	384.97	22.98	3596.353859
410	51.1358	0.0	18.1	0.0	0.597	5.757	100.0	1.4130	24.0	666.0	20.2	2.60	10.11	2123.012477
414	45.7461	0.0	18.1	0.0	0.693	4.519	100.0	1.6582	24.0	666.0	20.2	88.27	36.98	1563.509815

Esses valores indicam potencialmente amostras que apresentam um alto grau de distância em relação ao resto da distribuição. Consequentemente, há uma grande chance de essas amostras serem marcadas como *outliers*.



Referências

AGGARWAL, C. C. *Outlier analysis*. New York: Springer, 2015.

BEYER, H. Book review: TUKEY, J. W. *Exploratory data analysis*. Addison-Wesley Publishing Company Reading, Mass.—London, UK. *Biometrical Journal*, v. 23, n. 4, p. 413–414, 1981.

FREEMAN, J. Book selection: Outliers in statistical data (3rd edition). *Journal of the Operational Research Society*, v. 46, p. 1034–1035, 1995.

MCLACHLAN, G. Mahalanobis distance. *Resonance*, v. 4, p. 20–26, 1999.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Dica do Professor: Tratando outliers em Pandas e Numpy

Os *outliers* estão muito presentes em análises univariadas de dados. Essa representação gráfica está cada vez mais disponível, principalmente em linguagens de programação, como é o caso do Python.

Nesta Dica do Professor, aproveite para conhecer duas categorias de *outliers* e saber como identificá-las visualmente utilizando o mapa de *outliers*.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Saiba mais: Tratando outliers em Pandas e Numpy

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Outlier: o ponto fora da curva

Neste *link* , leia um estudo que apresenta uma visão geral dos *outliers*, desde a sua definição até exemplos práticos com Python.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Identificando e tratando *outliers* nos dados com Python

Acesse este *link* e saiba como lidar com *outliers* utilizando técnicas com Python.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Outliers: o que são e como tratá-los em uma análise de dados?

Entender os *outliers* é fundamental em uma análise de dados. Neste *site*, acompanhe apontamentos importantes sobre como detectá-los a partir de estatística descritiva.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Infográfico: Análise de componentes principais

Os dados estão presentes no nosso dia a dia em mensagens de texto ou na verificação de resultados de jogos, por exemplo. Esses dados são encontrados em qualquer forma, formato e tamanho, sendo números brutos e não estruturados que não têm significado algum sem que estejam ligados a um contexto, que pode transformá-los em informações que podem direcionar as decisões.

Dessa forma, um número elevado de informações é gerado, e, para analisá-lo por inteiro, informações importantes podem ser perdidas. Portanto, existem técnicas que podem ajudar a lidar com esse desafio: as técnicas de redução de dimensionalidade.

Neste Infográfico, você vai verificar as diferenças entre dois dos principais métodos de redução: a PCA e a análise fatorial (FA, do inglês *factor analysis*).

ANÁLISE DE COMPONENTES PRINCIPAIS x ANÁLISE FATORIAL

A análise de componentes principais (PCA, do inglês *principal components analysis*) e a análise fatorial (FA, do inglês *factor analysis*) são técnicas de redução de dimensionalidade muito utilizadas. As duas têm a mesma função: minimizar a perda de informações no reconhecimento de padrões.

Apesar de terem a mesma função principal, fundamentalmente elas apresentam diferenças, que você vai ver a seguir:



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

	Análise de componentes principais	Análise fatorial
Significado	Um componente pode ser definido como uma nova dimensão, em que variáveis derivadas são linearmente independentes umas das outras.	Um fator é um elemento comum, ou subjacente, em que diversas variáveis se correlacionam.
Função	A função da PCA é a decomposição dos dados em menores quantidades de componentes.	A análise fatorial tem como função entender como os fatores capturam grande parte das informações de um conjunto de variáveis nos dados presentes no conjunto de dados.
Suposição	Identifica dimensões compostas dos preditores observados.	Pressupõe que os fatores existem nos dados fornecidos.
Objetivo	Explicar o máximo possível de variância cumulativa nos preditores ou nas variáveis.	Explicar covariâncias, ou correlações, entre as variáveis.
Quanta variação é explicada?	A PCA é capaz de capturar a variância máxima em cada um dos componentes — ou seja, os componentes explicam toda a variação nos dados.	Como os fatores não são diretamente mensuráveis, não explicam toda variação no dados. Dessa forma, ocorre um termo de erro único para cada uma das variáveis medidas.
Processar	Componentes calculados como combinações lineares de variáveis originais.	Variáveis originais definidas como combinações lineares dos fatores.
Representações matemáticas	$Y = W_1 \times PC_1 + W_2 \times PC_2 + \dots + W_{10} \times PC_{10}$ Onde PC representa os componentes e W se refere ao peso de cada um dos componentes.	$X_1 = W_1 \times F + e_1$ $X_2 = W_2 \times F + e_2 \dots$ Onde F é referente ao fator, W aos pesos e e aos termos de erro, sendo o erro a variância em cada X, que não é explicada pelo fator.
Interpretação dos pesos	Pesos são a correlação entre os escores padronizados dos preditores, ou variáveis, e os componentes principais.	Na análise fatorial, os pesos são a relação ou associação de cada variável com o fator subjacente, podendo ser interpretados como coeficientes de regressão padronizados.
Estimativa dos pesos	Utiliza matriz de correlação de variáveis, gerando autovetores, estimando-os como os coeficientes.	Os pesos são determinados por meio do processo de análise fatorial.
Hierarquia	Primeiro, as variáveis são especificadas, e, depois, os pesos são estimados por meio da regressão.	Primeiro, são especificados os fatores, e, logo após, são estimados os retornos dos fatores com a regressão.

Ambas as técnicas, PCA e FA, são responsáveis pela redução dos dados de dimensões superiores para o espaço dimensional inferior, sem que o conteúdo da informação da variância dos dados seja perdido.



Apesar de haver semelhanças, essa comparação mostrou as principais diferenças entre esses dois métodos. A escolha de qual dos dois utilizar dependerá das necessidades do usuário: quando o objetivo é reduzir os preditores correlacionados em um conjunto menor, utiliza-se a PCA; já se o objetivo for entender e testar a presença de fatores latentes que causam variação nos dados, deve-se utilizar a FA.

Conteúdo do Livro: Análise de componentes principais


Os dados dominam os negócios. Com a evolução tecnológica, as formas de comunicação e execução de processos mudaram completamente, migrando praticamente tudo para o digital. Dessa forma, milhões de dados são gerados por segundo, dados esses que podem conter inúmeras informações sobre acontecimentos ou padrões de comportamento, por exemplo.

A maioria dos conjuntos de dados disponíveis contém um alto número de variáveis, e devem ser encontrados jeitos de explicar a relação entre essas variáveis. Sendo assim, deve-se reduzir a dimensionalidade do conjunto de dados, de modo a obter um menor número de variáveis que sejam capazes de explicar o máximo de informações possíveis, e isso é o que a PCA faz.

No capítulo **Análise de componentes principais**, base teórica desta Unidade de Aprendizagem, você vai estudar a PCA, de modo a conhecer e compreender os principais conceitos e as características que permeiam essa técnica. Além disso, você vai conhecer os cálculos que podem ser utilizados para a execução dessa análise de dados e, por fim, vai entender a sua aplicabilidade na prática.

Boa leitura.

APRENDIZADO DE MÁQUINA



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Análise de componentes principais

Juliane Soares

OBJETIVOS DE APRENDIZAGEM

- > Conceituar análise de componentes principais.
- > Descrever a metodologia da análise de componentes principais.
- > Identificar aplicações da análise de componentes principais no contexto de aprendizagem de máquina.

Introdução

Vivemos numa era em que o mundo evolui constantemente e de diversas formas, onde novos dispositivos e tecnologias surgem a cada dia, seja no âmbito pessoal ou profissional. O mundo digital tomou uma grande proporção, de modo que áreas como comunicação, processos organizacionais, saúde, educação, formas de armazenamento de dados, envio de documentos, pesquisas, compras, entre muitas outras mudaram completamente e adotaram o espaço cibernético.

Diante disso, uma grande quantidade de dados digitais é gerada por segundo e esses dados são de extrema importância para entender acontecimentos e reconhecer padrões de comportamento de usuários, além de outras questões mais focadas em determinadas áreas. No entanto, como os conjuntos de dados disponíveis geralmente apresentam uma ampla gama de variáveis, uma saída analítica é reduzir a dimensionalidade desses conjuntos para extrair informações

importantes concentradas no menor número possível de variáveis, sendo esse o papel da análise de componentes principais (*principal component analysis* — PCA).

Neste capítulo, você vai entender o que é a PCA, seus conceitos e características importantes. Além disso, conhecerá os principais cálculos envolvidos no processo da PCA e onde essa técnica pode ser aplicada.

Conceitos básicos

O reconhecimento de padrões e a compressão de dados são aplicações que dependem diretamente de uma representação de dados eficiente. O reconhecimento de padrões é responsável pela decisão sobre quais classes de objetos pertencem a um padrão observado, enquanto a compressão de dados é utilizada de modo a poupar o número de bits durante a representação de certos dados, a fim de garantir sua menor distorção possível durante o processo e nos resultados. Assim, o intuito é a extração de medidas invariantes ou insensíveis às variações dentro de cada classe, em que tal processo de extração é chamado de extração de características. Também é possível definir a extração de características como um processamento de dados responsável pelo mapeamento de um espaço de alta dimensão em um espaço de baixa dimensão com perda mínima de informação (KONG; HU; DUAN, 2017).

Dessa forma, a PCA é uma das mais utilizadas técnicas de extração de características. Nesse contexto, os componentes principais são as direções em que ocorrem as maiores variações de dados, sendo capturada a maior parte do conteúdo de informações desses dados, correspondendo, assim, aos autovetores associados aos maiores autovalores da matriz de autocorrelação dos vetores de dados (KONG; HU; DUAN, 2017).

O método PCA é utilizado para identificar o menor número de variáveis não correlacionadas a partir de um maior conjunto de dados. O PCA enfatiza a variação e captura padrões fortes no conjunto de dados analisado. Sendo assim, a PCA é muito usada em modelos preditivos e análise exploratória de dados, e pode ser considerada um método estatístico muito útil para compressão de imagens, reconhecimento facial, neurociência e computação gráfica.

A PCA é capaz de tornar os dados mais aptos a exploração e visualização. Com esse método não paramétrico, é possível extrair informações de conjuntos de dados muito complexos e confusos, em que seu foco é a quantidade máxima de variância com o menor número de componentes principais. Uma das principais vantagens associadas a esse método é que, assim que os padrões são encontrados nos dados analisados, a compactação desses dados

também é suportada. Dessa forma, ele é utilizado para eliminação do número de variáveis ou do número de preditores quando há uma quantidade elevada comparada ao número de observações, ou ainda para evitar a ocorrência de multicolinearidade.



Saiba mais

A multicolinearidade ocorre quando algumas variáveis preditoras estão correlacionadas a outras variáveis preditoras, ou seja, quando existem fatores redundantes.

A PCA está ligada à análise de correlação canônica — que explica a relação entre dois conjuntos de variáveis por meio de combinações lineares — e utiliza transformação ortogonal para a conversão de um conjunto de observações que contenham variáveis correlacionadas com os componentes principais. É importante ressaltar que o número de componentes principais usados na PCA deve ser menor ou igual ao menor número de observações. Além disso, a PCA tem sensibilidade ao dimensionamento relativo às variáveis originais em questão.

Muitas áreas em que são gerados grandes conjuntos de dados, como pesquisa de mercado, indústrias e ciências sociais, utilizam a PCA, principalmente porque essa técnica ajuda a proporcionar uma imagem de menor dimensão dos dados originais, reduzindo um conjunto de dados complexos a um conjunto de informações simples e úteis, sendo necessário um esforço mínimo para análise dos componentes.

A base da análise de dados multivariada, fundamentada em métodos de projeção, é a PCA. Dessa forma, seu uso mais importante é a representação de uma tabela de dados multivariada com um menor conjunto de variáveis, de modo que seja possível observar tendências, saltos, agrupamentos e pontos fora da curva. Em outras palavras, a PCA encontra estatisticamente linhas, planos e hiperplanos no espaço dimensional, aproximando os dados da melhor forma possível no sentido de mínimos quadrados. Linhas ou planos podem ser definidos como a aproximação de mínimos quadrados de um conjunto de dados que torna a variância das coordenadas na linha ou no plano a maior possível (TALEBI, 2021).

A Figura 1 mostra a redução da dimensionalidade e da redundância comparando as variáveis originais e com os resultados pós-PCA, de tal modo que as variáveis originais são combinadas para maximizar a variância. Assim, um novo eixo é definido no espaço de entrada, e ao longo de tal eixo a variância é

maximizada. Nessa técnica, é fundamental a escala automática, que significa que se deve subtrair a média ao longo de cada variável, dividindo pelo seu desvio-padrão. Dessa forma, o centro de cada novo eixo corresponde à média. Matematicamente, equivale à realização de uma decomposição autovetor da matriz de covariância definida pelas variáveis originais (TALEBI, 2021).




Figura 1. Visualização do método PCA.

Fonte: Talebi (2021, documento *on-line*).



Saiba mais

Para melhor compreensão da PCA, é importante conhecer os termos a seguir.

- **Variância:** usada para cálculo da variação dos pontos de dados que são distribuídos em um gráfico de dimensionalidade.
- **Covariância:** estima o grau em que componentes de alguns conjuntos de dados agrupados se movem numa mesma direção. É usada para identificar dependências e relações entre as características dos conjuntos de dados.
- **Autovetor (*eigenvector*):** usado para a compreensão das alterações nos dados. O autovetor também pode ser definido como expansão de um gráfico X-Y sem que as direções sejam alteradas.
- **Autovalor (*eigenvalue*):** indica a variância numa direção específica.
- **Componentes principais:** novo conjunto de variáveis de dados que são coletadas do conjunto de dados original. Os componentes de dados são extremamente significativos e independentes e possuem todas as informações importantes das variáveis originais.

Em resumo, os componentes principais apresentam as seguintes propriedades:

- são um conjunto de variáveis de dados primários projetadas em diferentes direções e apresentam as principais propriedades das variáveis originais;
- são utilizados em aprendizado de máquina e ciência de dados para reduzir dimensionalidade;
- são ortogonais;
- ao ordenarem os componentes principais, o primeiro sempre deverá ter a maior variância e o último, a menor.

Metodologia

O funcionamento da PCA ocorre de forma simples e direta: recebe um conjunto de dados como entrada e retorna um conjunto novo reconstruído igualmente. No novo conjunto de dados formado, os recursos (componentes) não são correlacionados. Além disso, os componentes que possuem mais informações aparecem no início do conjunto, ou seja, ao somar o valor informativo dos dados, pode ocorrer de alguns componentes expressarem até 95% da informação original. Dessa forma, é possível utilizar apenas esses poucos componentes para uma análise, pois eles equivalem aos dados originais, mas de maneira compacta, removendo redundâncias e reduzindo o número de recursos em geral (MUELLER; MASSARON, 2016).

A PCA é uma técnica matemática que pode ser chamada de autoanálise, em que são resolvidos autovetores e autovalores de uma matriz quadrada simétrica, com somas de quadrados e produtos cruzados. O autovetor associado ao maior autovalor apresenta a mesma direção que o primeiro componente principal; já o autovetor associado ao segundo autovalor determina a direção do segundo componente principal. Assim, ao somar os autovalores, se dará o traço da matriz quadrada, bem como o número máximo de autovetores representa o número de linhas ou colunas.



Fique atento

Os autores Paul, Suman e Sultan (2013) afirmam que o primeiro componente extraído numa PCA representa uma quantidade máxima de variância total nas variáveis analisadas, enquanto o segundo componente apresenta duas características importantes: a primeira é que este componente

é o responsável por uma quantidade máxima de variância no conjunto de dados não contabilizado pelo primeiro componente; a segunda característica é que não existe correlação entre o primeiro e o segundo componente. Sobre o restante dos componentes extraídos na análise, cada um responde por uma variância máxima nas variáveis não contabilizadas pelos componentes anteriores e também não apresentam correlação com os primeiros componentes.

Vejamos então um passo a passo da metodologia de uma PCA, de acordo com Jaadi (2021) e Vasconcelos ([200-?]). O primeiro passo para uma PCA é a obtenção do conjunto de dados a ser analisado. Obtendo o conjunto de dados, é preciso atentar à padronização do intervalo das variáveis iniciais contínuas, de modo que elas contribuam de forma igualitária para a análise. A questão é que a PCA é sensível às variâncias das variáveis iniciais, o que significa que, caso haja grandes diferenças entre os intervalos das variáveis iniciais, as com maiores intervalos dominarão aquelas que apresentam intervalos menores, levando a resultados tendenciosos.

Sendo assim, antes de padronizar o conjunto de dados, é necessário calcular a média e o desvio-padrão para cada recurso. A média pode ser obtida pela seguinte equação:

$$\bar{x} = \left(\frac{x_1 + x_2 + x_3 \dots + x_n}{n} \right)$$

Já o cálculo do desvio-padrão pode ser visto na fórmula a seguir, onde x_i é valor individual, $\bar{x}$ é a média e n é número de valores:

$$\sigma = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$$

Por fim, chegamos a seguinte equação de padronização:

$$z = \frac{x - \bar{x}}{\sigma}$$

A partir disso, é preciso calcular a matriz de covariância. O objetivo dessa etapa é compreender como as variáveis do conjunto de dados de entrada variam da média entre si, verificando se existe alguma relação entre elas. Variáveis altamente correlacionadas contêm informações redundantes. A matriz

de covariância é uma matriz simétrica $d \times d$, em que d se refere ao número de dimensões e tem como entradas as covariâncias associadas aos pares possíveis das variáveis iniciais. Considerando um conjunto tridimensional com três variáveis (w , x e y), a matriz fica da seguinte forma:

$$M = \begin{bmatrix} \text{Cov}(w, w) & \text{Cov}(w, x) & \text{Cov}(w, y) \\ \text{Cov}(x, w) & \text{Cov}(x, x) & \text{Cov}(x, y) \\ \text{Cov}(y, w) & \text{Cov}(y, x) & \text{Cov}(y, y) \end{bmatrix}$$

A diagonal principal da matriz mostra a variância de cada variável inicial, já que calcular a covariância entre uma dimensão e ela mesma resulta na variância ($\text{Cov}(x, x) = \text{Var}(x)$). Cabe ressaltar que covariância é sempre medida entre duas dimensões. A equação a seguir mostra como calcular a covariância:

$$\text{Cov}(w, x) = \frac{\sum_{i=1}^n [(w_i - \bar{w}) \cdot (x_i - \bar{x})]}{n}$$

onde w e x são listas de dados, $\bar{w}$ e $\bar{x}$ são os valores das médias dessas listas e w_i e x_i são cada um dos elementos da lista na i -ésima posição, sendo n o número de itens de dados obtidos.

Esse cálculo de covariância deve ser feito entre cada par de dimensões para formar a matriz de covariância. O sinal da covariância é o ponto que importa na matriz: caso seja positivo, as duas variáveis estão correlacionadas, aumentando ou diminuindo juntas; caso seja negativo, elas são inversamente correlacionadas, ou seja, uma aumenta enquanto a outra diminui.

A partir da matriz de covariância, é possível determinar os componentes principais dos dados. Isso é feito por meio dos cálculos de autovetores e autovalores. Esses valores sempre vêm em pares, de forma que cada autovetor tem um autovalor. Os autovetores são os responsáveis por determinar as direções dos eixos onde há maiores informações, que são os componentes principais, enquanto os autovalores determinam a quantidade de variância transportada em cada componente principal.

Assim, consideremos que M é a nossa matriz de covariância, v um vetor e λ um escalar que satisfaz $Mv = \lambda v$, sendo então λ um autovalor associado ao autovetor v de M . Dessa forma, a equação fica:

$$Mv - \lambda v = 0 ; (M - \lambda I)v = 0$$

onde I é matriz de identidade, M a matriz dada e os escalares não nulos, λ , que resolvem a questão serão os autovalores.

No entanto, como v é um vetor diferente de 0, a equação a seguir só pode ser igual a 0 se:

$$\det(M - \lambda I) = 0$$

Em seguida, os autovalores devem ser classificados em ordem decrescente, sendo o primeiro autovalor o primeiro componente principal, e assim por diante. Após a definição dos componentes principais, para que a porcentagem da variância seja calculada por cada componente, deve-se dividir o autovalor de cada um dos componentes pela soma dos autovalores.

Por fim, é o responsável pela análise que define quantos componentes principais serão mantidos, se todos ou se os de menor significância serão descartados, considerando a perda de informações contidas nos componentes descartados. Assim, com os componentes principais restantes é formada a matriz de vetores.

Aplicação

A principal aplicação da PCA é a redução de dimensionalidade de um conjunto de dados, de modo que a maior parte da variação existente nos dados seja capturada num número reduzido de dimensões. Dessa forma, esse método pode ser usado para as mais variadas formas de análises, em diferentes áreas. Em geral, podemos destacar as seguintes aplicações mais significativas do PCA:

- **Neurociência:** nessa área existe uma técnica de análise de covariância acionada por pico que utiliza uma variante da PCA, que identifica propriedades específicas de um estímulo que levam ao aumento da probabilidade de que um neurônio gere um potencial de ação. Além disso, a PCA também é utilizada para encontrar a identidade de um neurônio partindo da forma de seu potencial de ação. Como técnica de redução de dimensionalidade, a PCA também detecta atividades coordenadas de grandes conjuntos neuronais, determinando os parâmetros de ordem durante as transições de fase no cérebro.
- **Finanças quantitativas:** nessa área a PCA pode ser utilizado para diferentes questões, como:

- redução de dimensionalidade de problemas complexos;
 - análise da forma da curva de juros;
 - cobertura de carteiras de renda fixa;
 - implementação de modelos de taxas de juros;
 - previsão de retornos de portfólio;
 - desenvolvimento de algoritmos de alocação de ativos;
 - desenvolvimento de algoritmos de negociação de ações compradas e vendidas.
- **Compressão de imagem:** uma das principais aplicações da PCA é a compressão de imagens. Como o objetivo da PCA é reduzir a dimensionalidade de dados para reconhecimento de padrões com baixa perda de informações, na compressão de imagens ela serve como um algoritmo de compressão de baixas perdas, mantendo a qualidade da imagem o mais próxima da original.
 - **Reconhecimento facial:** a PCA pode ser usada em coleta de imagens de rostos, de modo a permitir que se forme um conjunto de recursos básicos. O conjunto de Eigenfaces, algoritmo usado para reconhecimento facial, é gerado utilizando PCA, de maneira que essa abordagem reduz a complexidade estatística numa representação de imagens faciais.

Para compreender um pouco mais esse processo, veremos uma PCA aplicada na evolução temporal da covid-19 a partir de um modelo sugerido por Nobi, Tuhin e Lee (2021). A PCA foi aplicada às séries temporais diárias dos casos de óbito por covid-19 e casos confirmados para os 25 principais países, considerando o período entre abril de 2020 e fevereiro de 2021, buscando compreender a rapidez com que o vírus foi transmitido nesses países durante esse período.

Os dados de casos e óbitos foram analisados em janelas de um mês. Os países em questão foram: Estados Unidos (US), Índia (IND), Brasil (BRA), Reino Unido (UK), Rússia (RUS), França (FRA), Espanha (SPA), Itália (ITA), Turquia (TUR), Alemanha (GER), Colômbia (COL), Argentina (ARG), México (MEX), Polônia (POL), Irã (IRN), África do Sul (SAF), Ucrânia (UKR), Indonésia (INDO), Peru (PER), República Tcheca (CZE), Holanda (NETH), Canadá (CAN), Chile (CHI), Portugal (POR) e Romênia (ROMA).

O primeiro passo dessa análise foi a descrição de autovalores e autovetores correspondentes das matrizes de correlação de casos e óbitos confirmados. Nesse caso, foram analisados somente os dois primeiros autovalores, o maior

e o segundo maior, bem como seus autovetores correspondentes. As mudanças dinâmicas no primeiro e segundo autovalores de casos confirmados e óbitos por covid-19 em janelas temporais de um mês são apresentados na Figura 2.




Figura 2. Mudanças no primeiro e segundo autovalores de óbitos e casos confirmados de covid-19.

Fonte: Adaptada de Nobi, Tuhin e Lee (2021).

O valor mais elevado dos maiores autovetores mostra a semelhança entre países mais afetados. Além disso, na Figura 2 é possível observar que os valores mais altos para primeiros autovalores encontram-se em abril de 2020, quando o vírus se espalhou mundialmente. Os maiores autovalores para casos da doença inicial começam a diminuir até junho e, a partir de julho há uma crescente flutuante. Porém, os primeiros autovalores para os óbitos diminuem até agosto e, após isso, ocorre aumento flutuante até fevereiro de 2021. Isso mostra que os óbitos aumentam e se correlacionam entre os países. Ao fazer uma comparação entre os primeiros autovalores de casos e de óbitos, nota-se que, de abril a junho de 2020, a dinâmica de óbitos é mais forte que a de casos e, depois desse período, o maior autovalor de óbitos é inferior ao de casos de julho a novembro, sendo muito semelhantes a dezembro. Em fevereiro de 2021, ocorre um cruzamento

entre óbitos e casos, indicando que casos de óbito foram mais graves nesse mês. Já os segundos autovalores de óbitos e casos aumentam de abril a setembro e são muito próximos ao primeiro autovalor de óbitos em setembro. Na maior parte do período analisado, o segundo autovalor de casos é maior que o de óbitos.

Por sua vez, a Figura 3 apresenta seguintes informações sobre o primeiro autovetor para casos de óbito, o segundo autovetor para casos de óbito, o primeiro autovetor para casos confirmados e o segundo autovetor para casos confirmados. O eixo horizontal mostra o mês do último ponto de dados de cada janela de tempo. O eixo vertical representa os países afetados. As áreas sombreadas em marrom indicam autovetores dominantes de diferentes países afetados.




Figura 3. Componentes de autovetores: (a) primeiro autovetor para casos de óbito; (b) segundo autovetor para casos de óbito; (c) o primeiro autovetor para casos confirmados; (d) o segundo autovetor para casos confirmados.

Fonte: Nobi, Tuhin e Lee (2021, documento *on-line*).

Na Figura 3, é possível observar um mapa do calor que mostra o quanto os componentes dos autovetores desses países dominam no primeiro e segundo autovetores. No primeiro autovetor de óbitos, os componentes mais influentes aparecem para Estados Unidos, Brasil, Rússia, Reino Unido, Itália, México e Irã em diferentes períodos de junho a novembro, conforme as áreas sombreadas em marrom nas Figuras 3a e 3c. Por sua vez, componentes menos influentes aparecem para os dez países mais pobres, sendo indicados em azul, entre outras interpretações. Já o primeiro autovetor para casos confirmados pode ser observado para a maior parte dos países em períodos diferentes de maio a abril, conforme pode ser visto na Figura 3c. Nas Figuras 3b e 3d estão representados os componentes de autovetor que correspondem ao segundo maior autovalor, os quais, para casos e óbitos, são muito maiores que os primeiros; no entanto, contribuem significativamente em poucos períodos, como revelam as áreas sombreadas em amarelo e vermelho. O segundo autovetor de óbitos é mais significativo do que o de casos confirmados, em que componentes de óbitos nos Estados Unidos e na África do Sul são os que dominam em outubro e abril, respectivamente.

A Figura 4 mostra os gráficos de dispersão dos coeficientes dos dois primeiros componentes principais, em que foram considerados somente períodos em que as dinâmicas de grupo são significativas. É possível observar que os países estão mais agrupados nas parcelas de carregamento quando os estados das doenças são semelhantes e graves entre os países.




Figura 4. Gráficos de dispersão dos coeficientes do primeiro componente principal (PC1) e do primeiro componente principal (PC2) dos 25 países estudados.

Fonte: Adaptada de Nobí, Tuhin e Lee (2021).

A dinâmica de grupo no plano do primeiro componente principal (PC1) e do segundo (PC2) é mostrada na Figura 4, em que as correlações entre componentes principais e a mudança normalizada de óbito ou casos confirmados são conhecidos como coeficientes de PC. Os coeficientes de PC são utilizados para medir os pontos fortes da relação entre países e componentes principais e para determinar qual país contribui mais em dois componentes principais. Quanto maior a contribuição de um país em componentes principais, maior é a gravidade das doenças. Foram projetados os dois primeiros coeficientes de PC em espaços bidimensionais para determinar onde os países estão localizados, de modo a fornecer informações adicionais sobre a gravidade das doenças. O PC1 define as variâncias máximas dos dados na direção do maior autovetor e o PC2 representa as variâncias na direção do segundo autovetor.

Ao longo do tempo, é possível observar que ocorreram mudanças nos grupos devido às alterações de gravidades da doença em diferentes países. Na Figura 4a estão os países Estados Unidos, Reino Unido, Itália, Espanha, França, Turquia, Alemanha, Irã, Canadá, República Tcheca, Holanda e Polônia, sendo a maioria deles americanos e europeus. Esse gráfico indica que tais países são os que mais contribuem para os dois componentes principais, bem como mostra condições críticas nessas regiões causadas pela covid-19 em abril de 2020.

Passando para o mês de outubro, nas Figuras 4e e 4f, observa-se que mais de dez países formam um grande *cluster* para casos confirmados e também ocorrem outros pequenos *clusters*. Entretanto, os pontos estão distantes em geral, o que indica estados variados da doença. Grupos críticos para casos e óbitos se dividiram em dois e três grandes grupos nesse mês, conforme pode ser visto na figura. Cabe ressaltar que nos dois grandes *clusters* para casos e óbitos estão países europeus, indicando que se encontravam em situações semelhantes, enquanto países americanos estavam no outro *cluster* maior em grupo de óbitos.

Quando os países se encontram distantes da origem, isso indica que no período em questão eles enfrentaram momentos críticos da doença. Em fevereiro, nas Figuras 4g e 4h, os países que representaram os piores cenários para a covid-19 foram Estados Unidos, Reino Unido, Canadá, Rússia, Colômbia, Portugal, Indonésia e África do Sul. Para os óbitos, existem dois grupos críticos, próximos um ao outro, e contêm países da América, Ásia e Europa. Enquanto isso, nesse mesmo período Irã, França, Espanha e Argentina fazem parte de um grupo próximo à origem, ou seja, representam bons cenários para a covid-19.

No início da progressão da doença, a maioria dos países contribuiu igualmente para os dois primeiros componentes principais. Porém, com o passar do tempo formaram-se diferentes grupos, de acordo com a gravidade da doença em cada momento e em cada país, principalmente porque alguns deles conseguiram reduzir a gravidade da doença por meio de contramedidas. Os países distantes da origem e próximos uns dos outros contribuem igualmente para os dois componentes principais e são considerados grupos-chave. Por sua vez, os grupos críticos são afetados pelo aumento da doença de forma desproporcional. Com isso, foi possível identificar os países que foram afetados mais gravemente pela covid-19. A técnica de PCA aplicada nesse caso é importante para conhecer a relação entre os países afetados e estabelecer uma previsão para a transmissão de doenças num futuro próximo.

Neste capítulo, foi possível compreender como a PCA funciona e como traz importantes informações diante de um cenário com muitas variáveis, diminuindo a dimensionalidade a ponto de permitir que seja feita uma análise completa utilizando apenas as principais variáveis, e ainda assim conseguindo obter uma visão da questão como um todo.

Referências

- JAADI, Z. A Step-by-step explanation of Principal Component Analysis (PCA). *Builtin*, 2021. Disponível em: <https://builtin.com/data-science/step-step-explanation-principal-component-analysis>. Acesso em: 17 mar. 2022.
- KONG, X.; HU, C.; DUAN, Z. *Principal component analysis network and algorithms*. Springer: Beijing, 2017.
- MUELLER, J. P.; MASSARON, L. *Machine learning for dummies*. Hoboken: John Wiley Sons, 2016.
- NOBI, A.; TUHIN, K. H.; LEE, J. W. Application of Principal Component Analysis on Temporal Evolution of COVID-19. *PLOS ONE*, v. 16, n. 12, e0260899, 2021. Disponível em: <https://doi.org/10.1371/journal.pone.0260899>. Acesso em: 17 mar. 2022.
- PAUL, L. C.; SUMAN, A. A.; SULTAN, N. *Methodological analysis of Principal Component Analysis (PCA) method*. Bangladesh: IJCEM, 2013.
- TALEBI, S. Principal Component Analysis (PCA). *Towards Data Science*, 2021. Disponível em: <https://towardsdatascience.com/principal-component-analysis-pca-79d228eb9d24>. Acesso em: 17 mar. 2022.
- VASCONCELOS, S. *Análise de Componentes Principais (PCA)*. [S. l.: s. n., 200-?]. Disponível em: <http://www.ic.uff.br/~aconci/PCA-ACP.pdf>. Acesso em: 17 mar. 2022.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integridade das informações referidas em tais *links*.

Conteúdo:



Dica do Professor: Análise de componentes principais

Os dados estão presentes desde que o mundo é mundo, e, com a evolução tecnológica, cada vez mais dados digitais são gerados. A partir desses dados, é possível obter inúmeras informações e reconhecer padrões. No entanto, por se tratar de enormes quantidades de dados, faz-se necessária a diminuição da dimensionalidade dos conjuntos de dados, para que eles sejam analisados de maneira correta, com a menor perda de informações possível durante o processo. É isso que a PCA faz atualmente.

Mas, até a PCA chegar ao que é hoje, foram realizados muitos estudos, que iniciaram na década de 1870. Nesta Dica do Professor, você vai conhecer um pouco sobre a história da PCA.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Atividade 3 (A3)

- 1) A compressão de dados e o reconhecimento de padrões são aplicações que estão relacionadas de modo direto com uma representação de dados eficiente, tendo como objetivo a extração de medidas insensíveis às variações em cada classe. A PCA é uma das técnicas de extração de características mais usadas.

A respeito da PCA, leia as afirmações a seguir:

I. O método PCA é usado para reconhecer um maior número de variáveis que não estejam correlacionadas.

II. Os componentes principais do método PCA são as direções em que acontecem as maiores variações de dados.

III. O método PCA destaca a variação e captura os padrões mais fracos no conjunto de dados que foi analisado.

Quais afirmações são verdadeiras?

A) I, II e III.

B) I e II.

C) III, apenas.

D) II, apenas.

E) I e III.

- 2) A PCA pode deixar os dados mais fáceis de serem explorados e visualizados. Com esse método, poderão ser extraídas informações de conjuntos de dados bastante complexos e confusos, com o objetivo de obter a quantidade máxima de variância com o menor número de componentes principais.

A respeito das vantagens da PCA, considere as seguintes afirmações e classifique-as em verdadeiras (V) ou falsas (F):

() A compactação dos dados é suportada logo que os padrões são descobertos nos dados analisados.

() Uma das vantagens da PCA é ser insensível ao posicionamento relativo das variáveis originais.

() O método PCA é capaz de aproximar os dados da maneira mais viável para os mínimos quadrados.

() A principal utilização da PCA é para a representação de tabelas de dados que sejam univariadas.

Assinale a alternativa que indica a sequência correta:

A) V – V – V – F.

B) F – F – V – V.

C) V – F – V – F.

D) V – F – F – F.

E) F – V – F – V.

- 3) O procedimento da análise de componentes principais tem o seu funcionamento de maneira simples e direta, sendo que é recebido um conjunto de dados como entrada, retornando, então, um conjunto novo e reconstruído igualmente.

A respeito do funcionamento da análise de componentes, leia as afirmações a seguir:

I. Os componentes do conjunto de dados novo que foi formado permanecem correlacionados entre si.

II. No conjunto de dados novo, os componentes com mais informações estão no início do conjunto de dados.

III. Os recursos do novo conjunto de dados na análise de componentes principais não são relacionados.

Quais afirmações são verdadeiras?

A) II e III.

B) I, apenas.

C) I, II e III.

D) III, apenas.

E) I e II.

4)

Em uma análise de componentes principais, o primeiro passo a ser executado para essa análise é estabelecer o conjunto de dados em que será aplicada a análise, e, depois de obtido o conjunto de dados, deverão ser realizados os demais passos que fazem parte da metodologia.

A respeito da metodologia de uma PCA, considere as seguintes afirmações e classifique-as em verdadeiras (V) ou falsas (F):

() Quando existe muita diferença entre os intervalos das variáveis iniciais, as variáveis com intervalos menores serão dominadas pelas com intervalos maiores.

() O cálculo da média e do desvio-padrão para cada um dos recursos precisa ser necessariamente feito após a padronização do conjunto de dados.

() O cálculo da matriz de covariância tem como finalidade o entendimento da forma como as variáveis do conjunto de dados de entrada variam da média.

Assinale a alternativa que indica a sequência correta:

A) V – V – V.

B) V – F – V.

C) F – F – V.

D) F – V – F.

E) V – F – F.

5) Dentro das etapas da metodologia da PCA, tem-se a realização do cálculo da matriz de covariância, sendo que a matriz de covariância é uma matriz simétrica. A partir da matriz de covariância, pode-se determinar os componentes principais dos dados.

A respeito da determinação dos componentes principais dos dados, leia as afirmações a seguir:

I. Os componentes principais dos dados são estabelecidos com base na matriz de covariância, com o cálculo de autovetores.

II. Cada autovetor terá um autovalor que o acompanha, portanto, os autovetores e os autovalores sempre formarão pares.

III. Os eixos que têm maiores informações, que são os componentes principais, são estabelecidos pelos autovetores.

Quais afirmações são verdadeiras?

- A) I e II.
- B) III, apenas.
- C) I, II e III.
- D) II e III.
- E) I, apenas.

Saiba mais: Análise de componentes principais

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Análise dos componentes principais das características e composição das carcaças de cordeiros pantaneiros e comerciais

Esta dissertação apresenta uma PCA que foi realizada com o objetivo de encontrar e identificar as melhores variáveis para explicar características e composição das carcaças de cordeiros pantaneiros e comerciais.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Análise de componentes principais em *data warehouses*

Esta dissertação trata sobre a construção de uma interface de programação de aplicação (API) que tem como objetivo permitir a aplicação da PCA em modelos de dados multidimensionais, integrando-a com ambientes de *data warehouse*.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Análise multivariada: componentes principais

Neste vídeo, acompanhe uma aula sobre a teoria dos componentes principais, sobre como realizar a PCA no *software* R e sobre como tais resultados podem ser interpretados. Por fim, é explicado como a análise de componentes principais pode ser aplicada em estudos de regressão e de dissimilaridade.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.