

Apresentação

Com o crescimento das empresas e o avanço tecnológico, a quantidade de dados gerados aumenta continuamente, tanto em formatos estruturados quanto não estruturados. Nesse cenário, a análise de dados torna-se essencial para transformar dados em informações úteis, apoiar decisões e gerar vantagem competitiva.

A análise exploratória de dados permite identificar padrões, compreender informações relevantes e representar melhor os dados analisados. Já a **self-service analytics** amplia esse processo ao possibilitar que usuários obtenham insights com mais autonomia, agilidade e eficiência.

Nesta Unidade de Aprendizagem, você estudará os conceitos, a importância e as etapas da análise exploratória de dados, além do papel do autoatendimento na busca de insights e na melhoria dos resultados analíticos.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- Definir o processo de análise exploratória de dados.
- Descrever as etapas da análise exploratória.
- Reconhecer a importância da análise exploratória.
- Reconhecer o papel do autoatendimento na análise de dados.
- Aplicar técnicas de busca de insights.
- Apontar estratégias de autoatendimento.

Infográfico: Análise exploratória de dados

Usar um conjunto de dados de baixa qualidade pode levar a conclusões enganosas, quando submetidas a um projeto preditivo. Cada algoritmo de *machine learning* tem sensibilidades diferentes para classes ou distribuições desbalanceadas. Se esses tratamentos não forem abordados, o resultado dessa análise pode ser errado ou inválido.

A análise exploratória de dados (AED) é um processo que tem como responsabilidade tratar e manter a qualidade do conjunto de dados a serem submetidos a uma análise.

Veja, no Infográfico a seguir, uma das etapas mais importantes na AED, o tratamento dos dados em relação aos valores ausentes, à normalização de valores e aos *outliers*.

TRATAMENTO DE DADOS NA ANÁLISE EXPLORATÓRIA DE DADOS (AED)

Uma das etapas mais importantes na AED é o tratamento em relação aos dados ausentes, normalização de valores e outliers.

A seguir são detalhados esses processos:

VALORES AUSENTES

Tipos de tratamento para resolver esse problema:



Recorrer ao processo em que a informação é gerada e tentar recuperá-la.

Alterar o valor ausente por um valor substituto. Existem várias formas para se fazer *imputation*, são elas:



- a) *Educated guessing*: Não é uma das formas mais utilizadas, basicamente infere-se o valor ausente de acordo com o padrão existente nos dados.
- b) *Average imputation*: Utiliza-se o valor médio da coluna (para as observações que têm valor) e se atribui esse valor para as observações que têm valor ausente.
- c) *Common-point imputation*: Nessa, técnica os valores ausentes são substituídos por valores padrão ou que mais se repetem.
- d) *Regression substitution*: Cria-se um modelo de regressão múltiplo para estimar os valores ausentes.
- e) *Multiple imputation*: Estende o conceito do uso da regressão com a identificação de correlações com os valores ausentes.

NORMALIZAÇÃO DE VALORES

Deixar todos os valores numéricos em uma escala comum, sem distorcer as diferenças no intervalo de valores, ou seja, transformar um conjunto de dados que estão em diferentes grandezas e escalas em um conjunto de dados padronizados.



TRATAMENTO DE OUTLIERS

É um valor atípico, que apresenta um grande afastamento dos demais valores da série, ou que é inconsistente, ou seja, identificar registros com comportamento fora do comum e analisá-los de acordo com o interesse.



É uma estratégia para melhorar ou adequar o conjunto de dados obtidos.

Os resultados de uma pesquisa podem ser fortemente comprometidos devido ao fato de as pessoas se sentirem constrangidas e não quererem responder determinadas questões.



Para essas situações, precisa-se definir quais técnicas serão utilizadas para preencher essa informação faltante.



Pode-se optar por descartar a pessoa que tenha pelo menos uma variável faltante

OU

pode-se preencher o dado faltante com técnicas de imputação de dados, onde o dado pode ser substituído por um valor como a média, a repetição do último valor ou com uma regressão linear.

FATORES SECUNDÁRIOS

Os fatores secundários são os seguintes:

Técnicas de imputação

As técnicas utilizadas dependem dos tipos dos dados faltantes, por isso é importante avaliar os dados que não foram informados.



Normalização de valores

Deve ser possível retornar aos valores originais após os mesmos serem normalizados.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Análise exploratória de dados


Em um projeto analítico, uma das partes mais importantes é a qualidade dos dados, os quais são submetidos a algoritmos preditivos. A atividade de coleta, organização, tratamento e análise dos dados faz parte da análise exploratória de dados (AED). Definir o escopo desses dados, por amostragem ou população, bem como trabalhar com dados qualitativos, quantitativos ou ambos, faz parte dessa exploração de dados.

No capítulo Análise exploratória de dados, da obra *Preparação e análise exploratória de dados*, veja os conceitos relacionados e as etapas da análise e reconheça os objetivos e importância de uma análise exploratória de dados.

Boa leitura.

PREPARAÇÃO E ANÁLISE EXPLORATÓRIA DE DADOS

Rafael Gastão Coimbra Ferreira



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS



Análise exploratória de dados

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir o processo de análise exploratória.
- Descrever as etapas de uma análise exploratória.
- Reconhecer os objetivos e importância de uma análise exploratória de dados.

Introdução


As empresas cada vez mais procuram armazenar um grande volume de dados. Novas tecnologias de armazenamento surgiram e ganharam espaço, permitindo a representação de uma grande variedade de informações ditas não estruturadas, ou seja, não necessariamente com um formato único de representação e de uma única origem. Ambientes heterogêneos, a exemplo da *web*, permitiram sua manipulação e, consequentemente, seu cruzamento, gerando uma nova ciência de dados. Somada aos conceitos da matemática, a análise de dados fornece resultados confiáveis e consistentes.

Entretanto, essa ciência de dados também é baseada no valor gerado pelos métodos estatísticos e algoritmos, que ajudam na descoberta de padrões nos dados. Um único método de acesso e análise de dados não vai gerar os resultados esperados. O segredo em uma análise de dados eficiente é, por meio de uma análise exploratória desses dados, realizar uma atividade de observação mais de uma vez e por diferentes perspectivas.

Neste capítulo, você vai estudar os conceitos relacionados à análise exploratória de dados e ver suas etapas relevantes e sua importância, quando realizada antes de o conjunto de dados ser submetido a uma análise mais profunda, por meio de técnicas e ferramentas de investigação. Essa análise permite realizar a tentativa e erro, uma etapa importante dessa ciência.

1 Análise exploratória de dados

Hoje cada vez mais temos acesso a dados dos mais variados tipos e formatos. Além disso, a quantidade de dados com acesso à informação vem aumentando. Para um projeto de ciência de dados (*data science*), é necessário tratar e analisar os dados brutos até se transformarem em informação. O uso correto dessa informação a transforma em conhecimento, e o ato de utilizarmos esse conhecimento em benefício da tomada de decisão gera o conhecimento como sabedoria. A Figura 1 apresenta uma pirâmide com as diferentes etapas de transformação do dado.



Os dados obtidos para um projeto preditivo não chegam em pacotes prontos e formatados para análise. Os dados brutos variam substancialmente em formato e é necessário transformar todas as fontes de dados de modo que a análise possa ser feita. Uma transformação nos dados pode envolver mudanças nos tipos de dados existentes ou até mesmo na criação de dados (algo como corrigir erros) baseada nos dados existentes.

A finalidade da **análise exploratória de dados (AED)** é verificar os dados para qualquer aplicação estatística. Com isso, obtemos entendimento sobre os dados coletados e, principalmente, sobre as relações existentes entre as variáveis analisadas. O Quadro 1 apresenta as estratégias utilizadas em diferentes abordagens estatísticas, incluindo a AED.

Quadro 1. Abordagens estatísticas e estratégias utilizadas

Abordagem	Estratégia
Estatística clássica	Problema → Dados → Modelo → Análise
Estatística bayesiana	Problema → Dados → Modelo Priori → Análise
AED	Problema → Dados → Análise → Modelo

Fonte: Adaptado de Capítulo... ([2011]).

Você pode observar que as estatísticas clássica e bayesiana geram um modelo e depois fazem a análise dos dados. Já a AED faz a análise dos dados por meio de mineração antes de indicar o modelo a ser utilizado. A AED tenta olhar para os dados de forma mais profunda sem resumir muito a quantidade de informações.

Classificação dos dados

Em uma análise exploratória os dados são considerados como variáveis, a exemplo de peso, altura, sexo e idade de determinado indivíduo. Tais variáveis podem representar diferentes valores, como valores numéricos e valores não numéricos.

Valores numéricos, também conhecidos como **valores quantitativos**, podem ser representados de duas formas: por valores inteiros, chamados de **discretos**, ou por valores no intervalo de números reais, chamados de **contínuos**. Utilizando os exemplos citados, *idade* seria um exemplo de valor quantitativo discreto e *peso* seria um exemplo de valor quantitativo contínuo.

Valores não numéricos, conhecidos como **valores qualitativos**, podem ser tratados como valores **nominais**, quando suas categorias de dados não seguem uma ordem natural — por exemplo, valores relacionados ao *nome*, *cor* e *raça* do indivíduo. Para categorias de valores ordenados, a exemplo da *classe social* (baixa, média e alta) ou *tamanho de uma roupa* (pequeno, médio e grande), se tem o tipo de valor qualitativo **ordinal**.

Técnicas gráficas e resumos numéricos

Gráficos são utilizados para representar informações quantitativas, pois são visualmente mais intuitivos para o leitor. Os gráficos são construídos a partir de dados em formato tabular. O objetivo principal dos gráficos é dar uma visão mais rápida e fácil dos dados a que se referem. Já uma tabela fornece uma ideia mais precisa dos dados e de como eles podem ser tratados.

A Figura 2 apresenta uma tabela com as quantidades vendidas de cada produto e um gráfico com as mesmas informações. Perceba que fica muito mais fácil visualizar que a laranja foi o produto mais vendido, uma vez que 200 do total de 830 vendas (isto é, 24,09%) foram deste produto. A qualidade na representação gráfica deve estar focada na clareza, simplicidade e autoexplicação. As técnicas gráficas desempenham um papel fundamental na AED, pois, como visto na Figura 1, é a partir da análise dos dados que se indica o modelo a ser utilizado.





Figura 2. Tabela de vendas x gráfico de vendas.

Para Gabriel Stankevix ([2020]), a análise exploratória dos dados é considerada a principal etapa da análise dos dados. Ela inclui um processo de organizar, resumir, aplicar alguns cálculos e resumir as informações em um formato adequado à visualização.

2 Etapas de uma análise exploratória de dados

Segundo Navidi (2012), uma amostra é uma longa lista de valores. Para destacar as características dessa amostra, normalmente se calculam algumas medidas estatísticas. As mais comuns dessas medidas são a média amostral e o desvio padrão amostral. A **média amostral** indica onde esses dados estão centralizados, e o **desvio padrão** fornece uma indicação de quão dispersos estão esses dados. A estatística descritiva é composta das medidas estatísticas calculadas.

A **estatística descritiva** consiste em interpretar os dados, visualizá-los e após relacioná-los com as variáveis. Ela está diretamente relacionada com os objetivos da pesquisa e é composta por etapas, conforme apresenta a Figura 3.



O trabalho da AED é geralmente dividido em várias etapas: coleta, organização, tratamento, análise, apresentação e interpretação dos dados. Ressalta-se neste ponto que a estatística descritiva está, portanto, fortemente relacionada com o processo de AED, uma vez que as etapas de organização, tratamento, análise e apresentação de dados utilizam técnicas descritivas. Compreender as etapas dessa análise orienta sua realização de forma correta. A seguir serão detalhadas cada uma dessas etapas.

Coleta e organização de dados

Na etapa de coleta de dados, deve-se definir quais serão os métodos de coleta utilizados. Inicialmente, são definidos os objetivos, ou seja, as questões da pesquisa; depois disso, define-se quais dados serão coletados e como serão coletados.

A organização dos dados consiste em estabelecer como obter informações a partir dos dados coletados a respeito de uma ou mais características de interesse. É muito importante levar em consideração a natureza dos dados. Por exemplo, em uma base de dados, existem dados que devem ser coletados em diferentes colunas de uma tabela — digamos, uma data de nascimento, na qual os valores do dia, mês e ano estão em colunas separadas — e devemos unificar esses dados para unificar a informação.

Tratamento de dados

A etapa de tratamento dos dados visa a melhorar ou adequar o conjunto de dados obtidos. Os resultados de uma pesquisa podem ser fortemente comprometidos devido ao fato de as pessoas se sentirem constrangidas e não quererem responder determinada questão, a exemplo da renda familiar, orientação sexual, religião. Para essas situações, é necessário definir qual solução será adotada. No exemplo da informação faltante, pode-se optar por descartar a pessoa que tenha pelo menos uma variável faltante, ou pode-se preencher o dado faltante com técnicas de **imputação de dados**, nas quais o dado pode ser substituído por um valor, como a média ou a repetição do último valor, ou por uma regressão linear. É muito importante observar que as técnicas de imputação dependem do tipo de dado faltante.

O objetivo da normalização de valores é deixar todos os valores numéricos em uma escala comum sem distorcer as diferenças no intervalo de valores, ou seja, transformar um conjunto de dados que estão em diferentes grandezas e escalas em um conjunto de dados padronizados.

Ainda existe nessa etapa o tratamento de *outliers*, que é considerado um valor extremo, ou seja, são valores que fogem da média dos demais valores. Um *outlier* nada mais é que uma observação que está muito distante do padrão observado naquele conjunto de dados, e pode ser causado por entrada errada de dados ou erros em tempo de tratamento. De qualquer forma, os *outliers* terão impacto em uma análise. Como solução, pode-se realizar sua remoção, seu tratamento individual ou sua transformação.



Fique atento

Para tratar os *outliers* é importante analisar bem o problema em questão e montar um modelo preditivo, entendendo se o *outlier* faz parte da necessidade para atender ao problema, ou se deve ser descartado para não prejudicar os resultados a serem atingidos. Por exemplo, em uma análise de crédito, você avalia a movimentação bancária de determinado correntista e percebe um valor de crédito muito alto na conta, fora da média de valores creditados mensalmente. Se o problema proposto é a análise de fraude, esse *outlier* será útil, ou seja, se o objetivo é detectar anomalias na conta corrente, o que se deseja detectar, na verdade, são os *outliers*. Entretanto, se o problema proposto é analisar o comportamento do perfil de cliente com relação a seus créditos em conta corrente, tal *outlier* vai distorcer os valores e deve ser removido.

Análise de dados

Para a etapa de análise dos dados, podem ser realizadas as análises univariada, multivariada e de correlações. A **análise univariada** consiste em avaliar cada uma das variáveis isoladamente. A ideia é conhecer o comportamento de cada variável por meio de sua classificação como qualitativa (ordinal ou nominal) ou quantitativa (contínua ou discreta). Assim, o objetivo é analisar a ocorrência de seus possíveis valores, e o resultado é a definição de sua frequência de possíveis valores.



Exemplo

Em uma análise da variável *idade*, podemos obter, em uma coleta de dados, os seguintes valores: {18, 19, 18, 21, 21, 18}. A frequência dessa variável *idade* seria assim definida: {18 — 3 ocorrências, 19 — 1 ocorrência e 21 — 2 ocorrências}.

Já a **análise multivariada** estabelece relações entre duas ou mais variáveis. Por exemplo, a altura da pessoa mediante o sexo e a idade.

As correlações ocorrem quando dois acontecimentos, os quais não necessariamente são causalidades, tendem a ocorrer de forma sincronizada. Por exemplo, a inflação alta tende a aumentar o desemprego. Outro exemplo é o seguinte: se um cliente almoça todos os dias no mesmo restaurante, a tendência é que as variáveis “frequência semanal de almoço” e “satisfação com a comida” estejam relacionadas.

Apresentação e interpretação de dados

Para Medri (2011) existem duas formas de realizar a etapa de apresentação dos dados: por meio de uma apresentação tabular ou de uma apresentação gráfica. A **apresentação tabular** é a representação usando uma tabela, que deve ter alguns elementos essenciais, como título da tabela, títulos das colunas e corpo com o conjunto dos dados.

Já a **representação gráfica** deve ser autoexplicativa e de fácil compreensão. Existem diferentes tipos de gráficos para cada uma das variáveis que se quer representar, a exemplo dos gráficos de colunas, barras, linhas, setores, entre outros.

Essa etapa é uma das mais importantes, visto que serão apresentados os dados obtidos. Para isso deve-se escolher a melhor maneira de apresentar esses dados, seja tabular, seja por meio de gráficos, porém os gráficos escolhidos devem ser os adequados para os tipos de dados obtidos, como dados quantitativos ou qualitativos. Por exemplo: a variável *estado civil*, classificada como qualitativa nominal, permite ter a frequência de vezes que cada categoria aparece (casado = 26, solteiro = 18, separado = 8). Neste caso, o melhor tipo de gráfico para sua representação é o gráfico de barra.

A Figura 4 mostra a variável *estado civil* representada por um gráfico de radar. Perceba que fica evidente que tal escolha não é a melhor forma de sua representação, pois esse tipo de gráfico não deixa clara a correlação existente entre os valores da variável *estado civil* e sua frequência obtida.

Estado Civil	Frequência
Casado	26
Solteiro	18
Separado	8




Figura 4. Gráfico de radar.

A partir da apresentação dos dados, a etapa de interpretação dos dados permite definir o modelo a ser aplicado para o problema em questão. Como apresentado no Quadro 1, iniciamos com a análise dos dados para depois definir o modelo a ser utilizado.



Fique atento

Antes de começar a usar algoritmos, é importante você entender a estrutura dos dados que tem em mãos — por exemplo, presença de valores ausentes, distribuição de variáveis, correlação, desvio-padrão, etc.

Essas etapas servem como um roteiro para evitar que dados mal coletados, sem curadoria ou aplicados sem muito critério, possam introduzir distorções nas aplicações de aprendizado de máquina (*machine learning*). Um bom exemplo dessa distorção pode ser o uso do algoritmo de classificação chamado de KNN (*K-nearest neighbors*). A ideia desse algoritmo é poder classificar os valores, permitindo que novos valores possam ser classificados mediante o cálculo de K-vizinhos mais próximos. Agora, considere que, em uma coleta de dados com indivíduos para uma variável *sexo*, você obtém os seguintes valores: *M*, *F* e *10*. Os valores *M* e *F* representam a categoria válida, mas o valor *10* passa a ser um valor fora da escala. Se esse valor não for corrigido,

o algoritmo não encontrará uma boa relação entre os dados e, com isso, o resultado apresentado nos dados de treino será ruim.



Saiba mais

A aprendizagem de máquina (*machine learning*) é uma subárea da inteligência artificial. Trata-se do processo de uma máquina conseguir aprender sozinha a realizar determinada tarefa sem ter sido programada explicitamente para isso.

3 Objetivos e importância de uma análise exploratória de dados bem feita

A AED é uma etapa importante para um projeto de *analytics*, pois quebra a ideia de que *data science* é apenas a execução de algoritmos e que deve envolver apenas conceitos de aprendizado de máquina ou técnicas complexas para agregar valor. Toda fase de um projeto de *data science* pede uma análise exploratória, a qual permite entender o dado, conhecer as suas relações e extrair diversos *insights*. Uma AED bem feita possibilita encontrar tendências e extrair valor nos dados, incluindo o conhecimento.

Uma base de dados, quando submetida a uma análise, pode conter diferentes problemas, como dados ausentes (*missing values*), valores discrepantes, valores truncados, dados corrompidos ou dados incompletos. Um exemplo disso pode ser visto na Figura 5, que mostra uma base de dados para registrar a alocação de casas, considerando os seguintes dados: identificador, rua, número da casa, *status* de alocação, quantidade de quartos e banheiros.

Missing values						
Linha	ID	Rua	Nº	Alocada	Quartos	Banheiros
1	100		21	Sim	3	2
2	200	Rua João Vicente	33	222	4	3
3	300	Av João da Silva V	567	Não	1	1

Corrompido

Figura 5. Dados com erro.

Um erro de dado ausente (*missing value*) pode ser observado na linha 1, para a coluna *Rua*. Já a coluna *Alocada*, linha 2, contém um dado corrompido de tipo inteiro, uma vez que a coluna é representada por valor *string*. Neste caso, evidencia-se o que chamamos de ruído, pois esse campo apenas deve ser representado pelos valores *Sim* e *Não*. O objetivo desta etapa como um todo é avaliar uma base de dados e mapear os dados com erros, assim como tratar esses problemas.

Não resolver valores discrepantes, ou seja, valores inteiros em *string* e vice-versa, gera um problema de erro genérico de *string*, quando submetido a um algoritmo de aprendizado de máquina. A AED permite ajustar os dados para que possam ser submetidos a um classificador de forma correta.

Identificando outliers

Domínio pode ser conceituado como um conjunto de valores os quais representam determinado dado. Um exemplo pode ser aplicado no domínio do campo *cor*, representado pelos valores *azul*, *vermelho*, *verde*, *branco* e *preto*. Quando esse domínio apresenta valores que se diferenciam drasticamente de todos os outros, são pontos fora da curva.

Em outras palavras, um *outlier* é um valor que foge da normalidade e que pode (e provavelmente irá) causar anomalias nos resultados obtidos por meio de algoritmos e sistemas de análise. A Figura 6 mostra um exemplo de cadastro de trabalhadores solicitantes da aposentadoria e alguns dados são apresentados: código, nome completo, idade e último salário.

Linha	Código	Nome completo	Idade	Último salário
1	201	Antonio Nunes	64	
2	202	Maria da Silva	71	
3	203	Pedro Antunes de Oliveira	59	
4	204	João da Silva	475	

Outliers

Figura 6. Outliers.

Observe que a linha 4 da coluna *Idade* apresenta um grande afastamento das demais da série, ou seja, um valor de idade atípico, sendo então um valor inconsistente. A existência desse valor vai provocar prejuízos na interpretação dos resultados das análises aplicadas.

Novamente, a exploração dos dados permite entender os *outliers*, permitindo evitar visões negativas como resultado de uma análise, caso não seja, justamente, o que está sendo procurado. Realizar uma análise separada apenas com os *outliers* é uma abordagem útil quando se quer investigar casos extremos, como, por exemplo, desempregados que sempre solicitam seguro desemprego, alunos que só tiram notas máximas, empresas que apresentam alto lucro mesmo em tempos de alta inflação, casos de fraudes, entre outros.

Resolvendo problemas no pré-processamento

Um projeto de aprendizado de máquina utiliza, como amostragem, um conjunto de dados os quais contêm características representadas por valores. Cada uma dessas características se apresenta em uma escala de valores distintos, a exemplo das propriedades de um produto, em que a altura se apresenta em centímetros e o peso em gramas. Quando se aplicam esses dados em um algoritmo de *machine learning*, este poderá considerar mais o peso, por exemplo, ou seja, poderá dar mais importância a certas características devido a seus maiores valores, e não necessariamente a sua maior relevância.

No âmbito de um algoritmo de aprendizado, as características são tratadas como unidades, e seus valores, como magnitudes. Cada unidade deve ter pesos semelhantes. Para lidar com essas escalas diferentes, existem modelagens chamadas de pré-processamento, como reescalonar, normalizar e padronizar.

Reescalonar significa alterar a unidade de medida dos dados, convertendo em determinada proporção — por exemplo, converter peso de mililitros para litros. **Normalização** significa dividir por uma norma do vetor, por exemplo, subtrair dados do vetor menor e dividir pela subtração do valor máximo e valor mínimo, assim colocando os dados em uma faixa de 0 a 1. Já a **padronização** trata de subtrair os dados por uma medição de localização e dividir por uma média de escala, permitindo deixar os dados mais próximos da medida normal, possível. Um exemplo seria subtrair os valores pela média e dividir pelo desvio-padrão.

Podemos concluir então que a baixa qualidade dos dados prejudica a execução de um projeto analítico, prejudicando a aplicação de técnicas relacionadas ao aprendizado. A má qualidade dos dados é uma das maiores preocupações dos cientistas de dados, e pode colocar em risco os esforços de análise de *big data*, apesar das melhores intenções dos cientistas de dados e outros profissionais que trabalham com informações.

Normalmente, em projetos de grande magnitude, as empresas superestimam a resiliência dos algoritmos de aprendizado de máquina e subestimam os efeitos de dados com erros. A má qualidade dos dados produz resultados ruins e resulta em análises de negócio erradas. Os resultados dessas decisões prejudicarão o desempenho dos negócios e dificultarão o apoio a iniciativas futuras. Em projetos relacionados à aprendizagem de máquina, pode-se detectar uma qualidade de dados insatisfatória a partir de resultados que simplesmente parecem não fazer sentido, com base na experiência passada e atual.



Referências

BONAT, W. H.; KRAINSKI, E. T.; MAYER, F. P. *Introdução à análise exploratória de dados*. 38 slides. Material de aula do Departamento de Estatística da Universidade Federal do Paraná. Disponível em: http://cursos.leg.ufpr.br/ce001/slides/01_Analise_Exploratoria.pdf. Acesso em: 28 jun. 2020.

CAPÍTULO 1: análise exploratória de dados. [S. l., 2011]. Disponível em: http://www.each.usp.br/lauretto/SIN5008_2011/aula01/aula1. Acesso em: 28 jun. 2020.

MEDRI, W. *Análise exploratória de dados*. Londrina: [s. n.], 2011. Material de aula do Departamento de Estatística da Universidade Estadual de Londrina. Disponível em: http://www.uel.br/pos/estatisticaquantitativa/textos_didaticos/especializacao_estadistica.pdf. Acesso em: 28 jun. 2020.

NAVIDI, W. *Probabilidade e estatística para ciências exatas*. Porto Alegre: AMGH, 2012.

NUNES, C. E. *Aula3 Carlos: dado, informação, conhecimento e sabedoria*. [S. l.], 2015. 10 slides. Disponível em: <https://pt.slideshare.net/carlosnunes77/aula3-carlos>. Acesso em: 28 jun. 2020.

STANKEVIX, G. *Análise Exploratória de Dados*. [S. l., 2020]. Disponível em: <https://medium.com/@gabriel.stankevix/analise-explorat%C3%B3ria-de-dados-732007ddbfa6>. Acesso em: 28 jun. 2020.

Leituras recomendadas

MACHADO, F. N. R. *Projeto de Data Warehouse: uma visão multidimensional*. São Paulo: Érica, 2000.

VIALI, L. *Série estatística multivariada: introdução*. [S. l., 199-?]. Disponível em: <http://www.pucrs.br/ciencias/viali/especializa/realizadas/ceea/multivariada/textos/Introducao.pdf>. Acesso em: 28 jun. 2020.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Dica do Professor: Análise exploratória de dados

Para um projeto de *data science*, o processo de análise de dados, composto por várias etapas, tais como coleta, preparação, criação de modelo, automatização e apresentação, apresenta uma gama enorme de ferramentas, possibilidades, técnicas e metodologias para resolver cada uma dessas etapas.

Um exemplo disso é a etapa de criação do modelo preditivo, a qual utiliza algoritmos de aprendizado, chamados de *machine learning*, por conceitos da matemática e da estatística.

Na Dica do Professor a seguir, veja tais conceitos relacionados a *machine learning*, suas atividades durante a execução do aprendizado e seus resultados. Entenda também a importância da análise exploratória de dados para que se possa organizar e preparar os dados que são apresentados a um modelo preditivo.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Saiba mais: Análise exploratória de dados

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Prof. Álvaro Caldas - estatística e análise exploratória de dados

Assista ao vídeo para saber mais sobre conceitos iniciais de estatística e análise exploratória de dados.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Análise de dados em Python

Aprenda como realizar a análise de dados usando o frame da Anaconda, que permite programar em Python em Linguagem R.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Infográfico: Self-service analytics

A *self-service analytics*, ou análise de autoatendimento, é uma abordagem avançada de análise de dados que permite que usuários de negócios consigam manipular dados, de modo que seja possível identificar melhores oportunidades de negócios sem a dependência de uma equipe de tecnologia da informação (TI) especializada. No entanto, será que utilizar soluções de *self-service BI* (*business intelligence*) é mais vantajoso que as BI tradicionais?

Neste Infográfico, você vai ver as principais diferenças entre os dois tipos (tradicional BI x *self-service BI*) e qual deles apresenta maiores vantagens para negócios e usuários.

TRADICIONAL BI X SELF-SERVICE BI

Há algum tempo o business intelligence (BI) tradicional era a única opção para realizar a análise dos dados e obter insights para os usuários. No entanto, atualmente, existe a *self-service* BI, ou BI de autoatendimento, com algumas vantagens.

A seguir, as principais diferenças entre os dois tipos de soluções:



A *self-service* BI apresenta mais vantagens e facilidades para os usuários na análise de dados e geração de *insights*, já que sua análise **não é centralizada e não depende de uma equipe de TI especializada para isso**.

Porém, com a solução tradicional, a **qualidade dos dados é mais controlada**, já que existe uma equipe responsável por garantir a preparação, o armazenamento e a segurança.

Dessa forma, o **recomendado é que sejam utilizadas as duas soluções em conjunto**, tendo BI tradicional para responder perguntas sobre o passado ou o que está acontecendo agora, enquanto a *self-service* pode responder perguntas em tempo real e sobre o futuro.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Self-service analytics


O grande número de dados digitais gerados por meio de tantas tecnologias, dispositivos e sistemas que existem atualmente, além dos novos que surgem a cada dia, pode ser utilizado de maneira que seja possível aproveitar as muitas informações que podem partir deles. O padrão de comportamento e as preferências dos consumidores podem ser muito úteis para que as organizações obtenham vantagem competitiva, caso saibam aproveitá-la corretamente.

Para isso, existem as técnicas de análise de dados, que coletam e analisam os dados gerados de diferentes fontes, formando informações importantes sobre determinados assuntos, produtos ou serviços. A *self-service analytics* (análise de autoatendimento) é uma das técnicas possíveis para esses fins.

No capítulo ***Self-service analytics***, base teórica desta Unidade de Aprendizagem, você verá a definição de *self-service analytics*, bem como o que ela tem a agregar à análise de dados. Além disso, conhecerá técnicas de autoatendimento para a busca de *insights*.

Boa leitura.

ANALYTICS PARA BIG DATA



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Self-service analytics

Juliane Adelia Soares

OBJETIVOS DE APRENDIZAGEM

- > Reconhecer o papel do autoatendimento na análise de dados.
- > Aplicar técnicas de busca de *insights* com autoatendimento.
- > Apontar estratégias de autoatendimento para análise de dados.

Introdução

Atualmente, praticamente tudo depende da tecnologia. A cada dia, surgem novos sistemas e dispositivos de Internet das coisas (IoT) e os próprios meios de comunicação passam por mudanças, assim como as formas de armazenar e transmitir dados, com processos organizacionais cada vez mais automatizados. Tudo isso leva a uma enorme quantidade de dados digitais gerados por segundo. Esses dados podem fornecer importantes informações quando utilizados de forma correta.

Transformar esses dados em informação relevante às organizações pode ser uma tarefa difícil e lenta, devido à grande quantidade e variedade de tipos de dados. O processo tradicional de análise de dados depende de uma equipe de TI ou de especialistas em dados para ser bem realizada, mas com a *self-service analytics*, ou análise de autoatendimento, usuários empresariais podem realizar coletas e análises de dados de diferentes fontes em tempo real, sem necessitar do auxílio de especialistas no ramo.

Neste capítulo, você vai entender o que é *self-service analytics*, como ela funciona e qual sua importância para a análise de dados. Vai conhecer também as técnicas existentes e que podem ser utilizadas para obter *insights* com o uso do autoatendimento.

Definição e importância de *self-service analytics*

Nos últimos anos, o montante de dados gerados aumentou consideravelmente e, de acordo com relatório Data Never Sleeps 9.0 (DOMO, 2021), estima-se que em 2020 a quantidade de dados gerados por minuto em algumas das plataformas *on-line* mais populares foi a seguinte:

- usuários do Facebook compartilharam em torno de 240 mil fotos;
- usuários do Twitter enviaram aproximadamente 575 mil *tweets*;
- no Instagram os usuários compartilharam cerca de 65 mil fotos;
- usuários do YouTube transmitiram cerca de 694 mil horas de vídeos;
- usuários da Netflix assistiram em torno de 452 mil horas de programação;
- usuários do TikTok assistiram a mais ou menos 167 milhões de vídeos.

Essas coleções de conjuntos de dados são chamados de *big data*, cujo volume, velocidade e variedade são tão grandes que torna difícil seu armazenamento, gerenciamento, processamento e análise utilizando bancos de dados e ferramentas de processamento de dados tradicionais. Uma ampla gama de domínios, como *web*, varejo, *marketing*, bancos, finanças, indústria, saúde, meio ambiente, IoT e sistemas cibernéticos são abrangidos por aplicativos de *big data* (BAHGA; MADISETTI, 2019).

Dessa forma, é necessário aproveitar esses dados para gerar informações relevantes aos negócios, o que é realizado por meio da análise de dados. Zhang (2017) define análise de dados (*data analytics*) como um procedimento que deve primeiramente definir metas quanto aos dados e quais perguntas eles devem responder, para então coletar as informações necessárias, inspecioná-las e interpretar os dados, com o intuito de separar os bits úteis que podem gerar conclusões e auxiliar na tomada de decisão dos usuários, a partir da descoberta de tendências e confirmação ou refutação de ideias já existentes.

Um dos métodos de análise de dados que está em evolução é a *self-service analytics* (análise de autoatendimento), que está crescendo consideravelmente como ponto focal das transformações digitais nas grandes empresas. Esse tipo de análise permite que os usuários consigam acessar e explorar conjuntos de dados. Myers e Kogan (2021) afirmam que as ferramentas de autoatendimento são produtos prontos para uso, de forma que usuários finais podem interagir com eles e configurá-los diretamente, filtrando, classificando, analisando e visualizando os dados sem o envolvimento de uma equipe de TI ou especialistas em análise de dados.

Com a proliferação dos dados gerados, a demanda por análises também cresceu muito. Essa demanda, em conjunto com a incapacidade das equipes de TI de atender às necessidades analíticas imediatas dos profissionais de negócios, promoveu uma mudança na análise dos dados, passando de plataformas governadas e centradas em TI para plataformas descentralizadas, fazendo com que usuários de negócios sejam capazes de lidar com recursos analíticos de autoatendimento e descoberta de dados.



Fique atento

De acordo com Daradkeh e Al-Dwairi (2017), a *self-service analytics* surgiu como inovação tecnológica, de modo a proporcionar ambientes que permitam que os usuários sejam autossuficientes e menos dependentes das equipes de TI. Assim, estende-se o alcance e o escopo das ferramentas de *analytics* a uma gama mais ampla de necessidades e problemas organizacionais, tornando aos usuários o ambiente de tomada de decisão personalizado e mais colaborativo. Dessa forma, o departamento de TI fica mais livre para desempenhar suas demais funções, podendo se concentrar no desenvolvimento de recursos analíticos mais avançados e estratégicos. Os autores ainda afirmam que uma organização que implementa *self-service analytics* reduz em torno de 47% as solicitações de atendimento, já que os usuários estão habilitados a serem mais autônomos.

Os principais motivadores que levam uma organização a adotar essa abordagem de análise são (DARADKEH; AL-DWAIRI, 2017):

- necessidade de constantes mudanças nos negócios;
- incapacidade da equipe de TI de atender novos requisitos de maneira imediata;
- necessidade de que as organizações sejam mais analíticas;
- acesso lento às informações.

Conforme Imhoff e White (2011), há basicamente quatro principais vantagens da *self-service analytics*, examinadas uma a uma a seguir.

- **Resultados simples de interpretar** — a ferramenta de *self-service analytics* deve conter um ambiente simples de descobrir, acessar e compartilhar informações, relatórios e análises. Os painéis devem ser personalizáveis ou possuírem recursos automatizados para que as

informações possam ser personalizadas de acordo com cada situação. Isso significa que a ferramenta de análise de autoatendimento deve ser fácil de consumir, exigindo definições de negócios claras e facilmente acessíveis, bem como linhagens de dados rastreadas e documentadas, melhorando a tomada de decisão a partir do rastreamento de interações e decisões para descobrir, capturar e divulgar melhores práticas.

- **Ferramentas fáceis de usar** — assim como os resultados devem ser fáceis de interpretar, as ferramentas devem ser simples de usar. Esse é o principal foco da análise de autoatendimento, pois, com uma ferramenta mais simples e intuitiva, os usuários não ficam dependentes da TI, ou seja, conseguem sozinhos acessar mais rapidamente as informações, selecionar seus próprios relatórios e criar suas próprias análises.
- **Soluções de *data warehouse* mais rápidas** — para a *self-service analytics* também são buscados mecanismos alternativos de implantação para a redução de custos, melhoria de *time-to-value* e suporte de processamento de dados extremos, recorrendo a metodologias do tipo *software* como serviço (SaaS), por exemplo. O objetivo é garantir um ambiente com desempenho e escalabilidade adequados para cargas analíticas simples e complexas, bem como grandes volumes de dados. Além disso, deve oferecer suporte à fácil administração em tempo real.
- **Fácil acesso à fonte de dados** — nem todos os dados precisam ser guardados em *data warehouse*. Dados externos, com, meteorológicos, geográficos, demográficos, entre outros, podem ser relevantes aos objetivos da análise, devendo ser acessíveis sem que seja necessário o suporte da equipe de TI. Outro aspecto importante é que os elementos de *software* de autoatendimento devem permitir a integração de dados de vários tipos (estruturados, não estruturados e semiestruturados), conferindo aos usuários uma visão mais ampla e completa. Isso significa que as ferramentas devem capturar tanto dados internos quanto externos, sendo capazes de coletá-los em diferentes fontes de dados.

Como citado anteriormente, um dos focos principais da *self-service analytics* é a independência dos usuários de negócios, de modo a torná-los mais eficientes e produtivos, o que proporciona às organizações melhor nível de produtividade devido à redução de tempo de resposta necessário para a preparação de relatórios, principalmente em casos em que é necessário o cruzamento de informações de diversos departamentos. Além disso, ganha-se maior flexibilidade, pois cada usuário consegue personalizar seus relatórios, fazer suas próprias perguntas e receber as respostas de acordo com a necessidade.

Nesse âmbito, temos, segundo Castro (2016), os principais benefícios da *self-service analytics* descritos a seguir:

- Usuários podem orientar suas próprias análises — quem utiliza o sistema consegue ter acesso a dados de diferentes fontes de forma simplificada para realizar suas análises conforme o contexto e gerar relatórios de acordo com a necessidade do momento, sejam departamentais ou da organização como um todo, executando tudo em tempo real, de forma rápida e precisa, podendo partir de diversas perspectivas.
- Liberação das equipes de TI — frequentemente dados corporativos ficam armazenados em plataformas distintas, com acessos difícil ou restrito. Em muitos casos, podem não fornecer detalhes necessários e interatividade desejada, impossibilitando a exploração e a análise por parte de usuários comuns, o que dificulta que sejam encontrados possíveis problemas ou novas oportunidades. Esse processo era centralizado normalmente na equipe de TI, que deviam gerar os relatórios quando solicitados, realizando compilação e filtragem de dados, em um processo muito burocrático e lento. Em sistemas de *self-service analytics*, os dados ficam integrados em um mesmo ambiente, ao qual os usuários têm acesso e são capazes de realizar suas análises de acordo com suas necessidades. Assim, as demais equipes ficam livres do fardo de criar consultas, visualizações, painéis e relatórios, permitindo que se concentrem em prioridades de maior valor e que exijam maiores habilidades técnicas.
- Análises mais coerentes e mais ágeis — com dados e sistemas integrados, as relações são estabelecidas de forma prévia e os dados são regularmente atualizados, criando uma versão única da verdade. Dessa forma, recursos de autoatendimento ajudam a reduzir gargalos na análise, além de acelerar os processos de negócios, pois os usuários conseguem analisar os dados mais rapidamente.
- Navegação pelos relatórios — nesse sistema os usuários conseguem se aprofundar em detalhes para encontrar a fonte dos problemas ou isolar oportunidades específicas. Com a análise de autoatendimento, também é possível filtrar dados compreendidos em determinado intervalo de tempo, selecionar filtros em uma lista, entre outras funções. Essas ações podem ser realizadas de forma dinâmica e imediata nos relatórios, sendo eficiente e intuitivo para suportar as decisões de negócios.

- Redução da “fadiga decisória” — quanto maior a quantidade de dados, maior o esforço necessário para analisá-los e maior a possibilidade de criar uma “fadiga decisória”, o que pode acarretar enganos, falhas em identificação de oportunidades ou solução de problemas. Um *software* de análise de autoatendimento faz uso de painéis de controle de resumo e relatórios, possibilitando converter informações em ações rápidas e inequívocas, além de garantir o acesso instantâneo às informações, mesmo em pesquisas complexas, o que permite ao usuário iniciar cada análise imediatamente.
- Redução de custos — por não exigir grande número de funcionários especializados para a execução de análises, os custos se reduzem, considerando que as análises são realizadas por usuários comuns do sistema. Além disso, a adoção de ferramentas SaaS, por exemplo, garante o acesso a informações a qualquer hora e de qualquer lugar, com redução de custos imediatos do investimento inicial, passando para um custo mensal de assinatura. Além disso, o sistema é escalável de acordo com o número de utilizadores efetivos, adaptando os recursos e a capacidade do servidor à necessidade de processamento, sem ser preciso adicionar recursos extras de TI.
- Alteração da cultura empresarial — empresas que adotam esse modelo podem passar de reativas para preventivas, com o acesso imediato a dados assim que ficam disponíveis. Desse modo, as organizações conseguem trabalhar de maneira proativa, aumentando sua vantagem competitiva ao identificar novos territórios e novas oportunidades. Além do mais, conseguem identificar e descontinuar linhas de produção prejudiciais com precisão, obtendo, dessa forma, uma maior percepção dos custos reais, o que possibilita melhor estipulação de preços e geração mais eficiente de promoções ou programas de incentivo com menores recursos e riscos.

Apesar das inúmeras vantagens, a *self-service analytics* apresenta alguns desafios para as organizações. Alguns dos principais, segundo Castro (2016), são os seguintes:

- Resultados analíticos imprecisos — como os dados vêm de diferentes fontes e formatos, as consultas de autoatendimento podem produzir maus resultados por causa de conjuntos de dados incompletos ou erros de dados não identificados e corrigidos. Há o risco também de variados usuários trabalharem com versões diferentes dos mesmos

dados ou filtrá-los e prepará-los de maneiras distintas, levando a informações inconsistentes.

- Segurança de dados e privacidade — como a *self-service analytics* fornece amplo acesso aos dados, pode causar problemas caso não exista uma forte proteção e política de segurança de dados eficaz, já que usuários não autorizados podem acessar informações confidenciais ou utilizar dados de maneiras que violam os regulamentos de privacidade.
- Implementações não controladas — se não for implementado algum nível de monitoramento centralizado e supervisionado por equipes especializadas, os ambientes de autoatendimento podem se tornar desordenados. Caso as equipes responsáveis implantem esses sistemas de análise por conta própria, isso pode levar a dados inconsistentes, várias ferramentas diferentes de análise e custos excessivos, dificultando o dimensionamento de recursos de autoatendimento eficientes.

De modo geral, a implantação de *self-service analytics* representa um grande passo para a análise de dados, principalmente pela cultura do imediatismo em que a sociedade se encontra, em que tudo é muito acelerado e as tomadas de decisões também devem seguir o mesmo ritmo, caso contrário as organizações que não acompanharem podem ficar em desvantagem. Outro aspecto importante é que a análise de autoatendimento abole a necessidade de vasta mão de obra especializada em análise nas organizações, reduzindo custos e não sofrendo pela escassez de funcionários qualificados.

Na próxima seção, será apresentada a busca de *insights* com autoatendimento.

Insights proporcionados pela self-service analytics

Atualmente, a análise de autoatendimento é ideal para a geração de *insights* aos negócios, pois as análises tradicionais não conseguem fornecer resultados em tempo real, devido à explosão de dados digitais gerados. Com isso, a demanda por análises mais rápidas cresceu consideravelmente.

O conceito de autoatendimento pode ser classificado em relação a tarefas distintas: acesso a relatórios preparados ou recursos de dados, acesso direto a dados, acesso a funções ou criação de novos recursos. Dessa forma, o suporte do sistema varia conforme a tarefa a ser executada (ALPAR; SCHULZ, 2016).

Observe a Figura 1, que ilustra os níveis de autoatendimento, divididos em uso de informações, criação de informações e criação de recursos de informação. É possível observar pelo gráfico que, quanto maior a autossuficiência, maior a necessidade de conhecimento.




Figura 1. Níveis de autoatendimento.

Fonte: Adaptada de Alpar e Schulz (2016).

A seguir, examinaremos em mais detalhes cada um desses níveis de autoatendimento, segundo critérios de Alpar e Schulz (2016).

Uso de informações

No nível mais baixo, os usuários têm acesso às informações já criadas e a relatórios existentes, ou então precisam apenas definir os parâmetros antes de realizar o processamento. A diferença em relação aos sistemas de relatórios tradicionais é que no autoatendimento os usuários não têm acesso apenas a alguns relatórios-padrão fornecidos por terceiros, e sim a todos com potencial relevância para si. Essa abordagem é vantajosa porque é adequada para usuários casuais, que não possuem habilidades analíticas ou ferramentas especiais. Nesse nível, os *insights* básicos podem ser obtidos de maneira simples, desde que as informações necessárias sejam encontradas e interpretadas corretamente. Já para percepções individuais profundas, não é suficientemente flexível.

O fornecimento de relatórios e painéis que possibilitam “perfurar em qualquer lugar” é incluído neste nível, ou seja, os usuários podem iniciar suas análises em um nível agregado, mas caso necessitem de respostas a perguntas mais específicas podem pesquisar caminhos predefinidos passo a passo, até obterem as informações no nível de detalhe desejado, ou até chegarem ao final da escada de agregação.

Aqui é possível obter rapidamente dados fora do *data warehouse*, sem que precisem ser importados para ele. A mudança para outras fontes de dados é realizada de forma intuitiva do ponto de vista do *front-end* ou sem que o usuário perceba. Esse recurso facilita a análise, mas restringe-se apenas ao que os especialistas em inteligência de negócios (*business intelligence* — BI) preparam.

Criação de informações

No segundo nível, os usuários podem ter acesso a dados no nível desagregado mais baixo disponível no sistema, de modo que seja possível criar informações a partir dele. Isso é importante pois não é possível prever todas as necessidades de usuários e preparar visualizações adequadas a cada uma delas.



Saiba mais

A Structured Query Language (SQL) é uma linguagem não procedural para acesso geral aos dados, mas seu uso é muito complexo para a maioria dos usuários empresariais. Dessa forma, as ferramentas de autoatendimento criam visualizações virtuais instantaneamente a partir de arquivos de *big data*, se necessário. Os usuários casuais podem optar se desejam analisar dados existentes como arquivos simples, relacionais ou multidimensionais e, assim, não dependem de especialistas em BI para selecionar os dados que precisam. Entretanto, essa facilidade pode acarretar riscos, como o de selecionar dados que apresentem trechos incorretos ou agregados, já que usuários comuns podem não ter plena compreensão da relação de dados complexos que estão em segundo plano.

Indo além da preparação de relatórios e gráficos, os usuários podem realizar análises avançadas de forma independente, como, por exemplo, análises preditivas e mineração de texto, que envolvem análises mais complexas do que simplesmente analisar dados históricos. Porém, para evitar análises falhas, são necessárias ferramentas com funções analíticas para que seja possível realizar essas análises sem a necessidade de dominar pacotes estatísticos.

Criação de recursos de informação

Neste nível, as funções vão além de sistemas tradicionais de BI. Em sistemas tradicionais, os dados de diferentes fontes são combinados e fornecidos aos usuários como uma fonte única. Porém, considerando a ampla gama de fonte de dados e requisitos de usuário, a preparação de dados tornou-se algo desafiador, e a *self-service analytics* oferece aos usuários a utilização de novas fontes de dados para análise sem que tenham passado por um pré-processamento. Assim, eles conseguem criar diferentes recursos de informação mediante a combinação de dados com os dados corporativos temporariamente.

Nesse âmbito, pode ser oferecido aos usuários empresariais a combinação de diferentes funcionalidades utilizando componentes reutilizáveis que foram preparados por profissionais de TI. Dessa maneira, com o uso de dados pré-processados, os elementos podem ser unidos com uma simples ação de arrastar e soltar para formar um chamado *mashup* na aparência de um painel.

Cabe ressaltar que a ideia de análise de autoatendimento não é a mesma para todos os usuários. Nesse sentido, Alpar e Schulz (2016) afirmam que o ajuste entre usuário e ferramenta a ser utilizada depende de suas tarefas específicas, demandas de informação, habilidades de computador e habilidades analíticas. Qualquer que seja sua função, usuários podem apresentar necessidades alternadas e habilidades distintas, não sendo necessário que sejam separados em grupos de acordo com sua função.

Na próxima seção, serão apresentada as principais estratégias de autoatendimento para análise de dados.

Estratégias em *self-service analytics*

As organizações estão buscando ser mais analíticas a cada dia, pois perceberam essa necessidade para competir com eficácia, devido às muitas informações que os dados gerados pelos consumidores podem trazer. Nesse contexto, o autoatendimento é importante principalmente por sua facilidade de uso, já que essas soluções permitem que muitos tipos de usuários não técnicos sejam produtivos, não exigindo codificação nem funcionários de TI para configurar todos os acessos a dados, consultas, visualizações e preparação. Exemplos de análises de autosserviço podem ser encontrados durante todo o ciclo de uma análise, desde a preparação de dados até a construção de análises e *insights* avançados.

Como ainda são encontrados problemas para implementar a cultura de *self-service analytics*, Halper (2020) apresenta cinco estratégias que podem auxiliar as organizações nesse processo, as quais serão examinadas a seguir.

Foco na gestão de mudança

Para que se mantenha o autoatendimento, é essencial que se construa uma mentalidade orientada a dados na organização. No entanto, questões culturais podem representar alguns dos principais desafios a serem superados. A criação de uma nova cultura pode levar tempo e frequentemente envolver evangelização, construção de relacionamentos, treinamento e *marketing*.

Entre as principais abordagens que podem ser adotadas com esse objetivo, podemos destacar duas. A primeira delas é encontrar um defensor de peso, alguém que defenda a ideia da análise de autoatendimento. Ter um executivo por trás de um esforço analítico é a chave para o sucesso. O executivo conta com orçamento, plataforma e influência para fazer uma divulgação do valor da análise em toda a organização. Algumas empresas podem optar por treinar um grupo de funcionários que passe o conhecimento adiante, pois, geralmente, os usuários percebem o poder da análise conforme vão sendo treinados e obtendo conhecimento.

A segunda abordagem envolve encontrar métricas que importam, pois, para construir uma cultura de autoatendimento de sucesso, é fundamental que os dados sejam relevantes para as funções dos usuários na empresa.

Ferramentas modernas de BI

Ferramentas modernas de BI permitem que os usuários consigam obter *insights* de maneira mais rápida, principalmente porque não envolvem conhecimento em linguagens de codificação. Essas ferramentas requerem um treinamento mínimo e seus recursos incluem benefícios como maior consumerização e inteligência aumentada. No primeiro quesito, os produtos de autoatendimento fornecem recursos em que o foco é o consumidor, ou seja, o usuário final. Algumas oferecem ferramentas gráficas que permitem que os usuários de negócios explorem camadas de dados mais profundas e dados fatiados, de modo que seja possível identificar o que merece um exame mais detalhado. Além disso, a visualização facilita a filtragem de dados para análise multinível. Ferramentas mais modernas oferecem recursos de colaboração, extraindo maior valor de cada análise, sem que seja necessário

iniciar análises do zero sempre que preciso. Também existem ferramentas que utilizam interfaces que aceitam linguagem natural, tornando mais simples para usuários comuns fazerem perguntas de maneira intuitiva.

Já a vantagem da inteligência aumentada advém do fato de que o objetivo dessas ferramentas é ajudar os humanos nas tarefas. Assim, algumas delas podem fornecer sugestões para melhor visualização ou podem até fornecer *insights* automatizados diante dos principais recursos de dados.



Fique atento

Apesar de envolver ferramentas mais simples, o treinamento para uso de *self-service analytics* não é dispensável. Afinal de contas, de nada adianta dispor de uma ferramenta cheia de recursos fáceis de usar se seus usuários não sabem como aplicá-las de forma correta, prejudicando os resultados da análise.

Aumento da alfabetização na área de dados

A alfabetização na área de dados diz respeito a quão bem os usuários compreendem visualização e análises de dados e o quanto conseguem interagir com eles e compartilhá-los de maneira adequada para obtenção de bons resultados. Assim, pode ser necessário ensinar habilidades como pensamento crítico com dados, compreensão de fundamentos básicos de estatística e comunicação com dados.

O pensamento crítico refere-se ao pensamento analítico, lógico e objetivo. Nesse âmbito, são necessárias habilidades básicas de análise de dados e a capacidade de pensar no contexto dos dados, além de possuir habilidades de formular as perguntas necessárias. Conhecimentos básicos em estatística, incluindo conceitos de média e mediana, entre outros, também são úteis.

A comunicação com os dados é importante, pois sua narrativa vai muito além da apresentação de números e fatos em relatórios, envolvendo também a narração da análise, de modo sejam compreendidos o significado e a relevância dos resultados. Para isso, é fundamental o entendimento do público-alvo, saber estruturar a narrativa e, por fim, entender o valor de uma boa visualização e o que deve ser feito ou não em tabelas e gráficos. Dessa forma, o público será capaz de compreender a resposta à pergunta original.

Garantia de dados confiáveis

Sem dados confiáveis, não há sucesso na análise de autoatendimento. Assim, é recomendado que as organizações construam parcerias entre unidades e negócios e a equipe de TI ou especialistas em dados para que realizem a análise de dados confiáveis.

As equipes de TI entendem que devem garantir que os negócios tenham sucesso, por isso implementam arquiteturas de dados para evitar silos e caos de dados, oferecendo suporte ao autoatendimento. Isso é realizado por meio da unificação das fontes de dados, para que sejam confiáveis e verificados. Uma das abordagens de arquitetura que pode ser implementada nesse tipo de análise é o uso de uma camada de modelagem semântica, que fornece visão virtualizada de todas as fontes e plataformas de dados. Essa virtualização cria uma camada única de dados virtuais, integrando diferentes fontes, locais e formatos sem que sejam replicados.

A qualidade dos dados é essencial para que sejam confiáveis, e devem ser precisos, oportunos e razoáveis. Por isso, ao construir sua infraestrutura de dados, as organizações devem estar atentas para garantir essa qualidade, criando técnicas de padronização, desduplicação, verificações de valores discrepantes e ausentes e verificação de consistência.

A acessibilidade a dados confiáveis também é um ponto importante para as análises de autoatendimento. Além da infraestrutura de dados confiáveis construída, os usuários devem ter acesso a outras ferramentas e tecnologias. Um exemplo disso são os metadados, que fornecem informações sobre os dados — quem os criou, quando, seu tipo, sua origem e seu uso — e que podem auxiliar na obtenção de significativas percepções. Geralmente as organizações fazem uso de um catálogo de dados, que é um diretório que contém dados pesquisáveis ou inventários que descrevem os dados e ajudam os usuários na identificação e compreensão sobre quais existem e estão disponíveis para realização de análises.

Equilíbrio entre autoatendimento e governança de TI

Para evitar caos de dados, governança é fundamental. Governança significa políticas, regras e responsabilidades adequadas para supervisionar os dados, sejam os que estão em repouso ou em uso. Essa é uma das principais preocupações em *self-service analytics*, devido à complexidade das arquiteturas de dados.

Essa deve ser uma responsabilidade compartilhada entre as necessidades do negócio e a equipe de TI, em que a equipe de dados é responsável pelo gerenciamento dos dados para sejam recebidos com alta qualidade para análise.

As equipes devem trabalhar em conjunto para definir as regras e políticas que regem os dados, de modo que não sejam criadas regras de mais, que só atrapalhariam o processo de análise de autoatendimento, nem regras de menos, permitindo acessos não autorizados e sem controle aos dados. Desse modo, essas regras e políticas devem incluir definições de controle de acesso, padronização de termos e coordenação e colaboração para que se obtenha todas as junções de dados e modelagem realizadas no *back-end*, garantindo que as linhas de negócios usem o autoatendimento confiável.

A *self-service analytics* apresenta muitos benefícios para as organizações que a adotam, principalmente porque o mundo se encontra numa era digital e de imediatismo, de modo que esse modelo consegue dar conta da explosão de dados e da realização de análises mais rápidas. Apesar disso, existem alguns desafios que devem ser considerados. Para evitar ou superar os desafios citados ao longo deste capítulo, cada organização deve partir de uma estratégia de BI bem planejada, incluindo uma arquitetura de BI sólida, estabelecendo padrões de tecnologia e governança. Esses elementos ajudam a garantir que a empresa obtenha conjuntos de dados corretos e a infraestrutura adequada para fornecer suporte ao uso de ferramentas de BI de autoatendimento. Também devem ser implementados programas de treinamento nas ferramentas de autoatendimento para que os funcionários estejam aptos a criar visualizações de dados, painéis e relatórios eficazes. Por fim, a política de governança de dados define as principais métricas de qualidade, regras e políticas de acesso e uso, bem como quais procedimentos devem ser usados para compartilhamento de relatórios e painéis e como a segurança de dados e a proteção de privacidade serão mantidas.

Referências

- ALPAR, P.; SCHULZ, M. *Self-service business intelligence*. Marburg: Springer, 2016.
- BAHGA, A.; MADISETTI, V. *Big data analytics: a hands-on approach*. [S. l.]: Hands-on Approach Textbooks, 2019.
- CASTRO, J. M. L. T. *Tendências de business intelligence: SSBI como foco principal de estudo*. 2016. Dissertação (Mestrado em Gestão de Sistemas e Tecnologias de Informação) — NOVA Information Management School, Lisboa, 2016. Disponível em: <https://run.unl.pt/bitstream/10362/19434/1/TGI0065.pdf>. Acesso em: 20 out. 2021.
- DARADKEH, M.; AL-DWAIRI, R. M. Self-service business intelligence adoption in business enterprises: the effects of information quality, system quality, and analysis quality. *International Journal of Enterprise Information System*, v. 13, n. 3, p. 65–85, 2017.

DOMO. Data never sleeps 9.0. *DOMO*, 2021. Disponível em: <https://www.domo.com/learn/infographic/data-never-sleeps-9>. Acesso em: 20 out. 2021.

HALPER, F. *Five strategies for creating a culture of self-service for analytics and business intelligence*. [S. l.]: TDWI, 2020.

IMHOFF, C.; WHITE, C. *Self-service business intelligence: empowering users to generate insights*. [S. l.]: TDWI, 2011.

MYERS, N. E.; KOGAN, G. *Self-service data analytics and governance for managers*. New Jersey: Wiley, 2021.

ZHANG, A. *Data analytics: practical guide to leveraging the power of algorithms, data Science, data mining, statistics, big data and predictive analysis to improve business, work, and life*. [S. l.: s. n.], 2017. *E-book*.



Fique atento

Os links para sites da web fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais links.

Conteúdo:



SOLUÇÕES
EDUCACIONAIS
INTEGRADAS

Dica do Professor: Self-service analytics

Para a tomada de decisões assertivas, que agreguem vantagem competitiva às organizações, a análise de dados é a melhor solução, pois por meio dela é possível conhecer os padrões de comportamento dos usuários relevantes ao segmento. Assim, a *self-service analytics* (análise de autoatendimento) é de grande importância no mercado atual, principalmente devido ao grande número de dados digitais gerados por minuto diariamente.

Nesta Dica do Professor, você vai conhecer algumas das principais ferramentas de *self-service analytics*, que podem facilitar a realização dessas análises por usuários finais.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Atividade 4 (A4)

1) Atualmente, cada vez mais se tem acesso a dados dos mais variados tipos e formatos e, além disso, a quantidade de dados com o acesso à informação vem aumentando. Para auxiliar na avaliação desses dados, existe um processo que é considerado a principal etapa da análise dos dados, onde deve-se organizar, resumir e aplicar alguns cálculos, com isso resumindo as informações em um formato visual adequado à visualização. Esse conceito se refere à/ao:

A) Análise exploratória de dados.

B) *Big data*.

C) Ciência de dados.

D) *Analytics*.

E) Sabedoria.

2) A análise exploratória de dados é composta por várias etapas, cada uma desempenhando um papel fundamental para que a análise seja bem-sucedida. Na etapa de tratamento dos dados, existem problemas que denotam atenção. Na coleta de dados para uma análise sobre a fraude em cartões de crédito, por exemplo, nos valores de compra, na fatura de um cliente, surgem alguns que apresentam um grande afastamento dos demais valores da série.

Esse tipo de dado é conhecido como:

A) Univariado.

B) *Outliers*.

C) Multivariado.

D) Qualitativo.

E) Quantitativo;

3) Ao aplicar pesquisas, cada vez mais tenta-se encontrar alguma ligação entre determinados fatos. Essas se referem à tendência de dois acontecimentos ocorrerem de forma sincronizada; quando um cliente compra pão todos os dias na mesma padaria, por exemplo, a

tendência é que as variáveis “frequência diária de compra” e “satisfação com o pão” estejam relacionadas.

A essa relação se dá o nome de:

- A) Normalização de valores.
 - B) Análise univariada.
 - C) Correlação.
 - D) Análise multivariada.
 - E) *Outliers*.
- 4) Uma das características que facilita a interpretação e correlação dos dados na análise exploratória de dados é sua apresentação.

Indique qual das opções sugere um tipo de apresentação:

- A) Listagem.
 - B) Imagem.
 - C) Esquema.
 - D) Gráfico.
 - E) Infográfico.
- 5) Um dos grandes problemas na análise exploratória de dados são os dados ausentes (*missing values*), que podem resultar em uma análise errada ou mesmo em problemas na utilização desses dados em algoritmos de *machine learning*. Existem algumas técnicas a serem utilizadas para imputação desses valores ausentes, a exemplo da média, da repetição do último valor, de uma regressão linear ou mesmo do descarte da informação.

Para que a técnica seja escolhida, porém, deve-se saber:

- A) A origem do dado.
- B) O motivo do dado faltante.
- C) Os dados normalizados.

D) O destino do dado.

E) O tipo do dado faltante.

Saiba mais: Self-service analytics

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Como a *self-service analytics* fica mais fácil com Alteryx

Este vídeo apresenta uma *live* com um especialista em Alteryx, ferramenta de análise de dados *self-service* que gera *insights* visuais analíticos. O palestrante explica o que exatamente esse *software* faz, mostrando como ele funciona e quais os benefícios que ele traz para facilitar a *self-service analytics*.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Análise do uso de uma ferramenta de *business intelligence* em tomadas de decisão a partir de dados de mídia social

Este artigo apresenta o uso de uma solução de *business intelligence* (BI) *self-service*, mais especificamente o Microsoft Power BI Desktop. Por meio dele, e utilizando dados do Facebook, são analisados dados de usuários em relação a uma determinada empresa. Esses dados são analisados por meio de gráficos e auxiliam na tomada de decisões da organização em questão. Confira.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Avaliação e análise de ferramentas *business intelligence* para visualização de dados

Este artigo mostra uma comparação entre quatro ferramentas: Tableau, Power BI, Sisense e Qlik View, de modo a auxiliar na escolha da que melhor atenda às necessidades de cada negócio. As ferramentas de *self-service* melhoram a agilidade nos diferentes departamentos de negócio, já que

permite a criação dos próprios relatórios por parte dos usuários, além de ter acesso a dados a qualquer momento sem depender de especialistas.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.