Unidade 4

Apresentação

O crescimento do volume e da variedade de dados ampliou a necessidade de soluções mais flexíveis e escaláveis para armazenamento e consulta de informações. Nesse cenário, os bancos de dados NoSQL surgem como alternativa aos modelos relacionais, especialmente em aplicações que trabalham com grandes volumes de dados.

Além disso, bancos NoSQL podem apoiar motores de busca, auxiliando na organização, indexação e recuperação rápida de informações provenientes de diferentes fontes.

Nesta Unidade de Aprendizagem, você conhecerá os principais motivos, etapas e métodos de migração de bancos relacionais para NoSQL, além de compreender o funcionamento dos motores de busca e sua relação com a indexação de dados.

Bons estudos.

Ao final desta Unidade de Aprendizagem, você deve apresentar os seguintes aprendizados:

- Identificar os motivos e as etapas da migração de bancos relacionais para NoSQL.
- Descrever os principais métodos de migração.
- Explicar o funcionamento dos motores de busca.
- Relacionar bancos NoSQL aos processos de indexação e recuperação de informações.

Infográfico: Migrações de bases relacionais para bases NoSQL

Quando se pensa em um novo sistema gerenciador de banco de dados que não segue os padrões tradicionais de relacionamento, devem-se considerar os desafios que serão enfrentados durante o processo de implementação e migração dos dados.

Neste Infográfico, conheça os principais desafios enfrentados, sabendo que não são questões triviais, por quem faz a migração dos dados de um banco relacional para um sistema NoSQL, que vão desde mudança de mentalidade até obstáculos no quesito técnico.

OS MAIORES DESAFIOS DA MIGRAÇÃO PARA NoSQL

A migração de dados de um sistema relacional para um sistema NoSQL deve trazer benefícios. No entanto, alguns desafios são encontrados nesse processo. São eles:

MENTALIDADE RELACIONAL.



É um desafio humano e não necessariamente técnico. Dados em SGBD NoSQL são armazenados de maneira diferente dos relacionais, mas a mente humana demora a se acostumar com essa mudança. Em muitos casos, desenvolvedores utilizam conceitos dos bancos relacionais em bancos NoSQL, gerando diversas falhas e erros de *software*.



O foco deve ser em como suas aplicações interagem com os dados, e não em um armazenamento baseado em linhas ou muitas tabelas.

RELACIONAMENTOS EXISTEM NO NoSQL.

Muitos desenvolvedores que vivem no mundo dos bancos relacionais acreditam que as entidades perdem seus relacionamentos nos SGBDs NoSQL. Em partes, isso é verdade, mas, em bancos de dados orientados a documentos, podem, sim, existir relacionamentos entre entidades, inclusive de maneira mais simples, **como é o caso do banco NoSQL RavenDB**. Isso é desafiador para quem está migrando os dados, mas também é uma grande vantagem.



STORED PROCEDURES NÃO EXISTEM.



Esse desafio, que é técnico, é que não existem procedimentos armazenados *(stored procedures)* em sistemas NoSQL. Dessa forma, **a lógica inteira deve ser movida para a aplicação, e não para o banco de dados**. Isso pode gerar certo desconforto para quem está migrando seus dados para sistemas NoSQL, pois precisará rever a lógica dos sistemas que farão uso desses SGBDs.

TRIGGERS NÃO EXISTEM.

Assim como os procedimentos armazenados, **as *triggers* (gatilhos) também não existem em bancos NoSQL**. O banco RavenDB, por exemplo, tem um recurso muito similar, chamado de *Subscriptions* (assinaturas), que possibilita que o programador consiga monitorar as alterações que ocorrem em qualquer documento.





Os desafios apresentados nos bancos NoSQL podem ser superados se o **planejamento** ocorrer antes da migração.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Migrações de bases relacionais para bases NoSQL

A migração de dados é muito importante quando há a intenção de manter informações de sistemas legados, porém com uma estrutura mais escalável e performática. Certos cuidados, portanto, devem ser tomados dos pontos de vista organizacional e técnico para que uma migração ocorra com o menor impacto possível para os usuários de ferramentas que fazem uso desses SGBDs.

No capítulo Migrações de bases relacionais para bases NoSQL, da obra *Banco de dados não relacional*, você vai entender como funcionam os processos de migração de dados para sistemas não relacionais, conhecendo os motivos que levam a tomada de decisão por uma migração de bases de dados relacionais para bases NoSQL.

Boa leitura.

BANCO DE DADOS NÃO RELACIONAL

Whesllley Rimar Bezerra



SAGAH
SOLUÇÕES EDUCACIONAIS INTEGRADAS

Migrações de bases relacionais para bases NoSQL

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir os motivos que levam à execução de um processo de migração de dados de um banco de dados relacional para um banco NoSQL.
- Especificar os passos necessários para executar um processo de migração de um banco relacional para um banco NoSQL.
- Descrever os métodos de migração existentes.

Introdução

Os bancos de dados relacionais são confiáveis e possuem uma estrutura muito organizada, pautada nas relações entre as diversas tabelas que formam suas bases de dados. No entanto, em determinadas situações, algumas empresas optam por migrar seus dados para um sistema não relacional (NoSQL), visando a escalabilidade e alta *performance*.

Neste capítulo, você conhecerá quais são os principais motivos que influenciam as empresas a decidirem pelo uso de sistemas NoSQL. Além disso, verá como é feito o processo de migração para NoSQL. Por fim, verá quais são os métodos de migração adotados pelo mercado.

1 Motivos para migrar de um banco relacional para um NoSQL

Primeiro, é importante deixar claro que os bancos não relacionais (NoSQL) surgiram não com o intuito de substituir os bancos relacionais, mas de trazer uma nova alternativa para o armazenamento de dados, de modo flexível, fluido, com alto desempenho e robustez. Desse modo, uma empresa pode utilizar tanto um banco de dados relacional quanto um não relacional. Em alguns casos, por exemplo, faz-se necessário manter as duas plataformas coexistindo em um mesmo parque tecnológico, como uma arquitetura híbrida, o que permite obter o melhor desempenho dos dois conceitos.

Entretanto, algumas situações podem levar à decisão de migrar os dados de um modelo relacional para um modelo NoSQL. Segundo Frozza *et al*. (2018), um dos motivadores dessa decisão é que, em larga escala de dados, um banco relacional pode apresentar limitações quanto a alta concorrência em operações de leitura e escrita, alta disponibilidade e velocidade no acesso aos dados e armazenamento dos dados de *big data*. Essas limitações podem causar alguns infortúnios, que vão desde a rigidez na manipulação dos dados, devido à sua natureza estruturada, até uma grande lentidão no retorno de consultas realizadas nesses conjuntos de dados.

Uma empresa pode ter diversas aplicações de *software* que produzem dados em diferentes estruturas, formatos e tamanhos. Em uma rede social, por exemplo, é praticamente impossível coletar e armazenar os dados gerados por ela em um banco tradicional, pois geralmente esses tipos de dados são de natureza não estruturada (textos, imagens, vídeos, etc.). Para Sadalage e Fowler (2013), a migração entre sistemas de gerenciamento de bancos de dados (SGBDs) relacionais (relacional para relacional) que possuem grandes conjuntos de dados é bem complexa, pois manter os dados disponíveis para as aplicações que fazem uso deles durante o processo de migração é praticamente impossível. Isso porque as movimentações dos dados podem bloquear as tabelas, indisponibilizando os dados e gerando transtornos aos usuários. Logo, como os bancos tradicionais possuem dificuldades para lidar com esse tipo de informação gerada pelas aplicações modernas, os bancos NoSQL passam a ser utilizados.

Segundo Machado *et al*. (2019), os bancos NoSQL possuem melhor aderência em ambientes *web*, constituindo um novo paradigma que visa a superar alguns dos problemas existentes nos modelos relacionais. O Quadro 1, a seguir, apresenta outros motivos que se destacam e são fortemente considerados pelas empresas para a migração de dados para bancos NoSQL.

Quadro 1. Motivos para a migração de dados para bancos NoSQL

Motivo	Definição
Desenvolvimento de novas aplicações	Construção de novas aplicações com base em outros modelos e estruturas de dados.
Atualizações de aplicações existentes	Necessidade de atualizações em aplicações já existentes para modelos mais flexíveis de armazenamento e processamento de dados.
Integrações entre sistemas	Fusão entre sistemas de arquiteturas diversas, com bases de dados com estruturas também diferentes, mas que precisam se comunicar.

Contudo, é preciso estar ciente de que migrar os dados para uma base NoSQL pode trazer sérios riscos se o processo de migração não for bem conduzido pela equipe de tecnologia. Alguns exemplos desses riscos são apresentados a seguir.

- **Perda de informação:** pode ocorrer durante o processo de migração de dados. Se o planejamento ocorrer de maneira adequada, é possível que a perda de informação seja mínima, não impactando muito o setor que utiliza os dados, pois estes podem ser facilmente recuperados pela equipe de tecnologia com arquivos de *backup*.
- **Problemas com compatibilidade:** outra questão que deve ser avaliada com atenção é a compatibilidade dos dados. O ideal é que haja um preparo antes da migração (levantamento de requisitos), a fim de prever possíveis problemas de compatibilidade na migração de informações com outros sistemas operacionais ou verificar se os arquivos estão com extensões diferentes das suportadas pelo sistema NoSQL.
- **Falhas catastróficas:** é importante lembrar que o processo de migração também está sujeito à ocorrência de falhas catastróficas, que podem ser erros de *software* não previstos, podendo causar um tempo maior de inatividade do SGBD ou perda de dados, por exemplo.

Quando ocorre uma migração de bases relacionais para NoSQL, e vice-versa, as aplicações de *software* (*web*, *mobile* e *desktop*) precisam ter seu código-fonte alterado, de modo a permitir que a aplicação possa se comunicar com o novo sistema de banco de dados. Além de alterar a maneira como a comunicação ocorre, deve-se fazer modificações em como essas aplicações gravam novos dados e/ou leem os dados armazenados nesses SGBDs.

2 Processo de migração de dados

De acordo com Pulgatti (2017), como os bancos NoSQL não possuem uma estrutura definida (esquema), a semântica (significado) dos dados fica a cargo do desenvolvedor, não sendo responsabilidade do SGBD NoSQL. Desse modo, o programador deve organizar os dados na base destino, de modo que não percam o sentido real, ou seja, eles devem ser interpretados da mesma maneira como no sistema relacional.

A seguir, serão apresentados os passos necessários para se realizar uma migração assertiva. Essas etapas devem ser consideradas antes mesmo de se iniciar o processo de mudança.

Do ponto de vista organizacional

O Quadro 2, a seguir, apresenta como devem ser realizados os preparativos que a instituição deve adotar para uma migração sadia entre SGBDs de estruturas diferentes (relacional para NoSQL).

Quadro 2. Passos para a migração de dados (ponto de vista organizacional)

Passos	Definição
Orçamento	É importante que a empresa tenha recursos financeiros dedicados à migração, pois, assim, pode efetivar a contratação de mão de obra especializada em migrações de dados.
Estratégia	Ter uma estratégia é de vital importância para que o procedimento seja bem-sucedido. A partir dela, é realizado o levantamento de requisitos, a fim de entender quais são as prioridades, bem como o planejamento quanto ao cronograma da migração.

(Continua)

(Continuação)

Quadro 2. Passos para a migração de dados (ponto de vista organizacional)

Passos	Definição
Usuários	É relevante para a instituição que os usuários finais participem ativamente do processo, pois algumas regras de negócios são definidas e esclarecidas por eles. Os usuários também podem ampliar a visão sobre quais dados devem ser priorizados na migração, agregando maior valor ao negócio. Além disso, é de grande valia perceber quais são os anseios dos usuários mediante a migração: melhoria na *performance*? Maior flexibilidade? Maior capacidade de armazenamento?

Do ponto de vista técnico

Do ponto de vista técnico, no que se refere aos preparativos para uma migração de um banco relacional para um NoSQL, destacam-se alguns requisitos, como: auditoria, *backup*, validação dos dados, testes, quantidade de registros que serão migrados, mapeamento de tipos de dados, codificação de caracteres, correção de falhas, bem como a modelagem de dados. A abordagem do ponto de vista técnico consiste nos passos descritos a seguir.

- **Auditoria** — Deve-se fazer uma auditoria no banco de origem para entender se há dados obsoletos ou campos não utilizados que podem ser ignorados na migração. Além disso, é importante entender qual é a capacidade de armazenamento do banco de destino, verificando se ele está aderente às expectativas da equipe de tecnologia.
- ***Backup*** — É importante fazer cópias de segurança (*backups*) antes de iniciar a migração, pois elas garantem a restauração dos dados quando há um cenário crítico de perda de informação. O *backup* de dados, além de ser considerado uma boa prática de mercado, é um processo extremamente importante a ser executado antes de qualquer tentativa de migração ou manipulações agressivas na estrutura dos dados. As cópias de segurança podem ser utilizadas em caso de falhas e evitam a perda de dados.

- **Validação dos dados** — Durante a migração, é importante verificar a integridade dos dados no ambiente de origem, assim como no ambiente de destino, a fim de ter controle sobre todo o processo. Dessa forma, a equipe de tecnologia poderá checar se todos os dados foram migrados corretamente para a nova plataforma. Após o encerramento do processo, deve-se verificar se os dados estão íntegros na nova estrutura.
- **Testes** — Após finalizar toda a migração, deve-se executar testes para medir a performance do novo SGBD. Assim, somente ao fim de muitos testes, deve-se dar prosseguimento na desativação do banco de dados anterior.
- **Mapeamento de tipos de dados** — Antes de se iniciar a migração, é importante conhecer quais são os tipos de dados envolvidos. Assim, quando ocorrer a migração para um sistema NoSQL, os dados devem ser armazenados no mesmo formato aceito pelo SGBD. O ideal é que, ainda no banco de origem, os metadados (informação anexa aos dados que ajuda a interpretá-los) sejam verificados, passando por uma conversão no banco de destino para um tipo de dado correspondente. Se não existir no NoSQL um tipo de dado equivalente ao tipo de dado existente no banco relacional, é interessante que, antes da migração, no banco de origem (relacional), seja feita uma conversão desse dado para outro tipo que seja aceito no banco NoSQL, ou, ainda, que essa conversão ocorra durante o processo de migração. Além disso, os administradores de bancos de dados, junto à equipe de desenvolvimento, podem perceber que esse dado não possui tanta relevância, podendo optar, portanto, pela sua exclusão.
- **Caracteres** — Deve haver um cuidado especial quanto aos caracteres, pois, se algum deles for incompatível, podem ocorrer erros na migração ou perda de dados, que inviabilizariam a conclusão da migração.
- **Modelagem de dados** — Após o mapeamento, é chegado o momento de modelar os dados. Em uma estrutura relacional comum, a regra mais simples é definida como o relacionamento entre duas ou mais entidades. Nos sistemas NoSQL, no entanto, não existe um padrão único. As técnicas de modelagem são adotadas de acordo com o tipo de banco de dados escolhido. Logo, se escolhermos o MongoDB ou o CouchDB (ambos orientados a documentos), teremos um formato semiestruturado de dados, denominado JSON (JavaScript Object Notation; ou Notação de Objetos JavaScript, em português) ou BSON (JSON binário), por exemplo. Assim, em um banco NoSQL orientado a documentos, um arquivo estruturado no formato JSON é um documento, ao passo que um conjunto de documentos é uma coleção. Os documentos possuem atributos, e cada

atributo recebe um valor. Ou seja, nesse exemplo, em uma migração de uma tabela (relacional), o resultado seria uma coleção (NoSQL), e assim por diante, de acordo com cada tipo de banco de dados NoSQL.

- **Falhas na migração** — Deve-se prestar atenção quanto a possíveis falhas durante a migração. Se ocorrer desconexão na rede ou os servidores sofrerem problemas de gravação, é possível que os dados sejam impactados. Assim, a equipe precisa estar preparada, controlando o ambiente de ponta a ponta, para não ser surpreendida por erros inesperados.



Fique atento

Outros tipos de bancos de dados NoSQL são utilizados em processos de migração, e a modelagem deve respeitar a estrutura de cada um deles. Exemplos: chave/valor, colunas, grafos, entre outros.

Descrição das etapas

A migração de dados ocorre em uma sequência de etapas. O Quadro 3, a seguir, apresenta a definição de cada fase dentro do processo de migração.

Quadro 3. Etapas da migração de dados

Fase	Descrição
Pré-migração	Essa é a fase preparatória que ocorre no SGBD de origem dos dados. Nessa fase, são organizadas todas as informações quanto aos dados a serem migrados.
Fases 1 a 5	Essas fases possuem processos que serão executados de acordo com o projeto de migração, podendo ser necessárias mais fases (> 5) ou menos fases (< 5). Esses processos podem ser diferentes em cada projeto de migração.
Pós-migração	É a fase final, em que os dados já foram transferidos para o SGBD NoSQL. Aqui, os dados do destino são comparados com os dados de origem, a fim de verificar a integridade das informações.

Processos de migração

Conforme observado, as fases de migração podem ser diferentes, dependendo do projeto de migração. Entretanto, é importante saber quais são esses processos, independentemente da abordagem adotada (Quadro 4).

Quadro 4. Processos de migração

Item	Definição
Origem	SGBD relacional de onde os dados serão migrados.
Destino	SGBD NoSQL para onde os dados serão transferidos.
EI (extração inicial)	Processo que se caracteriza pela extração inicial dos dados da base relacional (origem).
Arquivos	Dados extraídos da base relacional que já estão no formato aceito pelo SGBD NoSQL.
Coletor (C1)	Comunicação realizada entre os servidores de origem e destino, monitorada pelo *software* de migração.
EO (extração *on-line*)	Processo que se caracteriza pela extração das operações de manipulação e definição de dados que ocorreram na base de dados relacional (origem) e pelo envio de dados à base de destino (NoSQL).
RI (replicação inicial)	Processo responsável por replicar as informações que chegam ao destino que estejam configuradas para serem replicadas. O RI replica os dados extraídos pelo processo de EI.
RO (replicação *on-line*)	Processo responsável por replicar as informações extraídas pelo processo de EO, mantendo-se *on-line* enquanto ocorre a sincronização dos dados.
Exportação para CSV	Processo de gravação e posterior envio dos dados em formato CSV (*comma separated values*; ou valores separados por vírgula, em português) do servidor de origem para o servidor de destino (etapa *off-line*).
Importação do CSV	Processo de leitura dos dados em CSV no servidor de destino (etapa *off-line*).

3 Métodos de migração para um banco NoSQL

Segundo Oliveira (2017), existem dois tipos de métodos de migração de banco de dados: *on-line* e *off-line*, podendo existir variações entre eles. Neste capítulo, abordaremos o método *on-line* e duas vertentes do método *off-line*:

- migração *on-line* com sincronização contínua;
- migração *off-line* por meio de uma ferramenta;
- migração *off-line* manual por meio de *scripts*.

Contudo, independentemente do método de migração escolhido, o objetivo é transferir os dados de um SGBD para outro, conforme a Figura 1.

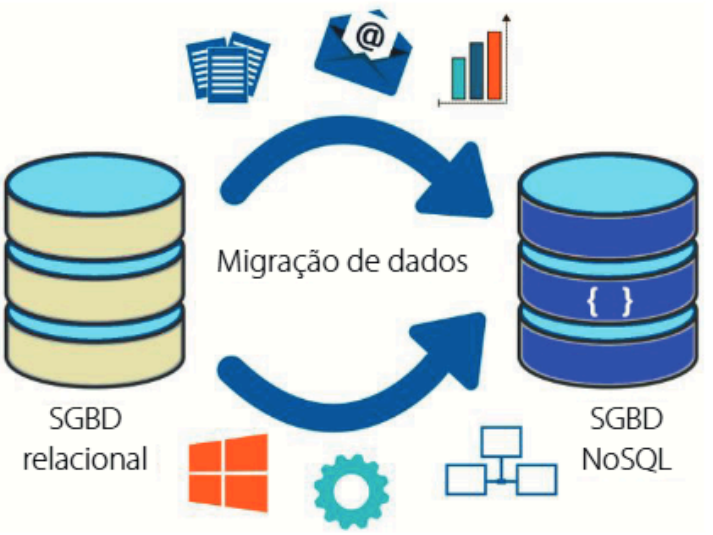


Figura 1. Exemplo de migração de dados entre SGBD relacional e NoSQL.

Além disso, na Figura 1, é possível observar que há transferência de dados, como arquivos, *e-mails* e planilhas, e essa migração ocorre entre o mesmo sistema operacional (no exemplo, Windows 10) em servidores que estão em uma mesma rede.

A seguir, serão apresentados cada um desses métodos de migração, bem como suas principais diferenças.

Migração *on-line* com sincronização contínua

Esse método de migração é conhecido por possibilitar que a aplicação que faz uso do SGBD permaneça conectada ao SGBD de origem, com sincronia total, durante o processo de transferência de dados. Assim, a aplicação é conectada à nova estrutura de dados somente quando a migração é finalizada. Isso requer conhecimentos avançados em programação, pois os mecanismos de conexão mudam de SGBD para SGBD. Entretanto, quando necessário, pode haver uma desconexão da aplicação com o SGBD para a realização de testes. O Quadro 5, a seguir, apresenta as etapas desse método de migração.

Quadro 5. Migração *on-line* com sincronização contínua

Pré-migração	Aplicação e dados no banco relacional
Fase 1	A aplicação permanece em execução; EI dos dados
Fase 2	A aplicação permanece em execução; RI dos dados no servidor de destino
Fase 3	A aplicação permanece em execução; EO dos dados
Fase 4	A aplicação permanece em execução; RO dos dados
Pós-migração	Aplicação e dados no banco NoSQL

Migração *off-line* por meio de uma ferramenta

Embora se assemelhe ao método de migração *on-line*, na migração *off-line*, a aplicação não está em execução e a transferência de dados é controlada por um *software* de migração, porém os processos são executados manualmente. O Quadro 6, a seguir, apresenta as etapas desse método de migração.

Quadro 6. Migração *off-line* por meio de uma ferramenta

Pré-migração	Fase 1	Fase 2	Pós-migração
Aplicação e dados no banco relacional	EI dos dados no servidor de origem	RI dos dados no servidor de destino	Aplicação e dados no banco NoSQL

Como exemplo, na migração *off-line*, poderia ser utilizada a ferramenta Oracle GoldenGate, responsável por realizar a replicação de dados de maneira heterogênea. Ou seja, essa ferramenta realiza a transferência de dados entre SGBDs de versões diferentes, de sistemas operacionais distintos e até mesmo entre SGBDs de estruturas diferentes, como é o caso dos NoSQL. A Figura 2, a seguir, apresenta alguns exemplos de bancos relacionais que podem ter seus dados migrados para outras plataformas com o uso da ferramenta Oracle GoldenGate.

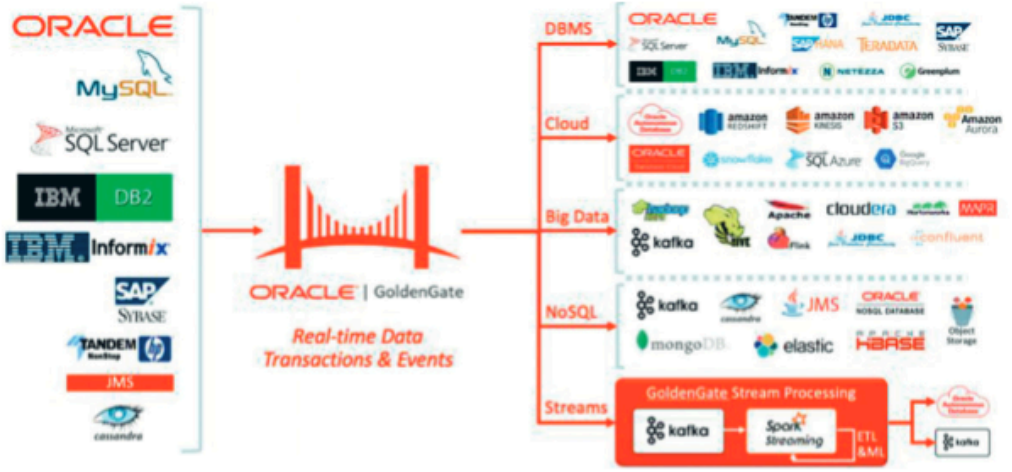


Figura 2. Cenário de atuação da ferramenta Oracle GoldenGate.

Fonte: Oracle... (2019, p. 1).

Migração *off-line* manual por meio de *scripts*

A migração *off-line* é um processo manual realizado por um especialista, que levantará quais dados devem ser extraídos, considerando-se o formato em que serão gravados e enviados ao servidor de destino. Além disso, ele deve considerar como será realizado o carregamento dos dados no servidor de destino. O Quadro 7, a seguir, apresenta as etapas desse método de migração.

Quadro 7. Migração *off-line* por meio de scripts

Pré-migração	Fase 1	Fase 2	Pós-migração
Aplicação e dados no banco relacional	Gerar arquivo CSV a ser enviado ao servidor de destino	Ler arquivo CSV no servidor de destino	Aplicação e dados no banco NoSQL

Portanto, é possível concluir que as migrações de SGBDs relacionais para SGBDs NoSQL podem ocorrer de maneira leve e sem complicações, desde que adotadas com planejamento e medidas preventivas, a fim de evitar percalços.



Referências

FROZZA, A. A. *et al.* DINo: uma ferramenta para importação de dados em bancos de dados NoSQL. *In*: ESCOLA REGIONAL DE BANCO DE DADOS, 14., 2018, Rio Grande. *Anais* [...]. Rio Grande: Centro de Ciências Computacionais da Universidade Federal do Rio Grande, 2018. p. 135–138. Disponível em: https://ojs.sbc.org.br/index.php/erbd/article/view/2839. Acesso em: 5 jun. 2020.

MACHADO, R. *et al.* Uma Aplicação para Migração de Dados de Banco Relacional para MongoDB. *In*: ESCOLA REGIONAL DE ENGENHARIA DE SOFTWARE, 3., 2019, Rio do Sul. *Anais* [...]. Rio do Sul: Instituto Federal Catarinense, 2019. p. 113–120. Disponível em: https://sol.sbc.org.br/index.php/eres/article/view/8503. Acesso em: 5 jun. 2020.

OLIVEIRA, F. V. *Migração de bases de dados relacionais para NoSQL*: métodos de análise. Orientador: Abílio Oliveira. 2017. 90 f. Dissertação (Mestrado em Engenharia Informática) – Departamento de Ciências e Tecnologias da Informação, Instituto Universitário de Lisboa, 2017. Disponível em: https://repositorio.iscte-iul.pt/bitstream/10071/15649/1/FabioOliveira_Tese_MEI.pdf. Acesso em: 5 jun. 2020.

ORACLE GoldenGate for Big Data. Redwood City: Oracle, 2019. 2 p. Disponível em: http://www.oracle.com/us/products/middleware/data-integration/goldengate-for-big-data-ds-2415102.pdf. Acesso em: 5. jun. 2020.

PULGATTI, L. D. *Data migration between different data models of NOSQL databases*. Orientador: Marcos Didonet Del Fabro. 2017. 80 f. Dissertação (Mestrado em Informática) – Setor de Ciências Exatas, Universidade Federal do Paraná, Curitiba, 2017. Disponível em: https://acervodigital.ufpr.br/handle/1884/49087. Acesso em: 5. jun. 2020.

SADALAGE, P. J.; FOWLER, M. *NoSQL essencial*: um guia conciso para o mundo emergente de persistência poliglota. São Paulo: Novatec, 2013. 216 p.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:

SOLUÇÕES EDUCACIONAIS INTEGRADAS

Dica do Professor: Migrações de bases relacionais para bases NoSQL

Quando uma empresa, independentemente da área de atuação, se prepara para a migração de dados, muitas adaptações precisam ser feitas, visando a executar essa tarefa da maneira que gere o menor impacto possível aos usuários e aos seus clientes.

Nesta Dica do Professor, veja como se preparar para a migração de dados de um sistema gerenciador de banco de dados relacional para
um sistema NoSQL, entendendo as características da migração.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Saiba mais: Migrações de bases relacionais para bases NoSQL

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

VDINo: uma ferramenta para importacão de dados em bancos de dados NoSQL

Leia, neste artigo, sobre uma ferramenta desenvolvida com o foco em migrações de dados de um sistema gerenciador de banco de dados relacional, como o PostgreSQL, para modelos NoSQL, como MongoDB, Redis ou Cassandra.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Uma aplicacão para migracão de dados de banco relacional para MongoDB

Leia, neste artigo, sobre a aplicação DB2Mongo utilizada na migração de dados relacionais do SGBD DB2 para o banco NoSQL MongoDB, conhecendo em detalhes o funcionamento de sua arquitetura, além de entender todo o processo de levantamento de requisitos, desenvolvimento e, por fim, a realização de testes.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

NoSqlayer: um *framework* para migrar conjuntos de dados relacionais para modelos NoSQL

Conheça, neste artigo, o *framework* NoSqlayer, utilizado para migrações de sistemas relacionais para SGBDs NoSQL. Veja, ainda, como são constituídos os módulos de migração e mapeamento dos dados da ferramenta. Por fim, acompanhe os resultados dos testes realizados com o *framework*.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Infográfico: Motores de busca (search engines)

Os motores de busca são essenciais para obtenção de arquivos e dados de forma rápida e organizada, com base em interesses pontuais que se pode demonstrar a partir de "palavras-chave". Mas você já parou para pensar o que os motores fazem com essas palavras-chave?

Como é que o Google, por exemplo, devolve uma coletânea de materiais sobre o que é, como fazer, onde estudar e outras coisas sobre "aprendizado de máquina" quando você procura apenas por essas palavras? Há uma série de passos para que isso ocorra, e você pode conferi-los agora.

Veja, no Infográfico a seguir, como os motores de busca funcionam.



Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Conteúdo do Livro: Motores de busca (search engines)

Com o avanço e a presença cada vez mais evidente do *Big Data*, bancos de dados e serviços que possibilitem a manipulação de grandes volumes de dados de forma eficiente são extremamente necessários. Os bancos de dados não relacionais são importantes nesse processo, e ferramentas baseadas neles, como o motor de busca Elasticsearch, podem ser a solução para obter resultados de busca rápidos e precisos em cima dessa imensidade de dados que nos cerca.

No capítulo **Motores de busca (*search engines*)**, da obra *Banco de dados não relacional*, você vai aprender sobre a definição e a classificação dos motores de busca, um pouco da sua história e funcionamento e também como o NoSQL pode estar envolvido nesse processo.

Boa leitura.

BANCO DE DADOS NÃO RELACIONAL

Mariana Araújo Pereira



SAGAH
SOLUÇÕES EDUCACIONAIS INTEGRADAS

Motores de busca (*search engines*)

Objetivos de aprendizagem

Ao final deste texto, você deve apresentar os seguintes aprendizados:

- Definir o motor de busca e seu funcionamento.
- Classificar os motores de busca quanto à fonte dos dados.
- Relacionar a utilização de bancos de dados NoSQL com o processo de indexação de motores de busca.

Introdução

Os motores de busca são programas utilizados para encontrar diferentes páginas e documentos que possuem informações relevantes e conectadas com o interesse do usuário que está realizando a busca a partir de termos ou palavras-chave. Esses motores podem utilizar modelos probabilísticos ou booleanos nas suas buscas, bem como podem ter diferentes fontes de dados e indexação. Esta última pode ser facilitada pela utilização de bancos de dados NoSQL.

Neste capítulo, você estudará sobre os motores de busca, bem como verá de onde eles surgiram e como funcionam. Além disso, verá quais são as suas classificações e exemplos amplamente utilizados de cada uma delas. Por fim, verá como os bancos NoSQL podem ajudar na indexação de motores de busca.

1 O que são e como funcionam os motores de busca

A chamada "Era do Conhecimento", que teve o seu início no século XX, revolucionou e ainda revoluciona o mundo como um todo, por meio do amplo número de informações geradas e disponibilizadas a cada dia. No entanto, devido ao grande volume de informações, é preciso condensar e categorizar todos esses dados de alguma forma, a fim de facilitar a sua busca de acordo com o interesse de quem está pesquisando. A preocupação em fazer isso vem desde meados dos anos 1900, antes mesmo do surgimento da internet, e se tornou pública com a idealização e publicação do Memex, em 1945, um dispositivo descrito pelo engenheiro, inventor e político estadunidense Vannevar Bush. A ideia dele era extremamente complexa e cheia de funcionalidades, dentre as quais estavam incluídas a capacidade de comprimir e armazenar toda a informação presente em livros e documentos, por exemplo, bem como permitir a sua consulta de forma rápida e eficiente (BUSH, 1945). Hoje, a descrição que Bush utilizou é considerada o conceito inicial do hipertexto ou, no mundo virtual, *hiperlink* (NYCE; KAHN, 1991), por isso, alguns o consideram como um dos grandes idealizadores do sistema de documentos hipermídia, conhecido como *web* (WWW, do inglês World Wide Web; ou Rede Mundial de Computadores, em português), e dos motores de busca que nele atuam.

Ao contrário do que algumas pessoas acreditam, o WWW e a internet são coisas diferentes. A internet é uma rede de computadores interconectados que surgiu no auge da Guerra Fria, nos anos 1960, a fim de facilitar a conexão entre laboratórios, e somente começou a se popularizar no fim dos anos 80, com a abertura da sua utilização comercial. Em contrapartida, o WWW é um sistema de informação global que funciona dentro da internet, criado no início dos anos 90 com o objetivo de desenvolver uma interface de fácil acesso a informações, utilizando, principalmente, o *hiperlink* (i.e., o endereço do *site*, com o www na frente), permitindo, assim, que pessoas de diferentes localidades tivessem acesso ao mesmo documento.



Saiba mais

No artigo publicado em 1992 por Tim Berners Lee, criador do WWW, Caillau e Groff, já há menção sobre ferramentas de busca que facilitassem o acesso para além do *hiperlink* (BERNERS-LEE; CAILLIAU; GROFF, 1992).

Em 1990, o primeiro motor de busca foi publicado, ainda baseado na internet pré-*web*. O Archie era um diretório de serviço para a internet que tinha como objetivo fornecer não só informações de documentos, mas também nomes e contatos de pessoas e serviços ligados a eles (EMTAGE; DEUTSCH, 1992). Esse mecanismo se manteve em alta por alguns anos, mas foi rapidamente substituído por outros motores pós-*web*.

Portanto, os motores de busca são programas desenvolvidos para pesquisar e localizar informações relevantes por meio de termos inseridos pelos usuários, fornecendo uma lista dos *sites* e arquivos que mais correspondem àquela busca com base nos termos pesquisados (TARAKESWAR; KAVITHA, 2011).

Funcionamento dos motores de busca

O processo necessário para o funcionamento dos motores de busca começa antes mesmo de o usuário pensar em utilizá-los. Como o conteúdo presente na *web* é muito vasto, os motores de busca utilizam *software* rastreadores que detectam as páginas disponíveis para o público, analisam o conteúdo e os *links* de cada página e extraem dados para catalogar e classificar cada uma delas. Os *software* responsáveis por esse processo são conhecidos como rastreadores *web*, aranhas ou *web crawler*. Informações como classificação etária e palavras-chave são registradas em um tipo de índice de pesquisa. No caso do Google Search, que atualmente é o motor de busca mais utilizado, esse índice que armazena dados de bilhões de páginas possui um tamanho superior a 100 milhões de gigabytes e tende a crescer cada vez mais, devido à sua constante atualização e ao aumento de materiais disponíveis na rede (COMO..., [2020?]).



Fique atento

Os *web crawlers* são *software* capazes de realizar varreduras sistematicamente em toda a internet, constituindo a base dos motores de busca. Por meio da obtenção de informações utilizando os textos e as palavras-chave das páginas digitadas, eles possibilitam a indexação dos *sites* nas "bibliotecas" dos motores de busca e o rápido retorno de resultados quando o usuário realiza uma operação de busca. Os *web crawlers* mais famosos são: Googlebot, da Google; Yahoo! Sluro, do Yahoo!; e Msnbot, da Microsoft.

O registro das informações e a criação de um índice de pesquisa fazem parte de um processo chamado de **indexação**. Ao encontrar uma página, o rastreador precisa "entender" do que ela fala e o que contém, analisando não só o texto, mas também imagens, vídeos e áudios ali presentes e salvando essas informações no banco de dados. Além disso, esses itens coletados são utilizados para identificar conteúdos duplicados, em que, no exemplo do Google, as "cópias" recebem uma penalização do índice, sendo exibidas em uma posição e frequência menor (COMO..., [2020?]). Em virtude da constante atualização de páginas, algumas verificações são constantemente feitas, como a "revisitação" das páginas indexadas, com o objetivo de encontrar e catalogar possíveis mudanças que ocorreram nelas (TARAKESWAR; KAVITHA, 2011). Com o índice de pesquisa estabelecido, a pesquisa propriamente dita pode ser realizada.

De forma geral, os motores de busca estruturam os resultados da pesquisa de acordo com a relevância da página. Embora muitos fatores possam influenciar a relevância, existem dois princípios gerais para determinar o quão relevante o conteúdo é: a localização das palavras-chave dentro do arquivo; e a frequência em que elas aparecem. Assim, as páginas nas quais o termo de pesquisa aparece mais vezes e está inserido no início da página, nos *links*, subtítulos e *tags* são consideradas mais relevantes e podem aparecer nas primeiras posições dos resultados das pesquisas. No entanto, cada mecanismo de pesquisa possui seu próprio método para atribuir pesos a cada característica das páginas. Isso explica por que, para a mesma pesquisa, diferentes motores de pesquisas fornecem resultados ordenados de modo diverso (TARAKESWAR; KAVITHA, 2011).

Após a inserção de frases e palavras na barra de busca, faz-se necessário que os algoritmos por trás dos motores realizem algumas ações, como: analisar o significado de cada palavra inserida, considerando possíveis erros de digitação (p. ex., "mangs", em vez de "manga") e contextos específicos (p. ex., "manga" da blusa ou a fruta?); buscar por dicas para identificar uma necessidade de informação ampla ou específica (p. ex., horário de funcionamento de um estabelecimento); e tentar identificar se os resultados devem ser locais ou globais e se o usuário procura por notícias antigas ou recentes. Tudo isso é realizado a partir de modelos linguísticos e aplicações de estudos sobre a compreensão da linguagem natural.

Ao pensar na inserção de termos soltos na barra de busca, torna-se evidente a necessidade de que haja uma forma de realizar a busca com diferentes termos, reconhecendo-os individualmente, em vez de considerar um grupo de palavras-chave como uma única entrada de pesquisa. Por exemplo, a frase "amarelo, lápis, xícara" não faz sentido algum, porém, se você inseri-la em um motor de busca qualquer, certamente obterá resultados de xícaras ou lápis amarelos e, muitas vezes, os três itens em conjunto (Figura 1). Na maioria das vezes, isso é possível por meio do operador booleano AND, que está implícito nas barras de busca e tem a função de dizer para o algoritmo que ele deve buscar "amarelo" E "lápis" E "xícara".



Saiba mais

Os **operadores booleanos** são palavras que informam ao sistema de busca como combinar os termos da pesquisa. Além do AND, há também OR, NOT e suas combinações, que, em português, correspondem a E, OU e NÃO, respectivamente. Em geral, eles podem ser utilizados explicitamente pelos usuários nas opções de busca avançada, sempre em maiúsculo. Os operadores booleanos são utilizados como filtros que selecionam conjuntos de documentos para modificar a classificação, pois encontram páginas altamente relevantes (YOSHIOKA; HARAGUCHI, 2005).

Além de todos esses critérios, como o número de vezes que a palavra aparece, a análise das palavras e os indicadores booleanos implícitos ou explícitos, há mais um ponto importante para classificar a relevância das páginas: o modelo utilizado para realizar os cálculos, que geralmente são booleanos ou probabilísticos. O **modelo booleano** é o mais antigo e simples, pois usa a correspondência exata entre os termos de busca e os documentos. Dessa forma, um documento é julgado apenas como relevante ou irrelevante, sem meio-termo. Com o **modelo probabilístico**, por sua vez, é possível estimar a probabilidade de o usuário achar um documento específico relevante ou não, para além da correspondência de termos. Melhorias no modelo probabilístico podem ser feitas com inferência bayesiana.

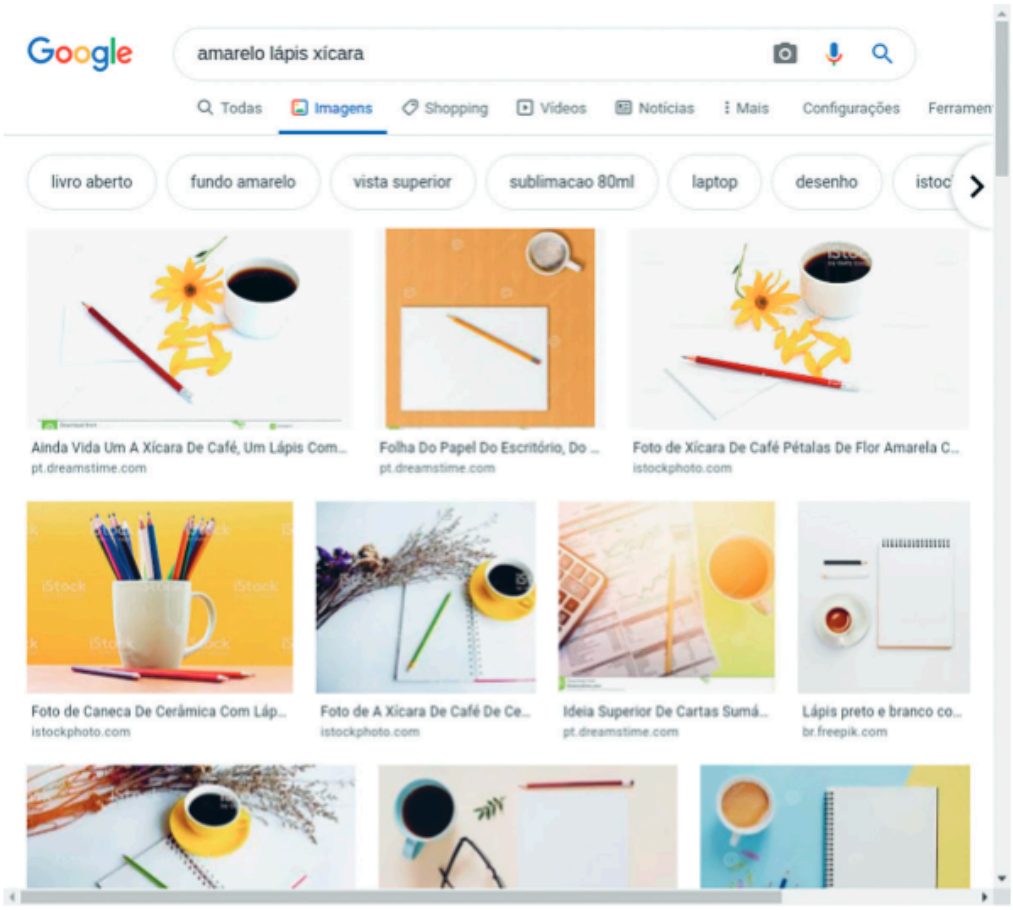


Figura 1. Resultado de busca por "amarelo", "lápis" e "xícara" no motor de busca Google Search.

Saiba mais

A **aprendizagem bayesiana** fornece um método para calcular a probabilidade assumida, com base nos registros de visita a *sites* anteriores do usuário para inferir qual resultado o agradaria mais, tornado o sistema, de certa forma, personalizado (ZHAO, 2018).

2 Tipos de motores de busca

Os motores de busca podem ser classificados quanto à sua indexação ou quanto à sua fonte de dados. Quando classificados quanto à sua indexação, eles podem ser divididos nos tipos listados a seguir.

- **Motores de busca por rastreador:** são aqueles que utilizam um rastreador, *bot* ou *spider* para rastrear e indexar novos conteúdos no banco de dados de pesquisa. Esse mecanismo contém três partes: o **rastreador** propriamente dito, o **índice** e o ***software* do mecanismo de pesquisa**. Em virtude do rastreio constante, é o mecanismo que fornece informações mais atualizadas. O Ask é um exemplo de motor de busca baseado em rastreador.
- **Motores de busca manuais:** são mecanismos de pesquisa que dependem de atividade humana para realizar a indexação dos dados. Ou seja, o próprio dono da página da *web* precisa definir qual é o endereço, o título e a descrição do site. Além disso, a submissão da página precisa ser revisada pelos editores. A indexação manual também pode ser realizada a partir de documentos não digitais, que serão transcritos com os campos de interesse predefinidos para a realização da indexação. Desse modo, a qualidade do conteúdo acaba sendo melhor, mas qualquer alteração realizada não será atualizada no mecanismo de busca até que o conteúdo seja enviado novamente de modo manual, o que limita a busca por resultados mais recentes sobre determinados assuntos. Alguns mecanismos especializados, como os motores de busca de genealogia, são alimentados dessa forma.
- **Motores de busca híbridos:** incluem os recursos dos motores de busca por rastreador e manual, como é possível perceber no Quadro 1. O Google Search é um exemplo de mecanismo híbrido (TARAKESWAR; KAVITHA, 2011).

Quadro 1. Comparação entre os motores de busca por rastreio, manual e híbrido

	Rastreador	Manual	Híbrido
Indexação por robôs	×		×
Indexação manual		×	×
Dados sempre atualizados	×		×
Dados mais confiáveis e curados		×	×

A seguir são listados os motores de busca que são classificados quanto à sua fonte de dados.

- **Metadados:** a maior parte dos motores de busca da internet utiliza como fonte de dados os metadados de arquivos e *sites*. Esses metadados nada mais são do que as informações sobre os dados que ali estão contidos, salvas em arquivos "invisíveis", o que inclui as palavras-chave. Então, a indexação das informações é realizada a partir do que está presente nos metadados, muitas vezes em campos bem-definidos, conforme a Figura 2.
- **Federados:** por meio dos dados federados, é possível realizar uma mesma pesquisa em diferentes bancos de dados, *sites* e repositórios com as informações já indexadas em cada um deles. Nesse caso, a pesquisa é realizada de forma paralela, e os resultados são mesclados antes de serem exibidos como um "resultado final" para o usuário. Essa forma de pesquisa em diferentes fontes utilizando a indexação de cada base é chamada de **pesquisa federada** (MELTON; BUXTON, 2011). O Google Scholar é um exemplo de motor de busca que utiliza pesquisa federada.

```
<title> A tag title está aqui </title>

<meta name = "description" content = "E o texto descritivo que entra aqui é a meta
descrição.">

<meta name = "keywords" content = "" />
```

Figura 2. Exemplo de metadados de um *site*.

- **Por *desktop*:** essa fonte de dados não está relacionada à internet, mas é muito utilizada por todos nós. O *desktop* armazena tudo que está no nosso computador físico. Assim, os motores de busca cujas fontes são o *desktop* não funcionam na internet, mas na própria máquina. Esse motor de busca é utilizado para buscar por arquivos, músicas, filmes e textos, por exemplo, nas centenas de pastas existentes em um computador. O Windows Search é o motor desse tipo mais utilizado, presente nos sistemas operacionais Windows. Esses motores realizam as etapas de busca e indexação de forma contínua, mantendo o índice sempre atualizado. Nesse processo, os tipos principais de informação recolhidos são o nome do arquivo, o caminho ou localização, os metadados e o conteúdo (WINDOWS..., 2018).

3 A importância do NoSQL para o desenvolvimento de motores de busca

O NoSQL é uma tecnologia que significa, literalmente, "não apenas SQL" (do inglês *not only SQL*), utilizada em bancos de dados não relacionais. Esses bancos não seguem a linguagem de busca estruturada, o que facilita o armazenamento de grandes volumes de dados com alta escalabilidade (i.e., capacidade de aumentar o tamanho e o processamento de acordo com a demanda) e disponibilidade (HIRIYANNAIAH *et al*., 2018). Portanto, os bancos NoSQL são ideais para estar por trás de um motor de busca, pois armazenam as informações cada vez mais crescentes durante a indexação e facilitam os resultados das pesquisas de acordo com os critérios estabelecidos. Alguns exemplos de NoSQLs que facilitam a pesquisa de alta qualidade são: Apache Lucene, Apache Solr e ElasticSearch (MCCREARY; KELLY, 2014), que será o foco desta seção.

Os sistemas baseados em NoSQL utilizam algumas estratégias para tornar os mecanismos de pesquisa mais eficazes, as quais são descritas seguir.

- **Índice de intervalo**: forma de indexar todos os valores de cada item do banco de dados em ordem crescente. É ideal para palavras-chave alfabéticas e datas, por exemplo.
- **Índice reverso:** para cada palavra em uma coleção de documentos, há uma lista de todos os documentos que contêm essa palavra, utilizada para acelerar a pesquisa de documentos que contêm palavras-chave.

- **Classificação da pesquisa por relevância:** calcula a probabilidade de aquela página corresponder ao que usuário procura, baseando-se na quantidade de palavras-chave, no tipo de documento, na avaliação de conteúdos, entre outros fatores.



Fique atento

Consulta e **pesquisa** podem parecer sinônimos, mas, nesse contexto, possuem resultados distintos. A consulta é aquela em que apenas os resultados que correspondem aos termos inseridos são exibidos. Já a pesquisa pode incluir termos opcionais, fornecendo resultados ordenados por relevância.

O ElasticSearch é um motor de pesquisa orientado a documentos, gratuito e de código aberto, baseado no Apache Lucene. Ele permite o armazenamento de dados centralmente, proporcionando uma busca rápida e um cálculo de relevância com ajuste fino e analítico, podendo ser ampliado com facilidade. De acordo com os distribuidores, o ElasticSearch pode ser utilizado para realizar buscas em aplicativos e *websites* ou para buscas de cunho empresarial, além de outras funções de análise e monitoramento de dados (ELASTIC, c2020). Além disso, ele aceita dados de diferentes tipos e fontes.

Após a análise dos dados brutos, ocorre a indexação, em que os dados são salvos em documentos do tipo JSON, e o índice é formado pelo conjunto de documentos relacionados entre si. Cada documento possui um conjunto de chaves (p. ex., nomes de campos) que está relacionado aos seus valores (que podem ser nomes, números, datas, etc.). A estratégia utilizada pelo ElasticSearch na estruturação dos dados é o índice invertido. Assim, durante o processo de indexação, o ElasticSearch armazena os documentos e desenvolve um índice invertido para tornar os dados contidos ali "buscáveis", praticamente em tempo real (ELASTIC, c2020).

Por ser um sistema distribuído, os índices podem ser divididos em diferentes *shards* (partições), que podem ser replicados. Ou seja, há uma maior consistência na criação dos índices, com maior tolerância a falhas no servidor, já que é possível recuperar os índices em outras partições, mesmo que a partição principal falhe. Além disso, o ElasticSearch suporta facetagem e percolação, sendo útil para notificar quando um novo documento corresponde à consulta registrada.



Saiba mais

Percolação é um método de pesquisa reverso em que, em vez de retornar todos os documentos correspondentes ao que foi pesquisado, são retornados todos os resultados de pesquisa já armazenados que correspondem a um documento.

O ElasticSearch pode ser implantado e gerenciado de diferentes formas, seja por meio de serviços consolidados, como o ElasticSearch Service, que está disponível na Amazon Web Services (AWS), no Google Cloud Platform (GCP) e no Alibaba Cloud, seja por meio do *download* e da instalação dele no seu próprio *hardware* ou serviço de armazenamento em nuvem. Além disso, mais de 10 aplicações foram desenvolvidas com base nele, com o objetivo de aprimorar os sistemas de análises e buscas de dados, como o Elastic App Search e o Elastic Site Search.

No caso do Elastic App Search, é possível utilizar a capacidade concentrada do ElasticSearch em conjunto com diferentes APIs (Application Programming Interface; ou Interface de Programação de Aplicações, em português) e painéis intuitivos. Nele, existem recursos de tolerância a erros de digitação, bem como a possibilidade de calibrar a relevância da busca a partir de conjuntos de sinônimos, reordenar os resultados para uma determinada consulta e atribuir pesos distintos para fazer um ajuste fino da precisão geral. Já o Elastic Site Search possibilita uma busca avançada de *sites* de modo prático e rápido. O seu rastreador é livre de manutenção e permite a personalização intuitiva e a análise robusta dos resultados de busca. Empresas como SurveyMonkey e Shopify utilizam esse sistema em seus *sites*.



Saiba mais

Para aprender a criar uma tabela e realizar buscas em um banco NoSQL, acesse a página do guia "Crie e consulte uma tabela NoSQL", publicado na página da Amazon Web Services (AWS).

Como visto, os motores de busca facilitam a obtenção de conhecimento e a organização e a manipulação de dados, tornando-se fundamentais para o desenvolvimento de atividades essenciais na área da tecnologia. Desse modo, é indiscutível a importância e a usabilidade dessas ferramentas no nosso dia a dia, seja por aplicações do ElasticSearch ou de motores de busca de abrangência global, seja por uma aplicação para *web* ou para os arquivos do seu computador pessoal.



Referências

BERNERS-LEE, T. J.; CAILLIAU, R.; GROFF, J.-F. The world-wide web. *Computer Networks and ISDN Systems*, North Holland, v. 25, n. 4-5, p. 454-459, 1992.

BUSH, V. As we may think. *The Atlantic Monthly*, Boston, v. 176, n. 1, p. 101-108, 1945.

COMO funciona a pesquisa Google. *In:* GOOGLE. Mountain View, [2020?]. Disponível em: https://www.google.com/search/howsearchworks/. Acesso em: 9 jun. 2020.

ELASTIC. *Elasticsearch*. Mountain View, c2020. Disponível em: https://www.elastic.co/pt/elasticsearch/. Acesso em: 18 jun. 2020.

EMTAGE, A.; DEUTSCH, P. Archie: an electronic directory service for the internet. *In:* USENIX CONFERENCE, 1992, Quebec. *Anais...* San Francisco: USENIX, 1992. p. 93-110.

HIRIYANNAIAH, S. *et al.* Semi-structured data analysis and visualisation using NoSQL. *International Journal of Big Data Intelligence, [s. l.]*, v. 5, n. 3, p. 133-142, 2018. Disponível em: https://www.inderscience.com/info/inarticle.php?artid=92657. Acesso em: 9 jun. 2020.

MCCREARY D. G.; KELLY, A. M. *Making sense of NoSQL*: a guide for managers and the rest of us. Shelter Island: Manning, 2014.

MELTON, J.; BUXTON, S. *Querying XML:* XQuery, XPath, and SQL/XML in context. Burlington: Morgan Kaufmann, 2011.

NYCE, J. M.; KAHN, P. (Ed.). *From memex to hypertext:* Vannevar Bush and the mind's machine. Cambridge: Academic Press, 1991.

TARAKESWAR, K.; KAVITHA, D. Search engines: a study. *Journal of Computer Applications*, New York, v. 4, n. 1, p. 29-33, 2011.

WINDOWS search overview. *In:* MICROSOFT. Redmond, 31 may 2018. Disponível em: https://docs.microsoft.com/en-us/windows/win32/search/-search-3x-wds-overview. Acesso em: 9 jun. 2020.

YOSHIOKA, M.; HARAGUCHI, M. On a combination of probabilistic and boolean ir models for WWW document retrieval. *ACM Transactions on Asian Language Information Processing, [s. l.]*, v. 4, n. 3, p. 340-356, 2005.

ZHAO, Y. The application of Bayesian learning in the search engine. *Wireless Personal Communications, [s. l.]*, v. 103, n. 2, p. 1121-1131, 2018.



Fique atento

Os *links* para *sites* da *web* fornecidos neste capítulo foram todos testados, e seu funcionamento foi comprovado no momento da publicação do material. No entanto, a rede é extremamente dinâmica; suas páginas estão constantemente mudando de local e conteúdo. Assim, os editores declaram não ter qualquer responsabilidade sobre qualidade, precisão ou integralidade das informações referidas em tais *links*.

Encerra aqui o trecho do livro disponibilizado para esta Unidade de Aprendizagem. Na Biblioteca Virtual da Instituição, você encontra a obra na íntegra.

Conteúdo:

SOLUÇÕES EDUCACIONAIS INTEGRADAS

Dica do Professor: Motores de busca (search engines)

A Amazon é a empresa mais valiosa do mundo. Seu segmento de atuação é amplo, como no desenvolvimento de inteligência artificial, por exemplo, ao mesmo tempo que se mostra grande referência no comércio eletrônico.

Este último tem-se expandido nos últimos tempos, tornando-se, inclusive, o maior ponto de partida dos clientes na hora de buscar por fornecedores para realizar a compra de diferentes itens. Parte disso se deve ao excelente motor de busca desenvolvido pela empresa, o A9, que é muito mais focado em qual produto é mais atraente ao cliente do que em quais resultados simplesmente correspondem àquela pesquisa.

Na Dica do Professor, conheça um pouco mais sobre esse motor de busca e veja por que ele é tão importante para a notoriedade da Amazon nesse ramo.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Atividade 4 (A4)

1) **Os motores de busca são criados com o objetivo de localizar informações relevantes para o usuário por meio de termos inseridos nas barras de busca. Quanto ao processo que permite isso, é verdade que:**

A) a cada pesquisa, uma nova varredura e indexação ocorrem pelo motor de busca, sem utilizar dados anteriores.

B) a indexação é o processo de fazer um rastreamento na Web para descobrir conteúdos novos.

C) os Web *crawlers* são responsáveis por coletar dados para a indexação e também por identificar conteúdos duplicados.

D) o principal critério de classificação de uma página na exibição dos resultados é o tamanho do texto.

E) pouco importa a posição e a quantidade de vezes que a palavra-chave apareça, desde que ela esteja lá.

2) **O usuário se conecta aos motores de busca a partir de barras de pesquisa presentes nas interfaces criadas. Quanto ao conteúdo inserido nessas barras e à forma como os motores o utilizam, é verdade que:**

A) todos os motores de busca apresentam resultados idênticos se você usar as mesmas palavras.

B) o motor só consegue utilizar as palavras do jeito como estão exatamente escritas.

C) se você inserir mais de uma palavra, esse conjunto será entendido como uma frase.

D) apenas as palavras inseridas são levadas em consideração no momento de o motor realizar a busca.

E) o resultado leva em conta as palavras-chave e também um possível contexto de acordo com o usuário.

3) **A relevância é um componente importante para a classificação dos resultados. Quanto à forma como ela é estabelecida, é verdade que:**

A) diferentes motores de busca utilizam diferentes parâmetros e pesos para determiná-la.

B)

- ao utilizar o modelo probabilístico, os dados são julgados apenas como relevantes ou irrelevantes.

C) o modelo booleano é o mais recente e considera a combinação perfeita das palavras-chave.

D) o modelo booleano poderá ser melhorado a partir de inferências bayesianas.

E) a aprendizagem bayesiana ignora os dados únicos dos usuários, fornecendo um resultado generealizado.

4) Quanto à fonte de dados, os motores de busca podem utilizar metadados, arquivos locais e até uma combinação de bancos de dados. Quanto a esse aspecto, é possível afirmar:

A) Os metadados são arquivos de dados combinados, como um álbum de fotos.

B) Os metadados são formulários preenchidos manualmente pelo dono do *site*.

C) A pesquisa federada reindexa todos os resultados encontrados.

D) Os motores de *desktop* procuram por arquivos presentes na máquina local.

E) Os motores de *desktop* só são capazes de procurar por aquivos de texto.

5) O Elasticsearch é um motor de busca distribuído e também uma solução de armazenamento NoSQL. Quanto a ele, pode-se afirmar que:

A) os dados são armazenados de forma relacional.

B) foi construído tendo como base o Apache Lucene.

C) usa um índice de intervalo para indexar os valores.

D) só pode ser implementado em máquinas locais.

E) é um sistema completamente pago.

Saiba mais: Motores de busca (search engines)

Para ampliar o seu conhecimento a respeito desse assunto, veja abaixo as sugestões do professor:

Recuperação de informação — conceitos e tecnologia das máquinas de busca

No capítulo 6,"Linguagens de consulta", aprenda um pouco sobre os diferentes tipos de consulta e as diferentes formas de linguagem que podem ser utilizados para a realização de pesquisas nos mecanismos de busca.

Conteúdo interativo disponível na plataforma de ensino!

Como a busca do Google realmente funciona

Neste artigo, conheça nos mínimos detalhes como a busca do Google Search funciona, incluindo descrições de ferramentas como o RankBrain e o Knowledge Graph.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.

Como fazer Scrapy com Python para iniciantes

No capítulo, conheça a extração de dados de páginas a partir de ferramentas de rastreio Web. Neste tutorial, aprenda a extrair informações de uma página a partir do método Scrapy utilizando a linguagem Python.

Aponte a câmera para o código e acesse o link do conteúdo ou clique no código para acessar.